单位代码：10293　密　级：

# 南京邮电大学

# 专业学位硕士论文

论文题目：基于改进的协同过滤算法在课程资源推荐系统的应用


学　　号　1220013412

姓　　名　刘昊东

导　　师　王 诚

专业学位类别　电子信息硕士

类　　型　全日制

专业（领域）　电子信息


论文提交日期　2023 年 5 月

中国知网 https://www.cnki.net

# Application of improved collaborative filtering algorithm application in course resource recommendation system

Thesis Submitted to Nanjing University of Posts and Telecommunications for the Degree of Master of Engineering

By

Liu Haodong

Supervisor: Prof. Wang Cheng

May 2023

中国知网 https://www.cnki.net

# 摘要

如今，信息技术与教育教学正在迅速融合，我们熟知的线下教育模式已经很难满足学生对个性化学习资源的需求，尤其在疫情期间，在线教育已经成为传统教育的重要补充，这种趋势也在不断地推动线上教育行业的发展，随之各式各样的网络课程资源也涌入到在线教育平台，从而导致课程信息严重“超载”，用户在学习过程中会明显感受到平台上的课程资源过于纷繁杂乱，不能根据用户的特点和需求对其选择课程进行个性化引导，很容易让用户在大量的网络课程资源搜寻中迷失方向，使得最终的学习效率大打折扣。

为了精准地刻画用户画像，拟采用协同过滤算法为用户推荐个性化的课程资源。而在实际应用过程中，此算法存在着诸多问题影响着推荐系统的性能，如拓展性差、冷启动、马太效应、数据稀疏等问题。因此本文在传统协同过滤算法的基础上对其进行改进，然后将改进的算法通过加权得到混合推荐算法，最终设计并实现课程资源推荐系统。本文主要工作如下：

（1）研究当下课程资源推荐平台的现状，阅读与推荐系统和推荐算法相关的文献资料，以及对协同过滤算法和混合推荐算法的研究现状和相关理论进行学习，并探索一些优秀学者对算法的改进和验证。

（2）提出了基于用户特征权重置信度的协同过滤推荐算法，此算法一方面缓解了传统的协同过滤算法在遇到新用户时没有历史行为数据而引起的冷启动难题，另外一方面，也降低了因用户评分矩阵的稀疏性所造成推荐效果较差的影响。

（3）提出了基于热门度修正因子的协同过滤推荐算法，此算法通过判断该项目的热门度是否超过相应的阈值，来决定对它是否进行修正，其原理是降低热门项目在算法计算过程中的比重，从而更个性化地推荐用户所感兴趣的一些项目。然后确定上述两种改进算法权重因子的合适取值，并对其进行融合，得到最终的基于改进算法加权的混合推荐算法。经过试验对比，可以证明本文改进后算法的性能指标较传统的协同过滤算法以及其他学者改进的算法有了显著提升，具有更好的评分预测效果。

（4）最后，将改进的算法应用到课程资源推荐系统，根据不同功能模块分析了此系统的需求，并对数据库表进行设计，利用 Spring、Vue、Axios 等技术栈实现整个系统的开发。

**关键词：课程资源，协同过滤，热门度修正因子，混合推荐算法，课程推荐系统**



中国知网 https://www.cnki.net

# Abstract

Nowadays, information technology and education are rapidly integrating, and the familiar offline education model can hardly meet students' demand for personalized learning resources. Especially during the epidemic period, online education has become an important supplement to traditional education, and this trend is also constantly promoting the development of online education industry. As a result, a variety of online course resources also flood into the online education platform, resulting in a serious "overload" of course information. During the learning process, users will obviously feel that the course resources on the platform are too complicated and disorderly, and it is not possible to give personalized guidance to the course selection according to the characteristics and needs of users. It is easy for users to get lost in the search for a large number of online course resources. The final learning efficiency is greatly reduced.

In order to accurately depict the user portrait, collaborative filtering algorithm is proposed to recommend personalized course resources for users. However, in the practical application process, the algorithm has many problems that affect the performance of the recommendation system, such as poor expansion, cold start, Matthew effect, data sparse and so on. Therefore, this paper improved the traditional collaborative filtering algorithm on the basis of it, and then weighted the improved algorithm to get a mixed recommendation algorithm, and finally designed and implemented the course resource recommendation system.The main work of this paper is as follows:

(1) Study the current status of course resource recommendation platform, read literature related to recommendation system and recommendation algorithm, study the research status and related theories of collaborative filtering algorithm and hybrid recommendation algorithm, and explore the improvement and verification of algorithms by some outstanding scholars.

(2) A collaborative filtering recommendation algorithm based on user feature weight confidence is proposed. On the one hand, this algorithm alleviates the cold startup problem caused by the absence of historical behavior data of the traditional collaborative filtering algorithm when encountering new users; on the other hand, it also reduces the impact of poor recommendation effect caused by the sparsity of the user score matrix.

(3) A collaborative filtering recommendation algorithm based on the popularity correction factor is proposed. This algorithm determines whether to correct the project by judging whether the popularity of the project exceeds the corresponding threshold. The principle is to reduce the



中国知网 https://www.cnki.net

proportion of popular projects in the algorithm calculation process, so as to recommend some projects that users are interested in more personalized. Then, appropriate values of the weight factors of the above two improved algorithms are determined and fused to obtain the final hybrid recommendation algorithm weighted by the improved algorithm. Through experimental comparison, it can be proved that the performance index of the improved algorithm in this paper is significantly improved compared with the traditional collaborative filtering algorithm and the algorithm improved by other scholars, and it has better score prediction effect.

(4) Finally, the improved algorithm is applied to the course resource recommendation system, and the requirements of the system are analyzed according to different functional modules, and the database table is designed, and the development of the whole system is realized by using Spring, Vue, Axios and other technical stacks.

**Key words:** Course resources, collaborative filtering, popularity correction factor, hybrid recommendation algorithm, course recommendation system



中国知网 https://www.cnki.net

# 目　录

第一章 绪论.....1
1.1 课题研究背景及意义.....1
1.2 国内外研究现状.....2
1.2.1 线上课程推荐研究现状.....2
1.2.2 推荐算法研究现状.....3
1.2.3 协同过滤算法研究现状.....4
1.2.4 混合推荐算法研究现状.....5
1.3 本文研究内容.....6
1.4 章节安排.....6
第二章 推荐算法相关理论及数据集预处理.....8
2.1 传统推荐算法的分类.....8
2.1.1 基于内容的协同过滤算法.....8
2.1.2 基于用户的协同过滤算法.....9
2.1.3 基于项目的协同过滤算法.....11
2.1.4 基于模型的协同过滤算法.....12
2.2 推荐系统的评价指标.....12
2.3 原始数据预处理.....13
2.3.1 数据集示例.....13
2.3.2 数据预处理.....14
2.4 本章小结.....18
第三章 基于用户特征权重置信度的协同过滤推荐算法.....19
3.1 引言.....19
3.2 问题的提出.....19
3.2.1 用户共同评分课程数量的差异.....19
3.2.2 用户特征对推荐算法的影响.....20
3.3 算法改进.....21
3.3.1 用户特征权重的建立.....21
3.3.2 基于用户特征权重的置信度因子.....22
3.3.3 基于用户特征权重置信度的协同过滤推荐算法.....24
3.3.4 算法流程.....24
3.4 实验结果与分析.....25
3.4.1 实验环境.....25
3.4.2 实验数据集.....25
3.4.3 实验评价指标.....26

中国知网 https://www.cnki.net

3.4.4 实验结果和分析.....26
3.5 本章小结.....29
第四章 基于改进算法加权的混合推荐算法.....30
4.1 引言.....30
4.2 算法改进.....30
4.2.1 项目的热门程度.....30
4.2.2 热门度修正因子.....31
4.2.3 基于热门度修正因子的协同过滤推荐算法.....31
4.2.4 基于改进算法加权的混合推荐算法.....32
4.2.5 算法流程.....32
4.3 实验结果与分析.....33
4.3.1 实验环境与评价指标.....33
4.3.2 实验数据集.....34
4.3.3 实验结果和分析.....34
4.4 本章小结.....39
第五章 课程资源推荐系统的设计与实现.....40
5.1 需求分析.....40
5.2 课程资源推荐系统的设计.....40
5.2.1 开发环境.....40
5.2.2 系统框架的设计.....41
5.3 功能模块的设计与实现.....42
5.3.1 数据模块.....42
5.3.2 算法分析模块.....45
5.3.3 功能模块设计.....46
5.3.4 课程资源推荐系统展示.....50
5.4 本章小结.....53
第六章 总结与展望.....54
6.1 总结.....54
6.2 展望.....54
参考文献.....56

中国知网 https://www.cnki.net

# 第一章 绪论

如今各个平台的信息量都在急剧膨胀，而用户感兴趣的信息却只是其中的极小部分，在寻找所需内容的过程中，形形色色的信息涌入他们的眼帘，造成用户很难捕捉到自己感兴趣的信息。为了提高用户的体验感，一项卓越的研究成果——推荐技术被优秀的学者提出，源于其不仅能增强用户的使用体验，还能带来巨大的商业价值，因此，个性化推荐技术成为如今学术界和工业界的研究热点之一。首先本章对课题研究的背景和意义进行了详细地介绍，其次对关于此课题相关技术国内外的研究现状进行分析，最后对本文的主要内容及章节安排进行简单介绍。

## 1.1 课题研究背景及意义

继 2015 年政府工作报告中“互联网＋[1]”这一概念被首次提出，同年 12 月，政府已宣布将“互联网+”列为国家战略，并将“互联网+教育”视为该战略的重要组成部分，这一举措引起了学术界和产业界的广泛关注和重视。现如今，国家出台了许多措施，促使教育行业逐渐向信息化靠拢。源于线上授课这种学习方式具有很强的灵活性，学习者无需前往教室或学习中心，这种学习模式允许学习者按照自己的进度和时间表安排学习，从而更好地满足他们的学习需求和生活需求。

据统计，在过去的两三年里，将近百分之九十的学生或多或少都接触到线上授课的这种模式，甚至在一些特殊情况下，线上学习对于一些中小学生获取新知识变得尤为重要。随着线上教育这种方式越来越受到用户的青睐，教育平台上的课程资源也百花齐放，并且不同的平台对一些课程的分类也会有些不同，这种现象导致用户很难对信息进行高效处理，用户在面对各式各样的课程资源[2]时也会眼花缭乱，可能用户对某一类型的课程感兴趣，但是却不知道课程的具体名称，采用搜索课程的方式会显得过程稍显冗余；或者相同课程不同老师授课，用户很难抉择，从而浪费很多的时间去做尝试判断。针对上述问题，课程资源推荐系统的出现就显得尤为重要，它的出现在一定程度上缓解了用户择课的苦恼，提高他们的学习效率。

现如今推荐技术[3]在不断地被一些优秀学者打磨改进，其中对于用户行为习惯的探索在算法中应用起到了显著成效，降低了因信息超载所造成用户体验感差的影响。推荐技术的飞速提升也推动着课程资源的推荐更为精准，为了使推荐服务更加贴合用户的行为习惯，提出



中国知网 https://www.cnki.net

了基于用户行为的推荐算法，此算法模型的出现不仅可以减少用户在搜寻自己感兴趣的课程所使用的时间，而且提高了用户对推荐内容的满意度。当然该技术的提出也为平台的商家带来了许多商机，一方面使平台的推荐质量提升了一个台阶，平台的口碑会更好，随之而来的浏览量也会增加；另一方面使用户更加信任这个平台，从而实现平台用户到消费者的转化。尽管此技术已经投入应用到多个线上教学平台，但依旧存在很多因素影响着推荐系统的性能，需要我们带着问题对算法的改进做更深层次地探究。

近几年来大规模线上公开课 MOOC[4]越来越受到学生的欢迎，国外的用户通常使用 EdX、Coursera、Khan Academy[5]这些教育平台开展学习，国内比较火爆的在线学习平台有泛雅网络[6]教学平台、51talk[7]、猿题库等。虽然线上授课的方式为人们带来了很多便利，但是课程推荐过程中还是存在一些问题，主要有以下三个方面：第一，由于现在课程种类各式各样，相同的课程可能会被贴上多个种类的标签，造成课程的分类很模糊；第二，在线学习平台没有充分挖掘用户之间的潜在关系以及用户的特征信息，因此个性化推荐[8]仍然是平台需要攻克的一项难题；第三，随着用户数不断增多，平台上的课程资源也不断丰富，但是平台没有对课程资源的质量进行把控，一些质量不高的课程就会被推荐给用户，从而给用户在学习时造成很大的干扰。

自上世纪九十年代以来，许多研究者参与到推荐系统[9]的研发过程中，Resnick 等人最先提出这个名词，该系统的大体思路是这样的：先将用户关于项目的历史数据进行预处理，进而通过推荐算法[10]找到符合用户兴趣的项目，最终为用户完成推荐。在如今日新月异的大环境中，推荐算法已经和我们的生活息息相关，并且也推动了一些软件的进步和发展。当下比较流行的推荐算法分为以下几种：基于内容推荐[11]、协同过滤推荐[12]以及混合推荐[13]。分析用户的行为数据是基于内容推荐的核心；协同过滤算法又分为基于内存和基于模型两大类型，也是当下课程资源推荐系统中常用的算法之一；混合推荐算法融合多种推荐算法，可以克服推荐系统的多种难题，推荐算法一经提出就在不同的领域得以使用，随之而来的一些问题也被学者发现，主要包括冷启动[14]、用户—项目评分数据稀疏[15]、推荐系统的可扩展性等。

## 1.2 国内外研究现状

### 1.2.1 线上课程推荐研究现状

上个世纪九十年代，Minnesota 大学科研团队对推荐系统进行了深入的探索，进而开启了对该系统研究的先河，同时也提出了“协同过滤”这一重要算法概念。在二十世纪初，国内



中国知网 https://www.cnki.net

掀起了一波对个性化推荐算法研究的浪潮，尽管与国外对此算法的研究相比，起步较晚，但是现在已经应用到众多行业的不同平台，如电商领域的天猫、唯品会等，通过将推荐算法植入到这些平台，提高用户购物的体验感；通过将个性化推荐应用到新闻资讯领域，如微博、知乎、头条等平台，不但能让用户浏览到感兴趣的讯息，而且提高用户对平台的信任度；当下像学而思、作业帮这些教育平台非常热门，都利用用户画像推荐相关的课程资源。推荐算法的出现为上述平台带来了很大帮助，很大程度地提高了用户在面对海量信息时抉择的效率，同时也将访客变为平台的忠实用户，从而实现商业价值。

钟亚妹[16]等人首先对系统前后端开发所用到的技术框架进行了简单地介绍，并在此线上学习系统运用协同过滤算法，最终帮助用户更加精准地找到自己感兴趣的课程。左琳[17]等人研发出一种带有数据增强的线上教学推荐系统，有效地解决了当下教育推荐技术训练数据匮乏的问题。彭云[18]等人为了挖掘更有意义的教学资源，建立了教师和学生之间资源共享，课程共建的新型教学关系，并采用协同过滤算法运用到教学资源推荐策略的实际应用当中。郭俭[19]等人基于苏州线上教育系统数据集提出了基于用户资源画像的算法改进，主要对用户的学习行为数据和用户设定进行挖掘研究。

国外也非常重视教育行业，因此众多研究人员也对线上课程推荐技术做出一些改进。Y Hou[20]等人设计了一个基于大数据支持、上下文感知的在线学习课程推荐系统，该系统可以处理动态以及庞大的数据集，通过使用个性化的上下文信息和历史统计来推荐课程。N. Vedavathi[21]等人研发出了一种在电子学习平台中向学生推荐课程的新技术，帮助学习者选择最佳课程，文章中的蝴蝶杂草优化算法（BWO）是通过结合入侵杂草优化算法（IWO）和蝴蝶优化算法（BOA）而新设计的。YK Ng[22]等人发现每个大学生在学习方面都有不同的需求，并通过对用户不同的标签进行分析和研究用户学习课程的顺序，提出了基于结合课程分析结果的混合推荐技术，按照学生个人偏好对潜在课程进行排名。LPJ Rani[23]等人认为选择合适的课程对学生成绩的提升非常重要，因此考虑通过推荐用户所选择课程同类型的课程，文章使用皮尔逊相似度来计算学生之间的相似性，最后利用基于记忆筛选的方法来对每个课程的分数进行评价，并将预期分数最高的课程推荐给用户。

### 1.2.2 推荐算法研究现状

随着不同类型的推荐算法被提出并投入到应用中，许多学者对此算法的研究产生了浓厚兴趣。在推荐算法中基于内容的推荐使用的频率非常高，其中我们可以将内容理解为物品的主要特征或者属性，例如课程的类型、名称、时长等都是特征[24]。而这些特征为后续算法的



中国知网 https://www.cnki.net

训练提供了数据的来源，陈婷[25]等人对现有的基于信任关系的推荐算法进行了研究，发现这些算法通常假设用户之间的关系是单一的，并没有对用户之间的信任关系进行深入挖掘，因此文章基于全局、局部信任关系进行建模，然后将概率矩阵分解模型融入到基于信任网络关系的协同过滤算法中。庞海龙[26]提出了基于线性回归模型的协同过滤推荐算法，此算法充分利用用户的行为数据以及用户和项目自身的特征数据来构建相似矩阵，并将实际评分值与预测评分值之间的差值作为线性回归模型训练的数据输入，根据训练好的模型来对未评分的项目进行预测评分。

B Mazoure[27]等人主要研究基于会话的推荐场景，希望在连续交互期间向用户推荐项目，目前许多工作已经将情景强化学习（RL）技术应用于基于会话的推荐，但这些方法没有考虑到会话之间用户意图会发生变化，因此他们研发了一种新的批处理 RL 算法，称为短期策略改进（SHPI），此算法通过改变 SHPI 中的地平线参数，修复了 RL 技术中的一些问题。D Boughareb[28]等人提出了一种基于文本标签选择的推荐算法，该算法利用用户属性标签和基于某些参数（频率、位置）生成了一个基于项的图（R-graph），其节点表示项，边表示这些项之间的相关性得分，开发了一种基于相关分数和术语邻域的算法，用于合适的标签选择和推荐。E Anakolu[29]开发了一个使用多目标优化方法建立的数学模型。为了降低这个非线性整数规划模型的复杂性，通过分解技术对模型结构进行分解，对所得到的公式进行求解，进而提出了一个新的迭代框架，通过遗传算法将所有目标函数合并到生成的群体中，利用启发式算法为每个用户选择一个群体，从而实现所期望的聚合多样性。

### 1.2.3 协同过滤算法研究现状

协同过滤算法有两种常用的算法，一种是基于物品的协同过滤方法[30]，另一种是基于用户的协同过滤[31]方法。两种算法的原理比较相似，都是通过相似度计算公式计算用户或者物品之间的相似度，并为目标用户寻找到最近邻，从而进行推荐。

殷佳莉[32]等人考虑到随着时间的不同，用户的兴趣爱好也是在不断变化的，作者结合人类的遗忘曲线这一特性，得到时间衰减函数作为权重因子，提出了一种融合时间衰减函数的协同过滤推荐算法。赵超[33]等人认为用户之间不仅有显式的信任关系，还考虑到用户之间隐含的信任关系，因此提出了一种基于隐含信任关系概率张量分解的推荐算法。赵文涛[34]等人提出融合相似度和预筛选模式的协同过滤算法。首先在相似度模型中定义相对评分差异，并列举应满足的定性条件得到优化的相似度，同时考虑基于信息熵改进的评分偏好和用户全局评分的数量信息作为权重因子，更好地区分用户间差异。其次通过分析相似度模型和评分预测



中国知网 https://www.cnki.net

公式的隐式约束，提出预筛选模式，过滤掉大量无效的用户及对应的评分数据，进一步提高计算效率，最终通过融合相似度和预筛选模式得到改进的推荐算法。

Fuad E[35]等人提出了一种基于p矩阵的相似性度量，基于p矩阵的个人评级数据统计（PMS）用于分析用户评级习惯，在PMS的基础上，提出了新的相似性度量方法来量化两个用户之间的距离，重点关注用户对项目的偏好和他们的评分习惯。JX Ren[36]等人意识到传统的推荐算法存在冷启动和解释性差的问题，并且没有关注时间这一重要因素对算法性能的影响，为了解决这些难题，提出了一种基于动态信任衰减的协同过滤算法（DTA-CF），并且通过实验验证了该算法的可行性。N Sachdeva[37]等人根据算法和数据集特征（例如稀疏性特征、序列动力学等），探究其对算法性能的影响，并且设计SVP-CF模型——特定于数据的采样策略，旨在保持采样后模型的相对性能，这种算法特别适合对长尾数据处理。

### 1.2.4 混合推荐算法研究现状

为了将不同推荐算法的优点结合起来，混合推荐算法应运而生。混合推荐算法可分为串行范式[38]和并行范式[39]以及分支范式[40]。将前一种算法生成的结果作为数据源输入到后一种算法当中，这种方式成为串行范式；而并行范式是将多种推荐算法通过加权的方式进行融合；分支范式具有很强的高效性，根据输入条件的不同，会自动匹配合适的算法进行模型计算。

于旭[41]等人首先通过挖掘了开发者的隐式特征，提出面向隐式特征的矩阵分解(MF)推荐算法，然后将面向显示特征的推荐算法与其进行融合，最后提出多层感知器融合算法。单晓红[42]等人通过研究用户对产品一些倾向性意见和产品本身的特征属性，构建了基于用户偏好与产品特征的混合推荐算法。钟乾[43]等人提出了积极、消极相似度这两个概念，并采用分布式符号数据的距离度量进行计算，最终通过协同过滤算法为目标项目进行评分预测。

A Roy[44]等人提出了一种用于群体推荐系统的基于内容增强的改进白蚁群体优化评级预测算法（CMTRP），CMTRP采用混合推荐框架来对数据进行处理，该框架利用公共评级来帮助克服可扩展性差的问题。KK A[45]等人提出方法的主要思想是使用卷积神经网络从图像中识别用户提出的建议，将其应用到推荐算法当中。Y Gao[46]提出了区分时间段的动态网络智能混合推荐算法（DIHR），它是一种结合DEMATEL和TOPSIS方法的新模型，用于解决考虑时间段的网络智能推荐问题，此方法利用 DEMATEL 方法评估顾客对商品指标的偏好关系，采用TOPSIS方法结合直觉模糊数（IFN）对商品进行评价和排序。



中国知网 https://www.cnki.net

## 1.3 本文研究内容

在所有推荐技术中协同过滤算法的运用场景最为广泛，因此本文对该算法做了如下的改进：文章通对修正余弦相似度计算公式中引入基于用户特征权重的置信度来缓解评分矩阵的稀疏性；为了抑制热门课程对实际推荐效果的影响，将热门度修正因子引入到皮尔逊相似度计算公式中，最终相似度计算是通过上述两个改进的公式按照相应的权重进行融合而生成的混合推荐算法，并将此算法应用在设计的课程资源推荐系统上。本文研究的主要内容如下：

（1）探究当前线上教育推荐系统所使用的推荐算法，并对此算法的研究现状进行学习了解；

（2）为了更好地为用户做出个性化推荐，以及缓解评分矩阵的稀疏性，本文使用 Jaccard 函数来计算用户间的置信度，并且在计算过程中设定用户之间对同一课程评分差值的临界值作为衡量其置信度的约束条件，从而提高了算法的精度，最后结合用户自身特征信息，提出了一种基于用户特征权重置信度的协同过滤推荐算法；

（3）以皮尔逊相似度作为协同过滤算法相似性度量的基准计算式，通过将热门度修正因子引入到协同过滤算法中，并且通过实验设定合适的热门度阈值，可以有效地削弱热门项目对推荐结果造成的影响，一个项目的热门程度可以通过用户对此项目所发出正向反馈的次数来表示，因此提出了一种融入热门度修正因子的协同过滤推荐算法；

（4）最终相似度计算公式通过将上述改进的算法按照权重进行融合，生成新的混合推荐算法，使得在为用户生成推荐的同时，考虑到上述问题对推荐效果的影响；

（5）选择课程推荐应用场景，将本文的基于改进算法加权的混合推荐算法应用到课程资源推荐原型系统中，实现算法的应用。

## 1.4 章节安排

本文各章节的安排如下：

第一章：绪论。首先介绍课题的研究背景和意义，分析线上课程推荐的形势以及存在的问题，之后详细地介绍了线上课程推荐、推荐算法、协同过滤算法以及混合推荐算法在国内外的研究现状，最后对研究内容和论文框架进行阐述。

第二章：推荐算法相关理论及数据集预处理。本章主要介绍推荐算法的分类、评测方法以及对原始数据集进行预处理。

第三章：基于用户特征权重置信度的协同过滤推荐算法。本章将用户特征权重和置信度



中国知网 https://www.cnki.net

函数引入到相似度计算公式中，并通过实验进行验证。

第四章：基于改进算法加权的混合推荐算法。本章首先提出了融入热门度修正因子的协同过滤推荐算法，再将其与第三章提出的算法按照相应的权重进行融合，生成混合推荐算法，最终通过实验验证改进算法的有效性。

第五章：课程资源推荐系统设计与实现。从需求分析、开发环境、系统框架、功能模块设计、数据库设计以及应用展示这些部分对系统进行详细地介绍，最后实现了课程资源推荐系统。

第六章：总结与展望。对本文的工作内容进行总结，指出存在的不足之处并对今后需要改进的地方进行展望。



中国知网 https://www.cnki.net

# 第二章 推荐算法相关理论及数据集预处理

推荐算法现如今已成为大多数商用平台必不可少的算法之一，尤其是随着个性化推荐技术的出现，其更能为平台用户推荐符合自身画像的内容。此技术的出现直接推动了信息挖掘的革新，使得用户不需要花费大量精力搜寻信息，同时也帮助商家实现利益最大化。

## 2.1 传统推荐算法的分类

在传统推荐算法的研究中，国内外学者根据不同场景提出了不同类型的推荐算法，其中单类协同过滤[47]推荐算法占据了半壁江山。图 2.1 展示了传统的推荐算法的详细分类。

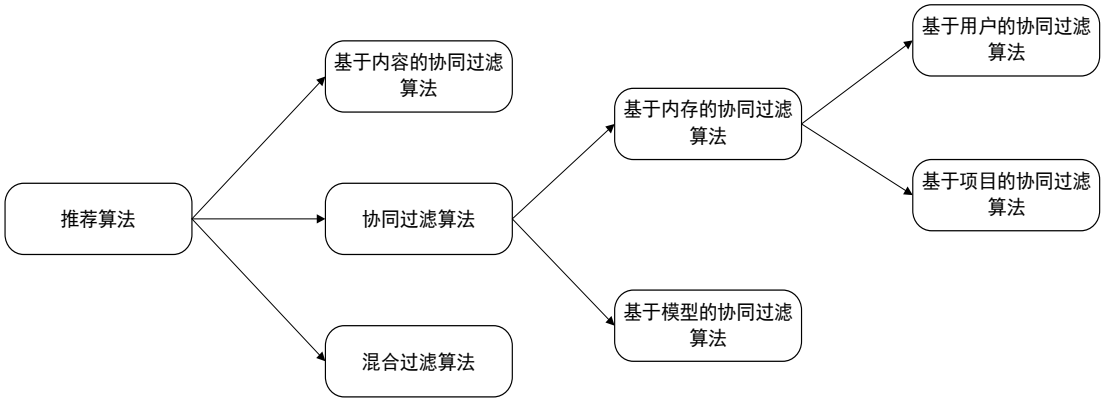


图 2.1　推荐算法的分类

### 2.1.1 基于内容的协同过滤算法

在目前的推荐系统中，基于内容的协同过滤算法运用的十分宽泛。其基本思想是根据用户已选项目的内容信息，分析内容的特征信息[48]，提取特征信息中用户的需求兴趣，通过计算内容之间的相似度，将相似度高的内容推荐给用户。如图 2.2 展示基于内容的协同过滤算法推荐的流程。

基于内容的协同过滤算法主要分为三个步骤：

1. 建立每个项目的信息表征；
2. 根据用户的行为信息建立用户的偏好特征；
3. 将用户的偏好特征与项目信息表征进行比对，为用户推荐合适的内容。

其中对内容特征信息的提取是基于内容的协同过滤算法的核心步骤，这一关键操作对内容的结构性特征要求很高，用户所感兴趣之处须和内容特征比较贴合，因此该算法比较适合



中国知网 https://www.cnki.net

对文本进行处理。而对于很难将内容特征化的视频、音频等非文本资源时，此算法在运用中有一定局限性。

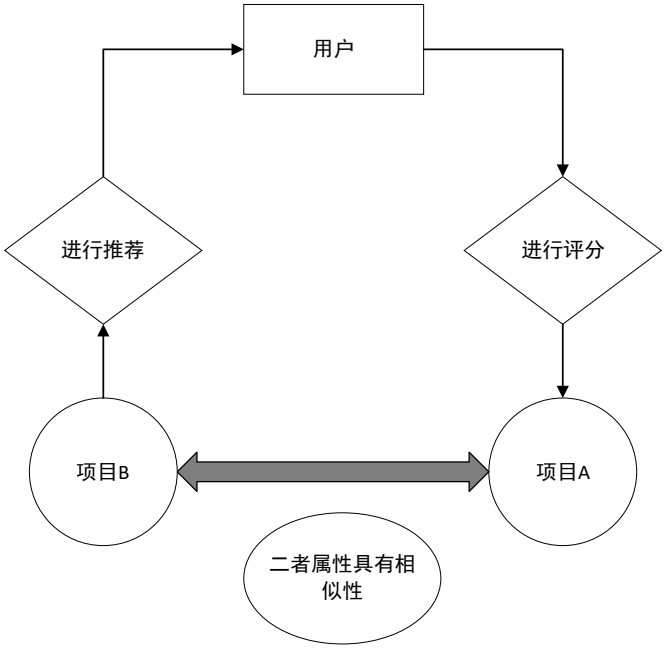


图 2.2 基于内容的推荐算法示意图

### 2.1.2 基于用户的协同过滤算法

通常来说，有些用户之间所偏爱的项目是有相似之处，这也是基于用户的协同过滤算法为目标用户产生推荐的依据，其核心思想是：使用相似度计算公式计算用户之间的相似度，进而找到推荐用户的近邻集合，并对项目预测评分，最终将评分靠前的项目推荐给目标用户。假设某位用户想在他的歌单添加一首新歌，他可能会询问和自己兴趣相似的朋友一些建议，比如他的好友最近在听《我记得》这首歌，那么这位用户喜欢《我记得》这首歌概率就会很大，将自己近邻好友的兴趣偏好推荐给你，其实这就是基于用户的协同过滤算法的所被运用到的实际场景。

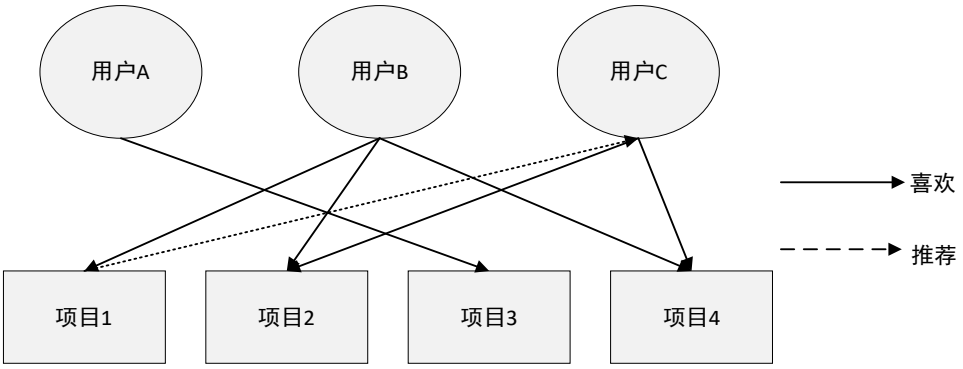


图 2.3 基于用户的推荐算法示意图



中国知网 https://www.cnki.net

如图 2.3 所示，用户喜欢某个项目用实线来表示，将项目推荐给用户的过程用虚线来表示。从图中可以看出项目 1、2、4 都受到用户 B 的喜欢，项目 2、4 受到用户 C 的喜欢，因此通过上述用户行为信息可以判断用户 B 和用户 C 的兴趣爱好比较相似，通常将项目 1 推荐至用户 C。

基于用户的协同过滤算法主要分为以下三个步骤：

1. 首先，收集用户和系统的交互行为数据，这些数据会以各式各样的形式存在，如对项目进行关注、点赞、或者评分这些行为等。建立一个 $m \times n$ 的矩阵 $S(m,n)$ 来表示用户对项目的行为信息，其中 m 表示用户的数量，n 表示项目的数量，$s_{ij}$ 代表用户 i 对项目 j 的评分值。$s_{ij}$ 评分值越高，说明用户对此项目的喜爱度越高，用户评分矩阵如式（2.1）所示：

$$S(m,n)=\begin{bmatrix} s_{11} & s_{12} & \cdots & s_{1n} \\ s_{21} & s_{22} & \cdots & s_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ s_{m1} & s_{m2} & \cdots & s_{mn} \end{bmatrix} \tag{2.1}$$

2. 通过上述的用户—项目评分矩阵中用户对项目的评分数据，再结合相似度计算方式，确定偏好相似的用户集，常用的用户相似度计算公式主要有余弦相似度、皮尔逊相似度以及修正的余弦相似度三种。

（1）余弦相似度

a，b 分别代表两个用户的评分向量，计算出的余弦值与用户之间的相似度成正比。如式（2.2）所示：

$$sim_{\cos}(\mathrm{a},\mathrm{b})=\frac{a \cdot b}{\|a\|\|b\|} \tag{2.2}$$

（2）皮尔逊相似度

在计算皮尔逊相似度之前，首先找到用户 a、b 共同评分项目的集合 $I_{ab}$，然后分别计算出用户 a、b 所有评分项目的平均分 $\overline{r_a}$，$\overline{r_b}$，最后通过式（2.3）计算用户之间的相似度，式中 $r_{ai}$，$r_{bi}$ 分别代表用户 a、b 对项目 i 的各自评分，此式取值范围为[-1,1]。

$$sim_{pes}(a,b)=\frac{\sum_{i\in I_{ab}}(r_{ai}-\overline{r}_a)(r_{bi}-\overline{r}_b)}{\sqrt{\sum_{i\in I_{ab}}(r_{ai}-\overline{r}_a)^2}\sqrt{\sum_{i\in I_{ab}}(r_{bi}-\overline{r}_b)^2}} \tag{2.3}$$

（3）修正余弦相似度

通过对皮尔逊相似度进行改进得到修正余弦相似度，二者的区别是分母中心化的方式不



中国知网 https://www.cnki.net

同，如（2.4）式所示。

$$sim_{a\cos}(a,b)=\frac{\sum_{i\in I_{ab}}(r_{ai}-\overline{r}_a)(r_{bi}-\overline{r}_b)}{\sqrt{\sum_{i\in I_a}(r_{ai}-\overline{r}_a)^2}\sqrt{\sum_{i\in I_b}(r_{bi}-\overline{r}_b)^2}} \tag{2.4}$$

式中 $r_{ai}$，$r_{bi}$ 分别代表用户 a、b 对项目 $i$ 的各自打分，$I_a$、$I_b$ 分别为两位用户各自评分项目的集合。

3. 根据用户之间的相似度大小地排序可以得出目标用户的最近邻用户，KNN 算法的主要原理是将测试数据集与训练数据集进行相似性比对，从而选出 Top-N 的用户，得到近邻集合，此算法为接下来预测项目的评分值提供基础，取评分较高的项目推荐给目标用户。其中预测评分值如式（2.5）所示。

$$pre_{a,i}=\overline{r_a}+\frac{\sum_{u\in U_a}sim(a,b)\left(r_{bi}-\overline{r_b}\right)}{\sum_{u\in U_a}sim(a,b)} \tag{2.5}$$

式中，目标用户 a 的近邻集合用 $U_a$ 来表示，$sim(a,b)$ 是用户之间的相似度，$\overline{r_a},\overline{r_b}$ 代表用户 a、b 分别对所有项目的平均打分，最终计算出预测评分值 $pre_{a,i}$。

### 2.1.3 基于项目的协同过滤算法

此算法与基于用户的协同过滤算法的核心原理相似，基于项目的协同过滤算法是通过计算项目之间的相似度，进而得到近邻集合[49]。此算法的推荐过程如图 2.4 所示。

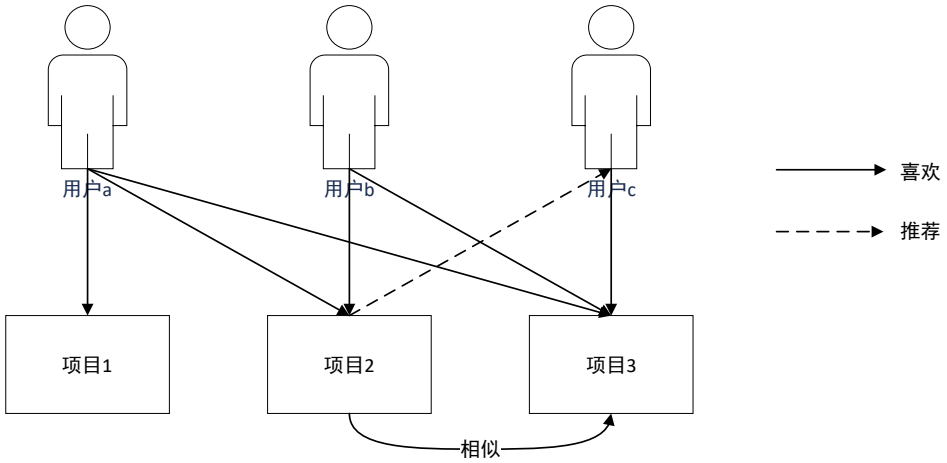


图 2.4　基于项目的协同过滤算法示意图

比如用户在课程推荐系统关注了通信原理这门课程，系统可能会为用户推荐计算机网络等相关类型的课程。这样的推荐方式就是通过基于项目的协同过滤推荐算法实现的，该算法



中国知网　https://www.cnki.net

的基本步骤与基于用户的协同过滤算法的步骤类似，只是在第二步的计算过程中，将计算用户之间的相似度替换为计算项目之间的相似度。但是仍然可以使用基于用户的协同过滤算法中相似性计算公式来得到近邻项目集合。

### 2.1.4 基于模型的协同过滤算法

推荐算法模型中输入的数据源（用户评分矩阵）中，有些项目是没有被用户进行评分的，此时可以根据已经收集的评分数据进行训练，来对未评分的项目进行预测评分，选择评分高的项目推荐给用户。为了更好地应对上述问题，可以通过使用机器学习的方法来建立模型，主流方法包括：关联算法[50]，分类算法[51]，聚类算法[52]，回归算法[53]，神经网络[54]，矩阵分解[55]等。

## 2.2 推荐系统的评价指标

通常评价一个推荐系统性能是有具体的评测标准[56]，一个性能较好的推荐系统主要有以下几点，第一，推荐的内容满足用户的需要；第二，将相似用户感兴趣的内容做到相互流通；第三，推荐系统平台可以收到来自用户高质量的评价。正是基于上述三个点来不断地优化推荐系统，并评测其性能。许多学者对推荐系统的性能非常重视，并根据评判标准的不同分为如下两类预测系统性能的指标。

1. 评分预测

现如今的推荐系统几乎都有对项目进行评分这一功能，后台收集评分信息作为模型训练的输入源，从而预测用户对项目的评分值，通常使用均方根误差[57](RMSE)和平均绝对误差[58](MAE)来评估评分预测的准确度，接下来对两种方法展开简单介绍。

平均绝对误差清晰地反应了预测值与真实值的误差情况，其值越小，推荐系统的性能也就越好；均方根误差采用拟合度量的方式来对推荐系统的性能进行评测，RMSE 与推荐系统的准确率成反比。 MAE 的计算公式如式（2.6）：

$$MAE = \frac{\sum_{a,i \in T} \left| r_{a,i} - q_{a,i} \right|}{\mathrm{n}} \tag{2.6}$$

同样地，RMSE 的计算公式如式（2.7）：

$$RMSE = \sqrt{\frac{1}{\mathrm{n}} \sum_{i=1}^{n} (r_{a,i} - q_{a,i})^2} \tag{2.7}$$

对于测试集$T$中的用户$a$和项目$i$，用户对项目的真实打分用$r_{a,i}$表示，$\mathrm{q}_{a,i}$为计算所得到



中国知网 https://www.cnki.net

的预测分数，$n$ 表示用户所评分项目的数量。

尽管上述两个计算公式中所使用的变量值是相同的，但是 RMSE 所得到结果稍大于 MAE。这种情况出现是由于 RMSE 计算特性所导致的，它是将误差值平方后相加再开方，这样会将误差值放大，而且当系统规定用户的评分值是整数时，预测结果取整会降低 MAE 的误差，此时采用 MAE 对系统进行评估的准确率高于 RMSE。因此本文主要采用 MAE 值作为算法性能的评测指标。

2. 推荐列表预测

推荐系统使用频率较高的推荐方式是 TOP-N 推荐，这种方式是系统将模型训练的结果前 N 项作为用户的推荐集合，使用准确率[59]（precision）来评估推荐结果的准确度[60]。

准确率的计算方式是：用户对推荐列表中喜欢的项目数与推荐列表项目总数的比值，也就是用户所感兴趣的项目被推荐出来的概率。其中准确率（precision）的计算公式如（2.8）式所示：

$$precision = \frac{\sum_{u} \left| R(u) \cap T(u) \right|}{\sum_{\mathrm{u}} \left| T(u) \right|} \tag{2.8}$$

式中，$R(\mathrm{u})$ 表示对用户 u 推荐项目的个数；$T(\mathrm{u})$ 表示测试集中用户 u 喜欢项目的集合。

## 2.3 原始数据预处理

本文选用泰迪杯教育平台的线上课程用户行为数据集，此数据集一方面可以作为大数据方向竞赛的数据源，另外一方面可以被科研人员用来对教育行业进行探索，本文从此在线平台的学生用户选课学习数据集展开研究。为了将课程资源精准地推荐给用户，首先需要对每个数据集表的内容进行了解，进而方便对数据进行预处理。

### 2.3.1 数据集示例

用户学习行为数据集一共包含四个数据集，分别是用户个人信息数据集（表 2.1）、课程资源信息数据集（表 2.2）、用户选课信息数据集（表 2.3）、用户课程评价信息数据集（表 2.4）。其中用户个人信息数据集记录着 11270 名用户的 10 万多条个人相关的具体信息，包含 10 个有具体含义的特征列，如用户序号、用户 ID、性别、学校、专业、关注课程数目等；课程资源信息数据集记录着 232 条课程相关信息包含了 8 个有具体含义的特征列，如课程序号、课程 ID、课程录入时间、课程名称、课程类型、讲师名、课程时长、被评价次数；用户选课信



中国知网 https://www.cnki.net

息数据集记录着用户 4 万多条的选课信息，以及对选择的课程是否进行评价；用户课程评价信息数据集记录着 45324 条用户对课程的评价信息。

表 2.1 用户个人信息数据集数据示例

| 用户序号 | 用户 ID | 用户名 | 用户密码 | 注册时间 | 登陆时间 | 性别 | 学校 | 学院 | 专业 | 偏爱课程类型 | 关注课程个数 |
|---|---|---|---|---|---|---|---|---|---|---|---|
| 1 | 用户 2115 | 李** | ****** | 2019/3/6 9:05 | NaN | 男 | 燕山大学 | 机械工程学院 | 机械设计 | 理科类 | 1 |
| 2 | 用户 9338 | 田** | ****** | 2020/2/27 0:37 | 2020/6/14 22:32 | 女 | 青岛工学院 | 管理学院 | 财务管理 | 经济学类 | 4 |

表 2.2 课程资源信息数据集数据示例

| 课程序号 | 课程 ID | 课程录入时间 | 课程名称 | 课程类型 | 讲师名 | 课程时长 | 被评价的次数 |
|---|---|---|---|---|---|---|---|
| 1 | 课程 205 | 2018/11/4 13:05 | 复变函数 | 理科类 | 王** | 10 小时 43 分钟 01 秒 | 4947 |
| 2 | 课程 2 | 2018/11/3 19:03 | 产业经济与产业分析 | 经济学类 | 张** | 11 小时 53 分钟 54 秒 | 1297 |

表 2.3 用户选课信息数据集数据示例

| 用户序号 | 用户 ID | 课程 ID | 课程名称 | 学习课程时长 | 是否对课程进行评价 |
|---|---|---|---|---|---|
| 1 | 用户 4232 | 课程 205 | 复变函数 | 3 小时 51 分钟 | 是 |
| 2 | 用户 6151 | 课程 62 | 计算机算法与程序设计 | 7 小时 09 分钟 15 秒 | 是 |

表 2.4 用户课程评价信息数据集数据示例

| 用户序号 | 用户 ID | 课程 ID | 课程名称 | 课程评分 |
|---|---|---|---|---|
| 1 | 用户 4232 | 课程 205 | 复变函数 | 3 |
| 2 | 用户 7758 | 课程 97 | 音乐鉴赏 | NaN |

### 2.3.2 数据预处理

未经过预处理的数据集中有大量在后期训练中使用不到的特征列，以及含有一些评分的缺失值，不方便后期对改进算法模型进行训练，因此需要对原始的数据集进行清洗，如果数据集中部分数据格式不能被算法模型使用，此时需对数据格式进行转换。经过上述步骤后的数据内容可能会比较离散，没有一定的逻辑性，可以通过数据集成的方式将数据集中的某些特征列进行合并得到最终的实验数据集，如图 2.5 所示的数据预处理流程图。



中国知网 https://www.cnki.net

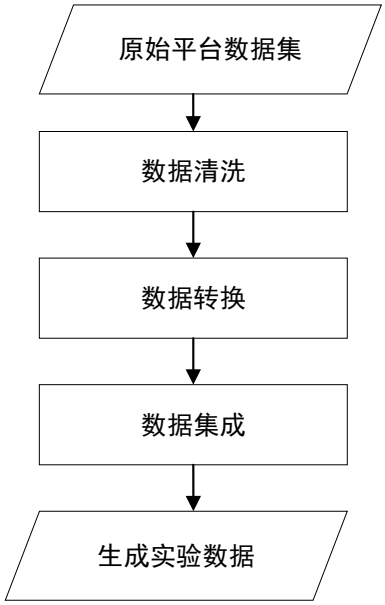


图 2.5　数据预处理流程图

1.　数据清洗

通常大多数数据集预处理的第一步是数据清洗，其中有如下几种情况：存在缺失值，无效特征列，重复数据等，使算法模型可以更高效地运用数据集，可以对数据集进行如下操作：

（1）无用特征列删除

某些数据集中，存在某一特征列为空值或者是重复值，这种类型的数据并不能作为有效信息，如用户的国家，时间差，登陆的时间等信息。因此本文将用户个人信息数据集中的注册时间、用户密码、用户名、登陆时间、关注课程个数；课程资源信息数据集中的课程录入时间、讲师名；以及用户选课数据集中的是否对课程进行评价这些特征列删除，方便后续进一步对数据集进行操作。

（2）缺失值的填充

用户课程评价信息数据集中有大量的评分数据存在缺失，常被使用的缺失值处理方法有：对缺失内容进行补全、删除某些缺失值的特征列、以及直接使用缺失值的数据集进行训练，后两种处理方法会造成信息损失，从而影响最终的实验结果。因此本文主要采用对数据缺失的内容补全，本节表 2.4 第二行中课程评分数据值为 NaN，代表用户未对此课程进行评分，于是对课程评分特征列的缺失值进行填 0 处理，如表 2.5 所示。

表 2.5 用户课程评价信息数据集填充后示例

| 用户序号 | 用户 ID | 课程 ID | 课程名称 | 课程评分 |
|---|---|---|---|---|
| 1 | 用户 4232 | 课程 205 | 复变函数 | 3 |
| 2 | 用户 7758 | 课程 97 | 音乐鉴赏 | 0 |



中国知网　https://www.cnki.net

2. 数据转换

数据规范化、离散化和特征编码是数据转换常见的一些操作，目的是将数据处理成算法模型可以理解的格式结构。本文主要对表 2.2、表 2.3 中特征列为课程时长、学习课程时长作统一规范。

如表 2.6、2.7 所示，对课程资源信息数据集、用户选课信息数据集的特征列进行截取，这些时间字段很难被算法模型所处理，因此将其修改成单位为分钟格式的数据，如表 2.8、2.9 所示，以便后续的处理。

表 2.6　课程资源信息数据集时间规范化前示例

| 课程序号 | 课程 ID | 课程名称 | 课程时长 |
|---|---|---|---|
| 1 | 课程 205 | 复变函数 | 10 小时 43 分钟 01 秒 |
| 2 | 课程 22 | 产业经济与产业分析 | 11 小时 53 分钟 54 秒 |

表 2.7　用户选课信息数据集时间规范化前示例

| 用户序号 | 用户 ID | 课程 ID | 课程名称 | 学习课程时长 |
|---|---|---|---|---|
| 1 | 用户 4232 | 课程 205 | 复变函数 | 3 小时 51 分钟 |
| 2 | 用户 6151 | 课程 62 | 计算机算法与程序设计 | 7 小时 09 分钟 15 秒 |

表 2.8　课程资源信息数据集时间规范化后示例

| 课程序号 | 课程 ID | 课程名称 | 课程时长 |
|---|---|---|---|
| 1 | 课程 205 | 复变函数 | 643.01 |
| 2 | 课程 22 | 产业经济与产业分析 | 713.9 |

表 2.9　用户选课信息数据集时间规范化后示例

| 用户序号 | 用户 ID | 课程 ID | 课程名称 | 学习课程时长 |
|---|---|---|---|---|
| 1 | 用户 4232 | 课程 205 | 复变函数 | 231 |
| 2 | 用户 6151 | 课程 62 | 计算机算法与程序设计 | 429.25 |

3. 数据集成

本文主要研究用户课程评分行为数据，而此数据集是由 4 个分散的数据集组成，因此需要对这 4 个数据集进行集成处理，4 个数据集之间的对应关系如图 2.6 所示。

对已经清洗过的用户个人信息数据集进行如下步骤的操作：

（1）利用用户个人信息数据集特征字段用户 ID 统计其在用户选课信息数据集的选课信



中国知网 https://www.cnki.net

息（课程 ID、课程名称、学习课程时长），并将用户 ID 特征列与统计的数据集进行左连接。

（2）用步骤（1）中数据集特征字段课程 ID 统计课程资源信息数据集中特征字段为课程时长的信息，并于步骤（1）的数据集进行左连接。

（3）利用用户个人信息数据集特征字段用户 ID 和用户选课信息数据集特征字段课程 ID 统计其在用户课程评价信息数据集的评分信息（课程评分），并将此数据集与步骤（2）的数据集进行左连接得到用户—课程评分信息数据集。

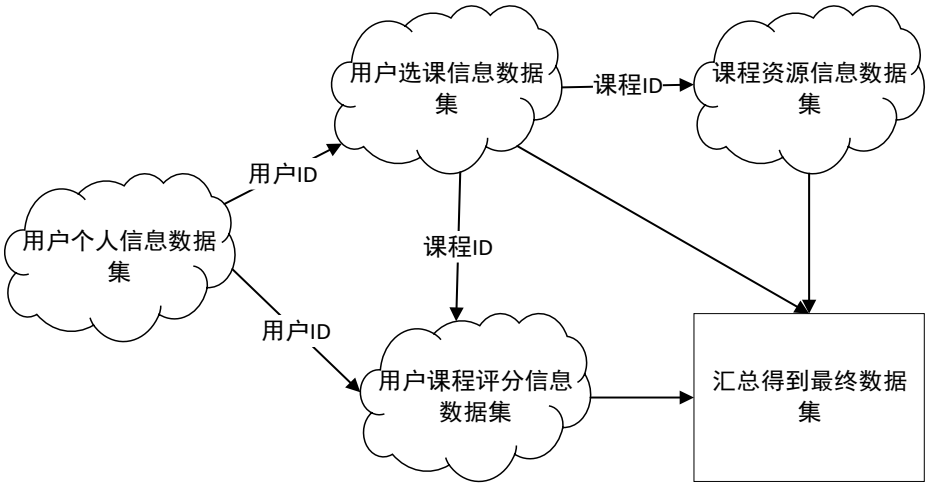


图 2.6　数据集成示意图

经过上述数据集成步骤后，最终得到维度为 45324×7 的用户—评分信息实验数据，如表 2.10 所示。

表 2.10 用户—评分信息实验数据集示例

| 用户序号 | 用户 ID | 课程 ID | 课程名称 | 学习课程时长 | 课程时长 | 课程评分 |
|---|---|---|---|---|---|---|
| 1 | 用户 4232 | 课程 205 | 复变函数 | 231.00 | 643.01 | 3 |
| 2 | 用户 6151 | 课程 62 | 计算机算法与程序设计 | 429.25 | 1745.00 | 3 |
| 3 | 用户 9148 | 课程 134 | 古代汉语 | 950.76 | 1960.85 | 2 |
| 4 | 用户 6095 | 课程 22 | 产业经济与产业分析 | 477.33 | 713.90 | 4 |
| 5 | 用户 1090 | 课程 176 | 信息系统分析与设计 | 174.00 | 786.75 | 3 |
| 6 | 用户 3784 | 课程 89 | 材料力学 | 568.80 | 756.31 | 5 |

经过数据清洗后得到维度为 11270×7 的用户个人信息实验数据集，如表 2.11 所示。

表 2.11 用户个人信息实验数据集示例

| 用户序号 | 用户 ID | 性别 | 学校 | 学院 | 专业 | 偏爱课程类型 |
|---|---|---|---|---|---|---|
| 1 | 用户 4232 | 男 | 广西大学 | 理学院 | 数学 | 计算机类 |



中国知网　https://www.cnki.net

| 用户序号 | 用户 ID | 性别 | 学校 | 学院 | 专业 | 偏爱课程类型 |
|---|---|---|---|---|---|---|
| 2 | 用户6151 | 男 | 安徽工程大学 | 信息与工程学院 | 电子信息工程 | 计算机类 |
| 3 | 用户9148 | 女 | 西安建筑科技大学 | 文学院 | 汉语言文学 | 文学类 |
| 4 | 用户6095 | 女 | 湖南大学 | 管理学院 | 经济学 | 经济学类 |
| 5 | 用户1090 | 男 | 中国石油大学（北京） | 人工智能学院 | 计算机科学与技术 | 物理类 |
| 6 | 用户3784 | 课程89 | 武汉理工大学 | 材料科学与工程学院 | 材料学 | 材料类 |

经过数据清洗和数据转换后得到维度为 232×6 的课程资源信息实验数据集，如表 2.12 所示。

表 2.12 课程资源信息实验数据集示例

| 课程序号 | 课程 ID | 课程名称 | 课程类型 | 课程时长 | 被评价的次数 |
|---|---|---|---|---|---|
| 1 | 课程 205 | 复变函数 | 理科类 | 643.01 | 4947 |
| 2 | 课程 62 | 计算机算法与程序设计 | 计算机类 | 1745 | 12467 |
| 3 | 课程 134 | 古代汉语 | 文学类 | 1960.85 | 3594 |
| 4 | 课程 22 | 产业经济与产业分析 | 经济学类 | 713.90 | 1297 |
| 5 | 课程 176 | 信息系统分析与设计 | 计算机类 | 786.75 | 12300 |
| 6 | 课程 89 | 材料力学 | 材料类 | 756.31 | 974 |

## 2.4 本章小结

本章首先对推荐算法的分类进行详细地介绍，并对具体步骤进行细致地描述，其次介绍了推荐系统比较常用的评价指标，最后将原始的数据集预处理为算法模型方便利用的数据集。



中国知网 https://www.cnki.net

# 第三章 基于用户特征权重置信度的协同过滤推荐算法

## 3.1 引言

我们所熟知的传统协同过滤算法仅仅只是重视用户之间的相似性，而没有挖掘用户之间的其他关系。但在实际的应用场景中，有诸多因素影响着推荐系统的性能，如用户之间的信任关系、特征信息等。近几年，涉及到用户信任关系的研究越来越多，由此可以看出其对推荐算法研究的重要性，然而如何对用户之间信任关系进行描述，是当今研究者所面对棘手的问题。在生活场景中的信任关系是随处可见的，如朋友、家人、亲戚之间相互推荐自己比较认可的服饰品牌、家用电器、护肤品等产品。因此将信任关系融入到协同过滤算法当中已是大势所趋。

随着线上选课体系的不断完善，参与的用户也随之增多，由于每位用户对课程的需求不同，他们并不是对所有课程进行评分，因此建立的用户—课程评分矩阵的稀疏性很大，就好比用户 A 只对一个感兴趣的课程进行评分，用户 B 评分的课程比较多，并且用户 B 所评分的课程恰好包括了用户 A 所评分的课程，这种情况在获得最近邻居集合的时候，并不能准确地反映用户的真实喜好。上述内容仅仅只是阐述用户与课程之间的关系，然而一个系统的信息量非常庞大并且信息之间的关系也极为复杂，如果仅仅是通过信息中的数字内容来探究推荐算法，会缺乏说服性，最终导致推荐的效果不是很理想。因此我们可以对用户评分数据深层的关系进行细致探索，以及将用户文本化的特征属性模型化，来进一步对协同过滤算法改进。为了更好地提高推荐的质量，提出了基于用户特征权重置信度的协同过滤算法（Collaborative filtering algorithm based on user feature weight reset reliability，CFUR）。

## 3.2 问题的提出

### 3.2.1 用户共同评分课程数量的差异

用户之间共同评分的项目的个数对用户在计算相似性时影响较大，特别是对于一些评分矩阵较为稀疏的情况，会影响最终的推荐效果。下表 3.1 展示了不同用户对他们关注课程的评分值，满分为 5 分，采用一档一分制，其中表内的 0 分表示的此用户未对该课程进行评分，在数据预处理的时候进行填充 0 分。



中国知网　https://www.cnki.net

表 3.1　用户—课程评分情况

| 用户 ID | 课程 212 | 课程 56 | 课程 178 | 课程 31 | 课程 22 |
|---|---|---|---|---|---|
| 用户 4287 | 1 | 2 | 2 | 1 | 3 |
| 用户 674 | 1 | 3 | 0 | 0 | 0 |
| 用户 3949 | 1 | 0 | 3 | 2 | 3 |

对于表 3.1，使用式（2.3）所示的皮尔逊相似度、式（2.2）所示的余弦相似度、式（2.4）所示的修正余弦相似度分别对用户 4287 和用户 674、用户 3949 之间的相似度进行计算，结果如表 2 所示。

表 3.2　不同相似公式计算结果

| 用户 ID | 皮尔逊相似度 | 余弦相似度 | 修正余弦相似度 |
|---|---|---|---|
| 用户 4287 和用户 674 | 1.000 | 0.632 | 0.423 |
| 用户 4287 和用户 3949 | 0.818 | 0.894 | 0.811 |

由表 3.2 可知，用户 4287 和用户 674 之间的相似度通过皮尔逊相似度计算所得到的值为 1，表中也可以看出用户 4287 与用户 674 共同评分的课程数有 2 个，用户 4287 与 3949 共同评分的课程数有 4 个，通过相似度计算公式得到的相似值却只有 0.818，并没有前者之间的相似度高，这明显不符合正常逻辑。然而，通过其他两种相似度计算公式所得到的相似值是符合预期情况的，这是因为其在计算过程中所采用的是用户共同评分课程的平均值，缓解了因评分项目的差异性所带来的误差。但上述三种相似度计算公式都忽略用户之间的置信度[61]这一重要因素，为了让推荐的精确度更高，本文引入用户间置信度这一概念来弥补这一缺陷。

### 3.2.2 用户特征对推荐算法的影响

以下是用户特征可能对推荐算法产生影响的一些因素：

1. 用户的历史行为：用户过去的浏览、搜索和购买行为可以提供重要的信息，帮助推荐算法了解用户的兴趣和偏好，并推荐与之相关的产品。
2. 用户的兴趣爱好：用户的兴趣爱好和喜好也是影响推荐算法的重要因素。例如，喜欢旅游的用户可能会被推荐旅游攻略、旅游产品等。
3. 用户的个人属性信息：用户本身客观存在的信息，如归属地信息、性别、年龄等，也可能影响推荐算法。例如，根据地理位置信息，推荐算法可以向用户推荐当地的商家或景点。
4. 用户的社交网络：用户的社交网络也可以影响推荐算法。例如，根据用户的好友列表，



中国知网　https://www.cnki.net

推荐算法可以向用户推荐好友喜欢的内容。

5. 用户的设备信息：用户使用的设备类型、操作系统、浏览器等也可能影响推荐算法。例如，在移动设备上，推荐算法可能更倾向于推荐易于阅读和操作的内容。

总之，用户特征对推荐算法的影响是多方面的，因此在开发和优化推荐算法时，应考虑到用户的不同特征，进一步实现优质化的推荐服务。

## 3.3 算法改进

### 3.3.1 用户特征权重的建立

我们所了解到的协同过滤算法并没有充分考虑到用户属性特征这一重要因素，导致模型得到的推荐列表并未令用户满意，尤其是对新用户来说，出现这样情况的原因是他们在进入系统时没有相应的评分行为。因此不同的用户在首次登陆会填写自己相关的一些信息，如专业领域，学校，年级等等一些用户信息，我们称它为用户特征。本文主要选取用户的性别、学校、学院、专业、偏好课程类型、学习课程的时长作为主要的用户特征，由于学习课程的时长该特征为数字信息，其他特征是文本信息，因此该权重主要分为两个部分来计算。

1. 用户间学习行为特征权重

欧几里得度量[62]可以通过距离大小来衡量用户之间的相似度，其实质是距离值与用户之间的相似度成反比。因此根据此算法来计算用户间学习行为权重，如（3.1）式所示。

$$wei_{\text{time}} = sim_{time}(a,b) = \frac{1}{1+d(a,b)} = \frac{1}{1+\sqrt{(\frac{L_time_a}{S_time_a} - \frac{L_time_b}{S_time_b})^2}} \tag{3.1}$$

其中 $\frac{L_time_a}{S_time_a}$、$\frac{L_time_b}{S_time_b}$ 分别代表用户 a 和用户 b 学习课程的时间占课程总时间的比重。$wei_{\text{time}}$ 代表用户间学习行为特征权重。

2. 用户间其他特征权重

除了用户学习某课程时长这一学习行为特征外，还有一些用户特征在注册时填写相关的文本信息，假设用户 a 的特征属性集合 X 为 $\{x_1, x_2, x_3 \cdots, x_n\}$，用户 b 的特征属性集合 Y 为 $\{y_1, y_2, y_3 \cdots, y_n\}$，通过式（3.3）来计算用户之间其它特征权重。

$$\mathrm{F}(a,b) = [X \cap Y] \tag{3.2}$$



中国知网 https://www.cnki.net

$$wei_{other} = \frac{F(a,b)}{sum_{other}} \tag{3.3}$$

式中，$sum_{other}$为用户 a、b 其他特征的总数；F(a,b)为用户间相同特征的数量。因此最终的用户特征权重$wei_{\text{user}}$计算公式如 3.4 式所示：

$$wei_{\text{user}} = \frac{wei_{time} + wei_{other}}{2} \tag{3.4}$$

本文按用户各类特征所占比例相同计算。

### 3.3.2 基于用户特征权重的置信度因子

如今，我们所处在一个复杂的社会大环境中，身边也会出现形形色色的人，我们会对一部分人表现出很强的信任度，这是由于不同程度的社交关系会导致人们之间的信任度也不相同。假设用户的朋友为他提供解决困难的相关思路或者想法，基于与朋友之间的信任关系，这位用户大概率会采纳他朋友的建议，而对于一个没有建立信任关系的陌生人，用户听取这位陌生朋友意见的概率会非常小，因此如果将用户之间的置信关系应用到推荐算法当中，可以使推荐系统的可靠性得到保障。

现在很多学者在对推荐算法进行改进时已经考虑到用户之间信任关系这一重要因素，通过对一些改进算法的文章进行研究，发现大多数学者理解的信任关系的定义是：对于课程资源推荐系统来讲，此系统中存在用户 a 和用户 b，假设用户 a 所关注的课程大多数与用户 b 所关注的课程相同，那么他们之间的置信度会比较高，相反，两名用户关注的课程不一样或者关注相同的课程数目比较少，那么他们之间的置信度会很低。

从用户的评分项目中我们可以看出，如果此项目拥有两个用户的评价记录，那么从一定程度上反映了用户之间存在着相应的信任关系。本文首先统计两个用户之间共同评分项目的个数，其次统计两个用户各自评分项目个数的总和，最终用户之间的置信度通过上述统计个数的比值来衡量。在置信度模型构建中，Jaccard 函数可以描述集合间相似性这一特性，因此将其选取作为置信度的度量函数，如式（3.5）所示。

$$s(a,b) = \frac{|I(a) \cap I(b)|}{|I(a) \cup I(b)|} \tag{3.5}$$

式中，$I(a)$、$I(b)$代表用户$a$、$b$各自评分项目的集合；用户共同评分的项目和评分项目的总和通过两个集合的交集和并集来表示。如图 3.1 所示，三幅框图展现了用户之间不同



中国知网 https://www.cnki.net

情况下的置信度值。

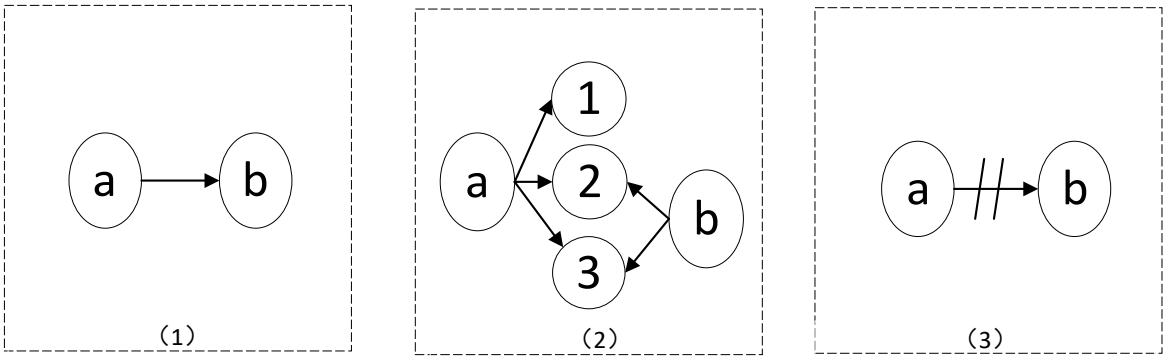


图 3.1　用户之间的信任关系

如图 3.1 所示，第一个子图对应的置信度 s(a,b) = 1，这种情况我们称用户 a 和用户 b 为显示信任关系；第二子图是在实际的算法模型经常遇到的一种情况，用户 a 与用户 b 有着共同感兴趣的项目，此时 s(a,b) =2/3；第三个子图表明用户 a 与用户 b 之间没有共同感兴趣的项目，所以他们之间不存在如公式（3.5）所描述的信任关系，因此对应的置信度 s(a,b) = 0。

上述的内容仅仅只是围绕着用户之间共同评分的项目展开讨论的，并没有深入考虑用户共同评分项目的分值是否对推荐结果有影响。如果一个用户对某个项目评分值为 5 分，另外一个用户对相同项目的评分值为 1 分，两个用户对同一项目评分值差距非常大，按照式（3.5）来理解，此项目会被认为用户共同评分项目交集的一部分，然而这样刻画出用户之间的置信度就失去了意义，因此引入评估因子 $\varepsilon$ 来对用户之间共同评分项目集合进行约束，生成新的集合 RT（a,b），如式（3.6）所示。

$$RT(a,b)=\begin{cases}1, & \left|S_{a,b}-S_{b,a}\right|\le\varepsilon\\ 0, & \left|S_{a,b}-S_{b,a}\right|>\varepsilon\end{cases} \tag{3.6}$$

若用户 a 和用户 b 对课程的评分差值不大于 ε，就说明该项目属于 RT 集合，反之，就说明该项目不属于 RT 集合，ε 具体取值需要通过实验调整参数来确定，在用户交互过程中，对初始置信度进行调整，由此得到如式（3.7）所示的置信度。

$$sim_{rt}(a,b)=\frac{\left|RT(a,b)\right|}{\left|Total(a,b)\right|} \tag{3.7}$$

其中 RT(a,b)代表经过式（3.6）筛选后更能代表用户 a、b 相似性的项目集合，Total(a,b)代表用户 a、b 各自评分项目的总和，最终融入用户特征权重得到基于用户特征权重的置信度因子 FT(a,b)如式(3.8)所示。

$$\mathrm{FT(a,b)}=wei_{\mathrm{user}}\times sim_{rt}(a,b) \tag{3.8}$$



中国知网　https://www.cnki.net

### 3.3.3 基于用户特征权重置信度的协同过滤推荐算法

综合上述讨论，我们将上述置信度计算模型融合到修正余弦相似度（式 2.4）模型中，得到改进后的相似度计算模型—基于用户特征权重置信度的协同过滤推荐算法（CFUR），具体如式（3.9）所示。

$$sim_{i1}(a,b)=\frac{\sum_{i\in I_{ab}}(r_{ai}-\overline{r}_a)(r_{bi}-\overline{r}_b)FT(a,b)}{\sqrt{\sum_{i\in I_a}(r_{ai}-\overline{r}_a)^2}\sqrt{\sum_{i\in I_b}(r_{bi}-\overline{r}_b)^2}} \tag{3.9}$$

其中，FT(a,b) 表示基于用户特征权重的置信度因子，其计算表达式如（3.8）所示，$sim_{i1}(a,b)$ 表示用户之间的相似度，由于最终需要通过预测评分来为目标用户生成推荐，因此需要将预测评分式（2.5）中 $sim(a,b)$ 修改为 $sim_{i1}(a,b)$，如式（3.10）所示，式中变量符号意义与式（2.5）中变量符号的意义相同，通过此式来预测用户对项目的打分情况。

$$pre_{a1,i}=\overline{r_a}+\frac{\sum_{u\in U_a}sim_{i1}(a,b)\left(r_{bi}-\overline{r_b}\right)}{\sum_{u\in U_a}sim_{i1}(a,b)} \tag{3.10}$$

### 3.3.4 算法流程

本节设计的基于改进用户特征权重置信度的协同过滤推荐算法具体步骤如下，其算法流程如图 3.2 所示。

输入：用户—项目评分信息、用户特征信息、评估因子 ε 、目标用户 u 、近邻个数 k 以及推荐个数 N。

1. 构建用户—项目评分矩阵 R；
2. 根据式（3.4）计算用户特征权重；
3. 依据评估因子 ε 筛选得到 RT 集合（式 3.6）；
4. 根据式（3.8）计算基于用户特征权重的置信度因子；
5. 将基于用户特征权重的置信度因子引入至修正余弦相似度计算中；
6. 采用式（3.9）中相似度计算方法得到用户之间的相似度；
7. 将计算得到相似度值从大到小排列取前 k 个用户作为目标用户的近邻集合；
8. 利用式（3.10）可以预测目标用户 u 对项目集合中的项目评分；
9. 在已经得到预测评分的结果中找出 Top-N 评分课程，生成推荐列表。



中国知网 https://www.cnki.net

输出：目标用户 u 的推荐列表。

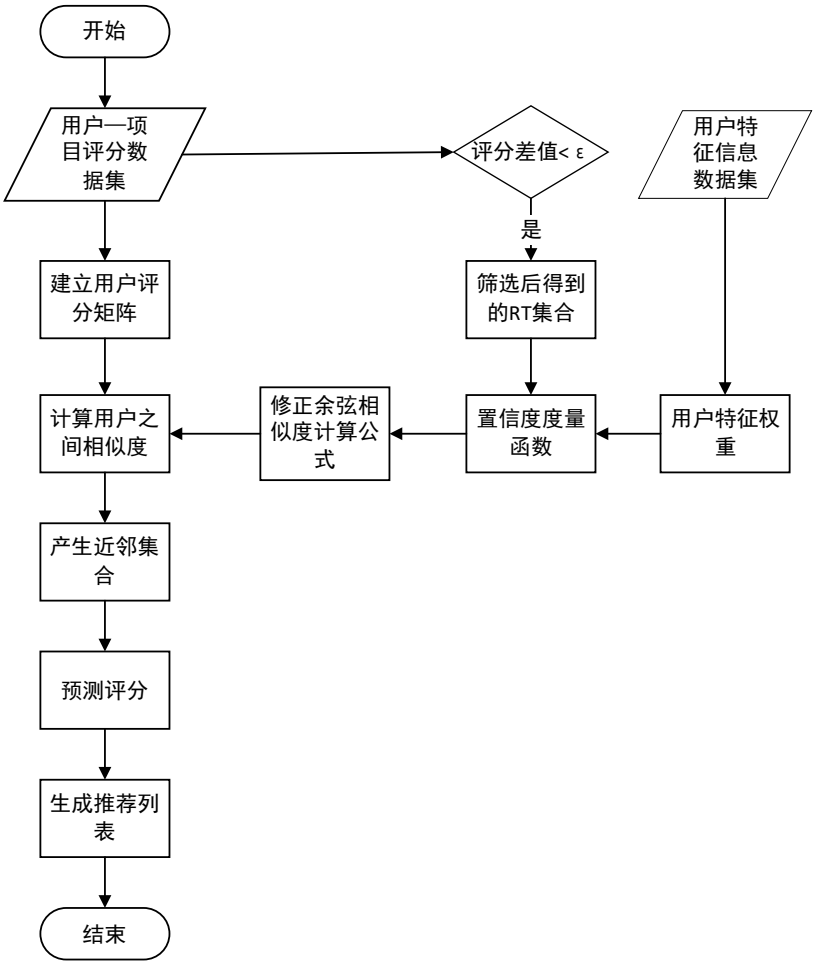


图 3.2　基于用户特征权重置信度的协同过滤推荐算法流程图

## 3.4 实验结果与分析

### 3.4.1 实验环境

此次实验的程序设计主要是使用 python 语言，并基于 windows 平台对环境进行搭建，在相应的开发工具上进行代码开发和测试。具体的实验环境配置，包括以下两个部分：

硬件环境配置：intel core i7 处理器，8G 内存，1T 硬盘。

软件环境配置：python3.8 开发环境，pyCharm 开发工具，Windows10 的 64 位操作系统。

### 3.4.2 实验数据集

本章所采用的实验数据集在本文 2.3 节已进行预处理，此次实验用到如下两个数据集。

1. 用户—课程评分信息实验数据集



中国知网　https://www.cnki.net

此数据集主要记录了 45324 条用户学习课程的基本信息，其中包括用户有过评分记录的课程名称、学习课程的时长、课程的总时长以及用户对课程的评分情况。对实验数据集的 80%作为训练样本，20%的数据集作为测试样本进行实验验证。

2. 用户个人信息实验数据集

此数据集主要记录了 11270 条用户的个人特征信息，如用户 ID、性别、学校、学院、专业、偏爱课程类型。

### 3.4.3 实验评价指标

本文在 2.2 节中对推荐算法的性能评测指标进行了介绍，并对指标的优劣势进行了说明，因此本章实验主要使用平均绝对值误差和准确率这两个指标来对 CFUR 算法进行评估。

### 3.4.4 实验结果和分析

为了验证 CFUR 算法的推荐效果，设计如下两组实验，并采用同一个训练集和测试集。

实验一：确定评估因子 ε

为了探究式（3.6）中 ε 的取值不同对推荐性能的影响情况，选取 ε =1、2、3，邻居数目为区间[5，50]，逐次递增的步长为 5，观察 ε 不同取值时对 MAE 的影响情况，从而为改进后的相似度计算公式选取合适的阈值。实验结果如表 3.3 和图 3.3 所示

表 3.3　不同 $\varepsilon$ 值对算法的性能影响实验结果

| 邻居数目 | ε =1 | ε =2 | ε =3 |
|---|---|---|---|
| 5 | 0.8294 | 0.8212 | 0.8269 |
| 10 | 0.8172 | 0.8045 | 0.8136 |
| 15 | 0.8097 | 0.7963 | 0.8087 |
| 20 | 0.8053 | 0.7895 | 0.8066 |
| 25 | 0.8034 | 0.7878 | 0.8017 |
| 30 | 0.8004 | 0.7854 | 0.7988 |
| 35 | 0.8011 | 0.7846 | 0.7975 |
| 40 | 0.8022 | 0.7858 | 0.7981 |
| 45 | 0.8027 | 0.7873 | 0.7992 |
| 50 | 0.8039 | 0.7891 | 0.8014 |

由图 3.3 中可知，当评估因子 ε =2 时，无论在任何近邻数目下，其相较于其他两个评估因子对应的 MAE 值低，实验结果也验证了当 RT(a,b)集合中用户间共同评分项目的评分差值不超过两分时，算法的性能会更高，因此选取评估因子 ε =2 为实验二 CFUR 算法性能的评估做准备。



中国知网　https://www.cnki.net

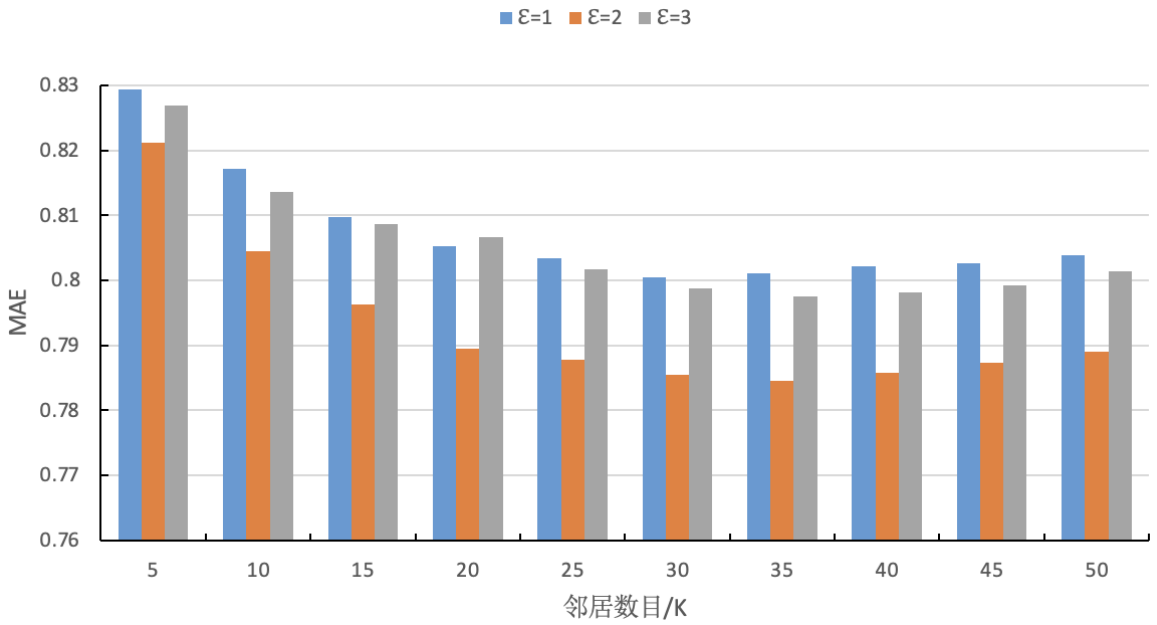


图 3.3　不同 $\varepsilon$ 值对算法的性能影响实验结果

实验二：CFUR 算法有效性的验证

为了证明本章改进推荐算法的有效性，本次实验主要选取本章改进算法的原型算法、基于信任模型进行改进的推荐算法以及对项目具有筛选属性的推荐算法进行对比，因此选取基于用户的协同过滤推荐算法（修正余弦相似度计算公式）、文献[33]提出的基于隐含信任关系的概率张量分解推荐算法以及文献[34]研究了融合相似度和预筛选模式的协同过滤算法，并分别记为 ACOS、PTIR、CFSP，通过实验来评估四种算法的性能，并对其性能指标进行对比分析。本次实验，通过控制近邻用户（K 值）在 5-50 这个范围区间内进行步长增加为 5 的变化，选用评估指标为 MAE，观察研究上述四种算法在此指标下的变化趋势，仿真实验结果如表 3.4 和图 3.4 所示。

表 3.4　验证 CFUR 算法有效性—MAE 值对比实验结果

| 邻居数目 | ACOS | PTIR | CFSP | CFUR |
|---|---|---|---|---|
| 5 | 0.8593 | 0.8442 | 0.8374 | 0.8212 |
| 10 | 0.8456 | 0.8288 | 0.8211 | 0.8045 |
| 15 | 0.8411 | 0.8234 | 0.8137 | 0.7963 |
| 20 | 0.8378 | 0.8201 | 0.8124 | 0.7895 |
| 25 | 0.8325 | 0.8175 | 0.8088 | 0.7878 |
| 30 | 0.8317 | 0.8154 | 0.8076 | 0.7854 |
| 35 | 0.8332 | 0.8169 | 0.8064 | 0.7846 |
| 40 | 0.8329 | 0.8147 | 0.8089 | 0.7858 |
| 45 | 0.8376 | 0.8112 | 0.8117 | 0.7873 |
| 50 | 0.8365 | 0.8157 | 0.8092 | 0.7891 |

根据上述实验结果可以看出，相较于其他几种改进的算法，传统的协同过滤算法的 MAE



中国知网　https://www.cnki.net

值相对较高，说明了改进后算法的推荐质量较传统的算法都得到了提升。随着 k 值不断增大，四种算法的 MAE 值变化的整个趋势是先迅速下降后逐渐趋于平稳，对于 CFUR 算法而言，尽管近邻数目在 5 至 20 这个区间内下降速度最快，但是其 MAE 值却没有取到最小，反而当近邻数达到 35 个时，MAE 值最小，说明了本文改进算法模型可以获得局部最优解，算法的性能最好。当用户的近邻数增加至 45 个时，据图观察到 PTIR 与 CFSP 算法的 MAE 值非常接近，PTIR 算法的 MAE 值仅仅只比 CFSP 低了 0.0005，纵观整幅折线图，K 无论取何值，本文 CFUR 算法的 MAE 值相较于 ACOS、PTIR、CFSP 算法的 MAE 值都低，从而证明了本章改进算法的有效性。

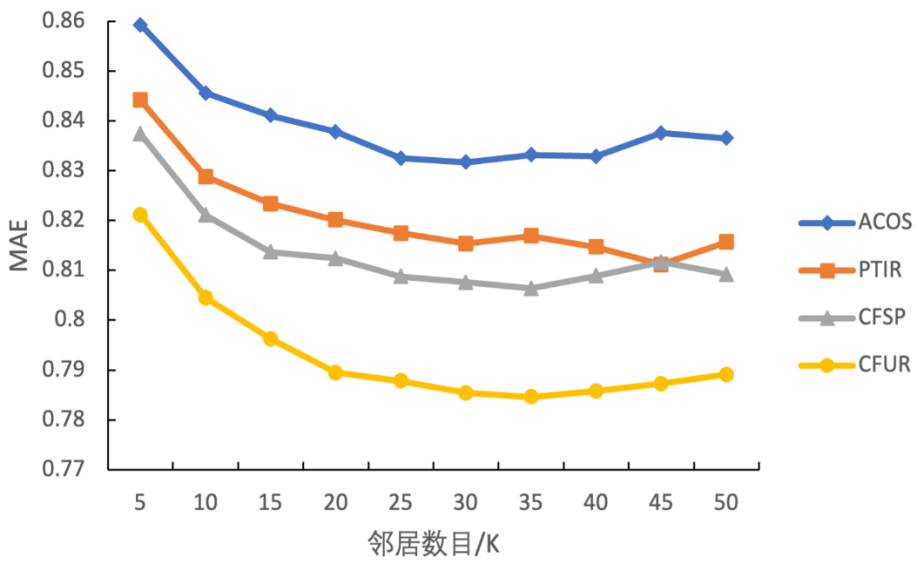


图 3.4　验证 CFUR 算法有效性—MAE 值对比实验结果

为了从不同的性能评测角度出发，采用准确率此性能指标来验证 CFUR 算法的推荐效果较其他三种算法是否有提升，实验结果如表 3.5，图 3.5 所示。

表 3.5　验证 CFUR 算法有效性—准确率对比实验结果

| 邻居数目 | ACOS | PTIR | CFSP | CFUR |
|---|---|---|---|---|
| 5 | 0.0735 | 0.0962 | 0.1043 | 0.1255 |
| 10 | 0.0947 | 0.1147 | 0.1249 | 0.1396 |
| 15 | 0.1014 | 0.1251 | 0.1375 | 0.1486 |
| 20 | 0.1170 | 0.1292 | 0.1429 | 0.1553 |
| 25 | 0.1219 | 0.1320 | 0.1383 | 0.1602 |
| 30 | 0.1243 | 0.1374 | 0.1459 | 0.1629 |
| 35 | 0.1273 | 0.1311 | 0.1482 | 0.1653 |
| 40 | 0.1258 | 0.1355 | 0.1341 | 0.1643 |
| 45 | 0.1195 | 0.1410 | 0.1467 | 0.1599 |
| 50 | 0.1231 | 0.1403 | 0.1424 | 0.1608 |

根据图 3.5 所示，随着邻居用户个数的增加，四种算法的准确率在初始阶段都先逐渐增加，后在一定区间内来回振荡，并趋于平稳。并且当用户数为 35 时，改进后算法的准确率最



中国知网　https://www.cnki.net

高，达到 0.1653，比传统的协同过滤算法增加了 29.85%，说明此时推荐的效果最优。同时也验证了上述实验的准确性。由结果也能看出 CFUR 算法的准确率曲线始终在传统的协同过滤算法以及 PTIR 算法、CFSP 算法的准确率曲线之上，这表明 CFUR 算法在为目标用户生成推荐时，推荐的项目更符合用户的偏好。

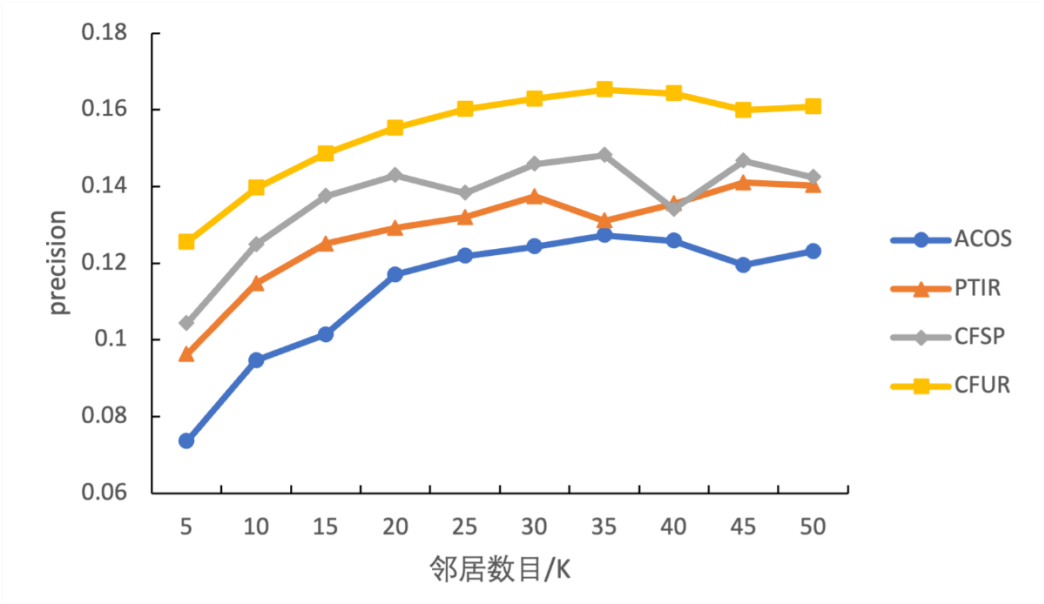


图 3.5　验证 CFUR 算法有效性—准确率对比实验结果

## 3.5 本章小结

本章针对协同过滤算法所存在的不足之处，提出基于用户特征权重置信度的协同过滤推荐算法，并对此算法公式的推导和流程进行详细描述。最终通过实验证明本章所改进算法相比于传统的协同过滤算法和其他改进算法的 MAE 值有所下降，并且改进后算法的准确率也有所提升。



中国知网　https://www.cnki.net

# 第四章 基于改进算法加权的混合推荐算法

## 4.1 引言

众所周知，国内外许多与推荐算法相关的研究者在如何更好地刻画用户之间的相似度这个问题上绞尽脑汁，然而度量值的精确度始终不够高。此难题一直让优秀的学者们争先恐后去探索，其中用户的评分行为经常作为一些学者的重点研究内容，他们忽略了其他因素对用户之间相似度的影响。传统的相似度计算认为每个项目所占的比重都是相同的，然而从大量的实验数据可以观察到，每个项目所被用户评价的次数是不同的，热门的项目会受到很多用户的关注，因此受到用户评价的次数就会很多，通常一个项目的热门程度与用户对其感兴趣的程度成反比，就好比某些热门产品我们每个人都需要用到，但它却不足以体现用户的兴趣爱好，相反的是许多冷门的项目却能够更好地反映用户的兴趣偏好，于是本章在计算用户之间的相似度时对热度较高的项目进行修正，将热门度修正因子融入到相似度计算公式中来克服这个问题，提出了基于热门度修正因子的协同过滤推荐算法。

上一章提到了基于用户特征权重的置信度课程推荐模型来缓解算法稀疏性的问题，本章将基于热门度修正因子的协同过滤推荐算法与其融合，得到基于改进算法加权的混合推荐算法（Hybrid recommendation algorithm based on improved algorithm weighting，HRAW），从而更好克服了传统推荐算法存在的一些问题。

## 4.2 算法改进

### 4.2.1 项目的热门程度

在一定个数项目集合 I 和用户集合 U 中，对某项目进行过评分的用户数与项目集合 I 中所有项目被用户评分次数的比值即为该项目的热门度，如式(4.1) 所示。

$$HT_i = \frac{N(i)}{U_{all}} \tag{4.1}$$

其中，$N(\mathrm{i})$ 代表对项目 i 进行评分的用户个数，$U_{all}$ 表示所有进行项目评分的总用户数，$HT_{\mathrm{i}}$ 表示项目 i 的项目热门度,其取值范围在[0,1]之间。$HT_{\mathrm{i}}$ 的值越大，表明此项目越热门。



中国知网 https://www.cnki.net

### 4.2.2 热门度修正因子

传统的协同过滤算法过度依赖用户共同有过评分记录项目的评分值，而没有重视此项目热门度的大小，造成最终的推荐结果精确度较低，这是由于在计算用户之间的相似度时没有考虑到项目热门度这一重要因素。以高校学生选择课程为例。例如，两名学生都选择过近代史这门课程，这并不能说明用户之间所感兴趣的课程都是相似的，这是因为近代史这门课程是必修课，大多数学生必须选择这门课程来完成必修的学分，并不能认为用户之间的相似度比较高。如果两名学生都选择了音乐鉴赏这门课程，那么可以认为这两名学生感兴趣的内容是相似的，这是因为只有对音乐感兴趣的学生才会选择这门课程。所以在计算用户之间的相似度时必须考虑冷门项目对其影响，一些用户对热门项目做出反馈这种行为并不能充分体现用户之间的区别，如果想进一步挖掘用户的喜爱偏好，可以关注用户对小众项目的反馈行为。因此提出了热门度修正因子这一概念，此公式不是对所有的项目进行修正，而是通过相应的热门阈值来判断是否对此项目进行修正，其计算公式如式( 4.2) 所示。

$$\mathrm{p}(i)=\begin{cases}1, & \mathrm{HT}_i \le TV \\ \dfrac{1}{\ln(1+N(i))}, & \mathrm{HT}_i > TV\end{cases} \tag{4.2}$$

公式中，$p(i)$表示项目 i 的热门度修正因子，TV 为热门阈值，若$HT_{\mathrm{i}} \le TV$，则认为项目 i 为非热门项目，将其对应的项目热门度修正因子置为 1，若$HT_{\mathrm{i}} > TV$，则认为项目 i 为热门项目，将其对应的项目热门度修正因子置为$\dfrac{1}{\ln(1+N(i))}$，通过此式可以分析出当$N(\mathrm{i})$值越大时，相应的$p(i)$会越小，其中$p(i)\in$（0，1），从而对热门度相对较高的项目起了抑制效果。

### 4.2.3 基于热门度修正因子的协同过滤推荐算法

基于皮尔逊相似度（式 2.3）计算公式的基础上，引入公式(4.2)中的热门度修正因子，改进后的公式如（4.3）式所示。

$$sim_{i2}(a,b)=\frac{\sum_{i\in I_{ab}} \mathrm{p}(i)(r_{ai}-\bar{r}_a)(r_{bi}-\bar{r}_b)}{\sqrt{\sum_{i\in I_{ab}}(r_{ai}-\bar{r}_a)^2}\sqrt{\sum_{i\in I_{ab}}(r_{bi}-\bar{r}_b)^2}} \tag{4.3}$$

式中$p(i)$是项目$i$的热门度修正因子，公式融入该因子后所得到的用户之间的相似度值更贴近实际情况，从而弱化了推荐结果不够精确的问题，由于最终需要通过预测评分来为目



中国知网 https://www.cnki.net

标用户生成推荐，因此需要将预测评分式（2.5）中 $sim(a,b)$ 修改为 $sim_{i2}(a,b)$，如式（4.4）所示，式中变量符号意义与式（2.5）中变量符号的意义相同，通过此式来预测用户对项目的打分情况。

$$pre_{a2,i}=\overline{r_a}+\frac{\sum_{u\in U_a} sim_{i2}\left(a,b\right)\left(r_{bi}-\overline{r_b}\right)}{\sum_{u\in U_a} sim_{i2}\left(a,b\right)} \tag{4.4}$$

### 4.2.4 基于改进算法加权的混合推荐算法

前文中已分别针对传统的协同过滤算法中置信度、项目热度较高的问题进行了相应的改进，如果想要同时克服上述问题，可以考虑将改进算法通过混合加权的方式融合，因此本文基于式（3.9）、式（4.3）融入权重因子 w 得到最终的相似度计算公式 $Tsim(\mathrm{a,b})$，其表达式如式(4.5)所示。

$$\mathrm{Tsim}(a,b)=wsim_{i1}(a,b)+(1-w)sim_{i2}(a,b) \tag{4.5}$$

其中，$w\in\left[0,1\right]$ 代表着融合两种相似度计算的权重，$Tsim(\mathrm{a,b})$ 代表最终用户相似度计算公式，通过该式求出的值越大，说明两位用户之间的相似性也越高，喜好也越接近，最终的推荐结果也更符合用户的兴趣。

基于式（4.5）得到用户之间相似度大小，进而筛选出近邻用户，使用如式（4.6）评分预测公式对项目进行预测评分，并对分数进行排序，取分数较高的项目为用户生成推荐列表。

$$pre_{a\mathrm{T},i}=\overline{r_a}+\frac{\sum_{u\in U_a} Tsim\left(a,b\right)\left(r_{bi}-\overline{r_b}\right)}{\sum_{u\in U_a} Tsim\left(a,b\right)} \tag{4.6}$$

### 4.2.5 算法流程

本节设计的基于改进算法加权的混合推荐算法实现过程如下，其算法流程如图 4.1 所示。

输入：用户—项目评分信息、项目资源信息、用户特征信息、评估因子 ε 、热门阈值 TV、目标用户 u 、近邻个数 k 以及推荐个数 N，

1. 建立用户—项目评分矩阵 R；
2. 与 3.3.4 节步骤 2-4 相同；
3. 根据式(4.1)计算项目的热门度，依据热门阈值 TV 判断此项目是否需要修正，如式(4.2)；



中国知网 https://www.cnki.net

4. 引入基于用户特征权重的置信度因子和热门度修正因子到用户相似度计算中，如式（3.9）、（4.3）所示；
5. 采用公式（4.5）通过加权的方法得到最终的用户间相似度计算公式；
6. 将计算得到相似度值从大到小排列取前 k 个用户作为目标用户的近邻集合；
7. 利用公式（4.6）可以预测目标用户 u 对课程集合中的项目评分；
8. 在已经得到预测评分的结果中找出 Top-N 评分项目，生成推荐列表。

输出：目标用户 u 的推荐列表。

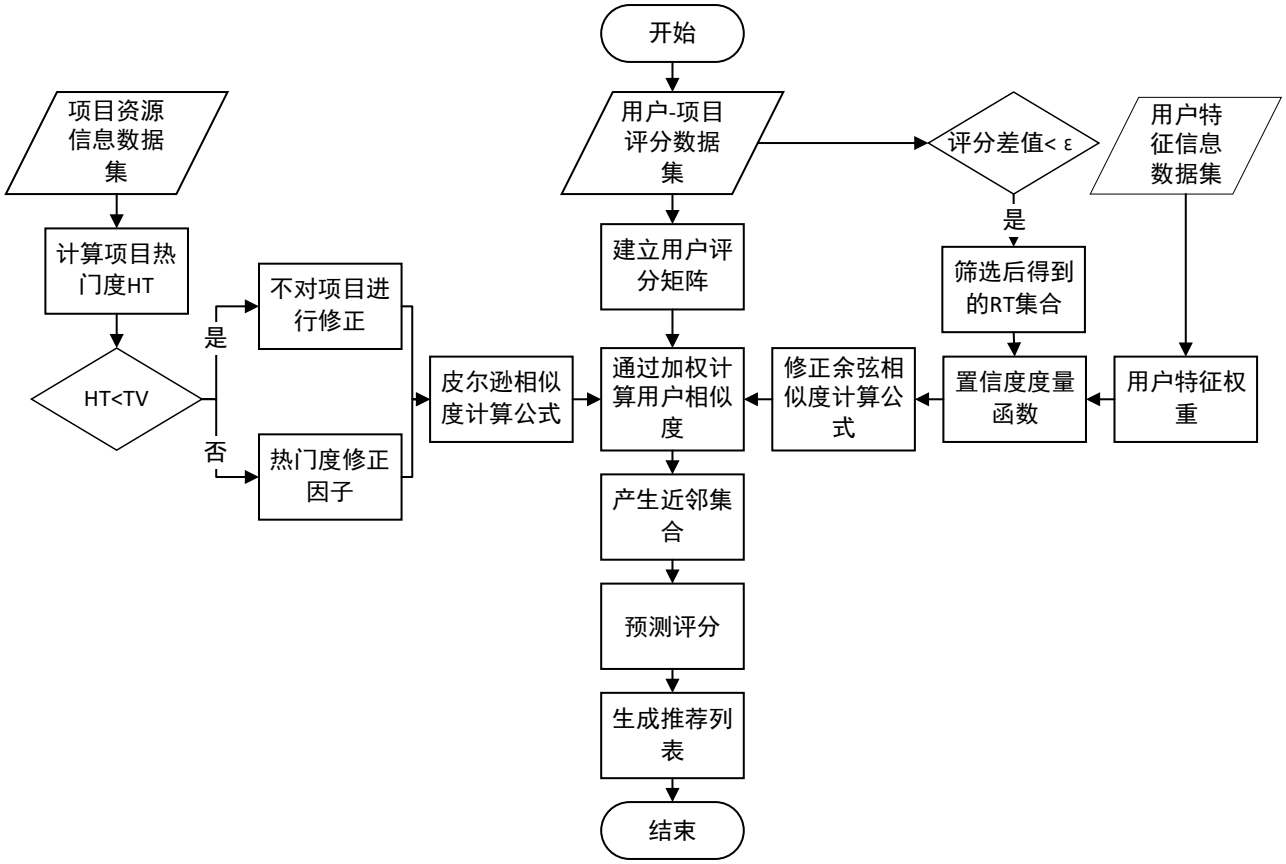


图 4.1　基于改进算法加权的混合推荐算法流程图

## 4.3 实验结果与分析

### 4.3.1 实验环境与评价指标

此次实验的程序设计主要是使用 python 语言，并基于 windows 平台对环境进行搭建，在相应的开发工具上进行代码开发和测试。具体的实验环境配置如 3.4.1 所示。

本文在 2.2 节中对推荐算法的性能评测指标进行了介绍，并对指标的优劣势进行了说明，因此本章实验主要使用平均绝对值误差和准确率这两个指标来对上述改进算法进行评估。



中国知网　https://www.cnki.net

### 4.3.2 实验数据集

本章实验数据集使用到了第三章实验数据集，除此之外，本章还用到了课程资源信息实验数据集，此数据集主要包括课程 ID、课程名称、课程时长、被评价的次数等特征列。

### 4.3.3 实验结果和分析

1. 基于热门度修正因子的协同过滤推荐算法性能对比实验设计

实验一：确定热门阈值 TV

为了测试计算式（4.2）中热门阈值 TV 的取值对推荐准确率的影响，选取 TV =0.4、0.5、0.6、0.7，邻居数目为[5,50]区间内不同取值时对推荐性能（MAE）的影响情况，从而为改进后的相似度计算公式选取合适的阈值。实验结果如表 4.1 所示，绘制图 4.2 所示，

表 4.1　不同热门阈值 TV 对算法性能的影响实验结果

| 邻居数目 | TV=0.4 | TV=0.5 | TV=0.6 | TV=0.7 |
|---|---|---|---|---|
| 5 | 0.867 | 0.8595 | 0.8233 | 0.8398 |
| 10 | 0.8436 | 0.8425 | 0.8016 | 0.8111 |
| 15 | 0.8319 | 0.8197 | 0.7843 | 0.7959 |
| 20 | 0.8244 | 0.7986 | 0.7732 | 0.7714 |
| 25 | 0.8189 | 0.7754 | 0.7669 | 0.7679 |
| 30 | 0.7934 | 0.7620 | 0.7588 | 0.7627 |
| 35 | 0.7915 | 0.7584 | 0.7529 | 0.7604 |
| 40 | 0.7992 | 0.7673 | 0.7544 | 0.7658 |
| 45 | 0.8054 | 0.7703 | 0.7550 | 0.7665 |
| 50 | 0.8101 | 0.7728 | 0.7557 | 0.7713 |

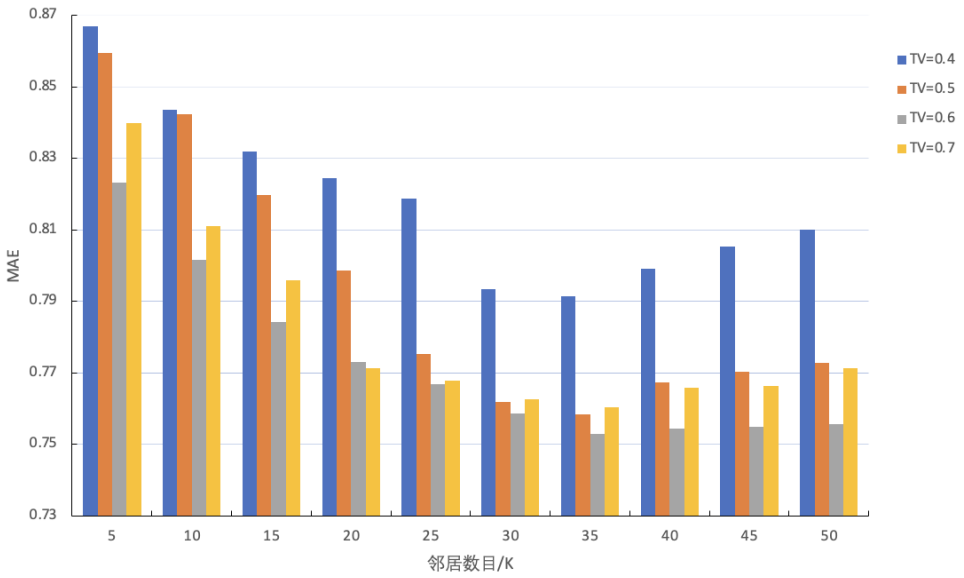


图 4.2 不同热门阈值（TV）对算法性能的影响实验结果



中国知网 https://www.cnki.net

由图 4.2 可知，在 TV=0.6、0.7 时，此算法的 MAE 值比较接近，而且在邻居数目为 20 时，尽管 TV=0.7 算法的 MAE 值比 TV=0.6 低 0.0018，但是在其他近邻数目的情况下，TV=0.6 算法的 MAE 值高于 TV=0.7，并且在任意近邻数目的情况下，TV=0.6 算法的 MAE 值高于 TV=0.4，0.5，因此在接下来选取热门阈值为 0.6 进行实验。

实验二：引入热门度修正因子后算法有效性的验证。

算法将热门度修正因子引入到皮尔逊相似度中，因此需要验证这一步骤的有效性。将此改进算法用 P-PES 来表示，本次实验主要选取 P-PES 原型算法和对相似度公式进行修正的算法进行对比，宋平[63]等人提出了使用正态分布函数修正推荐系统相关相似性，此算法在一定程度上也减少热门项目的影响，将此算法记为 NDFRS，文献 32、皮尔逊相似度计算公式分别用 CFTAF、PES 来表示。选取近邻集合 $k$ 在[5,50]取值，步长为 5，评价指标参考 MAE 值。对比结果如表 4.2 所示，绘制图 4.3 所示，

表 4.2　验证 P-PES 算法有效性实验对比结果

| 邻居数目 | PES | CFTAF | NDFRS | P-PES |
|---|---|---|---|---|
| 5 | 0.8657 | 0.8213 | 0.8288 | 0.8233 |
| 10 | 0.8573 | 0.8171 | 0.8072 | 0.8016 |
| 15 | 0.8504 | 0.8054 | 0.7931 | 0.7843 |
| 20 | 0.8486 | 0.8036 | 0.7823 | 0.7732 |
| 25 | 0.8472 | 0.8069 | 0.7812 | 0.7669 |
| 30 | 0.8448 | 0.7956 | 0.7784 | 0.7588 |
| 35 | 0.8459 | 0.7944 | 0.7796 | 0.7529 |
| 40 | 0.8464 | 0.7925 | 0.7835 | 0.7544 |
| 45 | 0.8467 | 0.7941 | 0.7857 | 0.7550 |
| 50 | 0.8475 | 0.7947 | 0.7879 | 0.7557 |

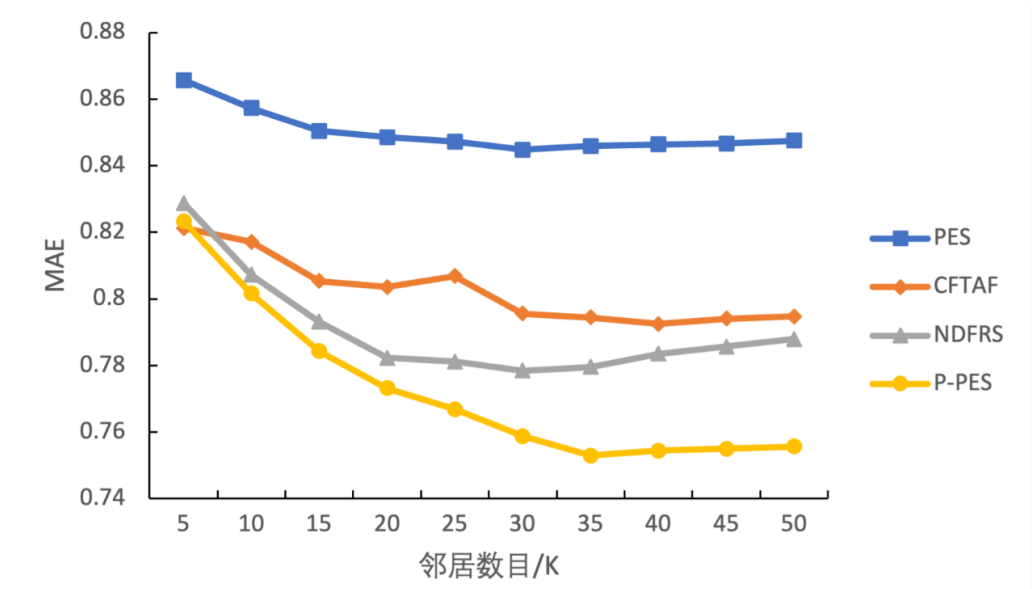


图 4.3　验证 P-PES 算法有效性实验对比结果



中国知网　https://www.cnki.net

从图中可以看出，本文改进的相似度计算公式的 MAE 值较传统的协同过滤算法相比都有所降低，因此说明了相似度计算公式中引入热门度修正因子是有效的。当 $k<20$ 时，改进算法的 MAE 下降幅度较大，当 $k>30$ 时，其 MAE 趋于平稳，并且由图 4.2 可知，当 $k=35$ 时，本文改进的相似度计算公式在此数据集中计算的 MAE 取得最小值，虽然当 k=5 时，基于热门度修正因子的算法改进的 MAE 值高于 CFTAF 算法，但是整体算法的性能是优于其他三种算法。

2. 基于改进算法加权的混合推荐算法对比实验设计

实验三：确定权重因子 w

由图 3.4 和图 4.3 可知，在 $k=35$ 时 CFUR 算法和 P-PES 算法的 MAE 值最小，因此在 k=35 情况下去改变公式（4.5）中的 $w$ 的值，在 $(0,1)$ 区间内选择步长为 0.1 进行取值，对比不同的 $w$ 计算出来 MAE 值，如表 4.3 所示，绘制如图 4.4 所示，

表 4.3　不同权重因子(w)对应的 MAE

| 权重因子(w) | MAE |
|---|---|
| 0.1 | 0.7284 |
| 0.2 | 0.7203 |
| 0.3 | 0.7114 |
| 0.4 | 0.7170 |
| 0.5 | 0.7184 |
| 0.6 | 0.7226 |
| 0.7 | 0.7298 |
| 0.8 | 0.7304 |
| 0.9 | 0.7341 |

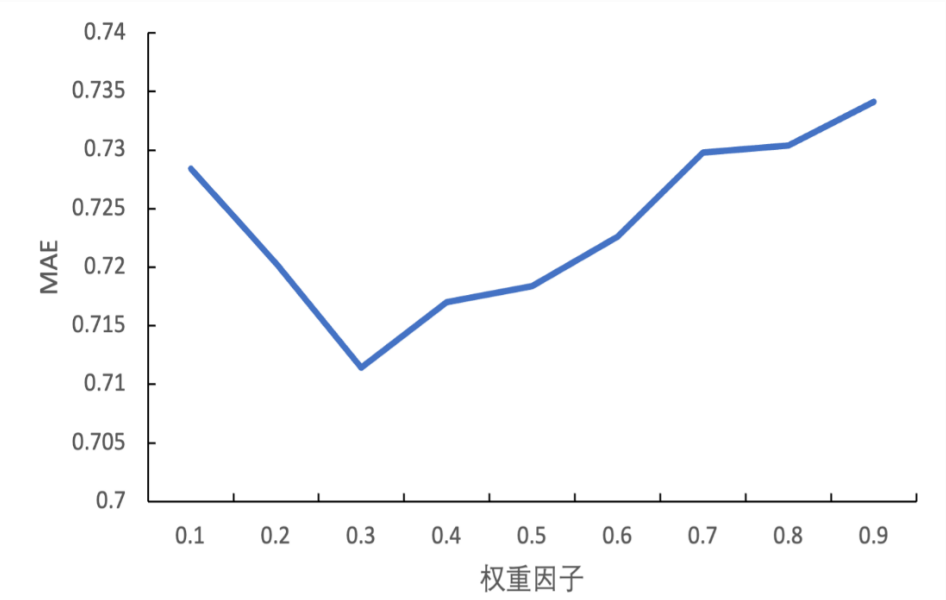


图 4. 4 不同权重因子（w）对应的 MAE



中国知网 https://www.cnki.net

如图 4.4 所示，在 $w$ 取[0.1,0.3]时，HRAW 算法的 MAE 值随着 $w$ 值的增大而减小，之后随着 w 值的增大，MAE 值也不断地增大，因此当 w 为 0.3 时，MAE 值取最小，算法效果最好。

实验四：不同算法之间的性能对比

为了更好地检验改进算法的效果，选取其他学者提出的混合推荐算法进行实验对比，因此将本文改进的算法与文献 42、文献 43、文献 44 所提出的算法进行对比实验，结果如图 4.5，4.6 所示，将 $w=0.3$ 代入最终的相似度计算公式中，近邻数从 5 开始，间隔为 5 直到 50 为止，分析比较不同近邻数算法的 MAE 值以及准确率之间的关系。

表 4.4　验证 HRAW 算法有效性—MAE 值对比实验结果

| 邻居数目 | 文献 42 | 文献 43 | 文献 44 | HRAW |
|---|---|---|---|---|
| 5 | 0.7849 | 0.7874 | 0.7601 | 0.7563 |
| 10 | 0.7654 | 0.7599 | 0.7487 | 0.7294 |
| 15 | 0.7465 | 0.7505 | 0.7356 | 0.7212 |
| 20 | 0.7427 | 0.7432 | 0.7294 | 0.7188 |
| 25 | 0.7385 | 0.7373 | 0.7230 | 0.7151 |
| 30 | 0.7366 | 0.7378 | 0.7204 | 0.7106 |
| 35 | 0.7391 | 0.7422 | 0.7178 | 0.7114 |
| 40 | 0.7422 | 0.7474 | 0.7193 | 0.7155 |
| 45 | 0.7456 | 0.7447 | 0.7181 | 0.7197 |
| 50 | 0.7495 | 0.7495 | 0.7229 | 0.7205 |

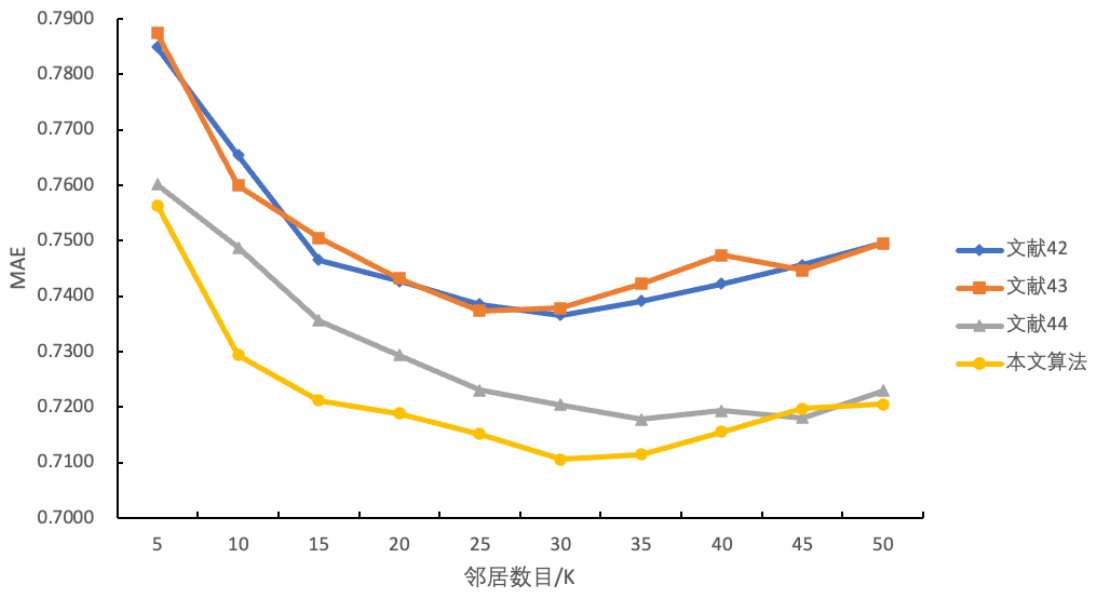


图 4.5　验证 HRAW 算法有效性—MAE 值对比实验结果

结果如图 4.5 所示，此图表示在不同近邻个数情况下，4 种算法 MAE 值的对比，随着 k 值在不断增加，HRAW 算法的 MAE 值先呈现下降趋势，然后有缓慢地上升趋势，出现这种情况的原因是随着近邻集合的增加，推荐过程中所参考的用户数目也在增多，因此推荐的精



中国知网　https://www.cnki.net

确性也会上升。邻居数目 $k$ 为 30 时，改进的混合推荐算法的 MAE 取最小值，从表 3.5 和表 4.2 也能看出，比传统的协同过滤算法（修正余弦相似度、皮尔逊相似度）的 MAE 值低 0.1211、0.1324，由此可见，本文改进算法的性能较传统的协同过滤算法有了明显的提升。从此折线图可以清晰地看出，虽然在近邻用户个数为 45 时，HRAW 算法的 MAE 值稍高于文献 44 所提出的算法，但是纵观整个结果曲线，HRAW 算法的整体性能是优于文献 44 提出的算法，并且本文改进算法整体上的 MAE 值都小于文献 42、文献 43 的 MAE 值。因此在模型训练时，设置近邻用户个数为 30 时，改进算法的推荐性能最优。

表 4.5　验证 HRAW 算法有效性—准确率对比实验结果

| 邻居数目 | 文献 42 | 文献 43 | 文献 44 | HRAW |
|---|---|---|---|---|
| 5 | 0.1647 | 0.1758 | 0.1822 | 0.1884 |
| 10 | 0.1739 | 0.1805 | 0.1984 | 0.2008 |
| 15 | 0.1775 | 0.1833 | 0.2033 | 0.2075 |
| 20 | 0.1829 | 0.1859 | 0.2064 | 0.2093 |
| 25 | 0.1883 | 0.1887 | 0.2050 | 0.2152 |
| 30 | 0.1905 | 0.1868 | 0.2028 | 0.2177 |
| 35 | 0.1846 | 0.1855 | 0.2096 | 0.2145 |
| 40 | 0.1841 | 0.1807 | 0.2081 | 0.2104 |
| 45 | 0.1867 | 0.1815 | 0.2116 | 0.2088 |
| 50 | 0.1774 | 0.1796 | 0.2095 | 0.2097 |

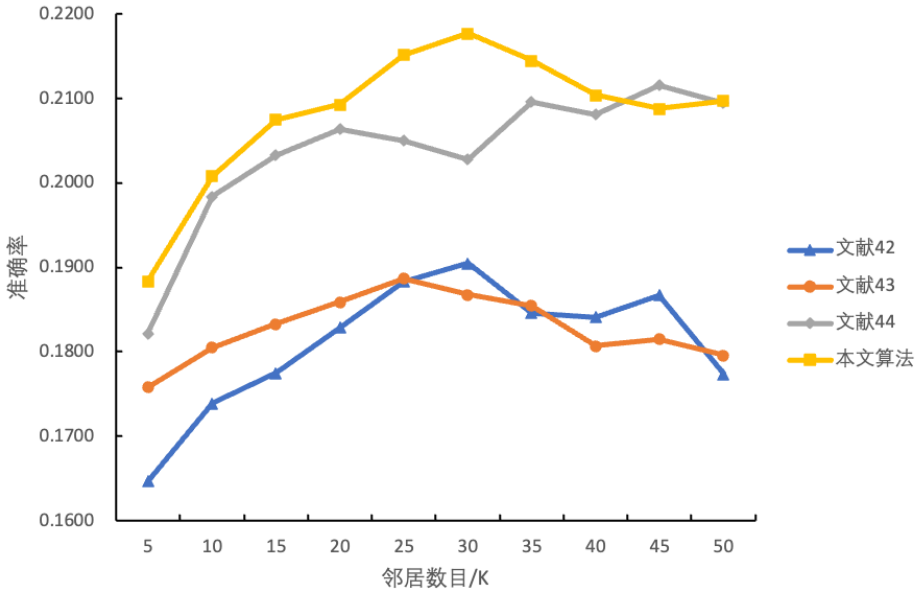


图 4.6　验证 HRAW 算法有效性—准确率对比实验结果

图 4.6 也证明了该算法显著的改进效果，从图中可以清晰地看出随着邻居数目的增加，改进算法的准确率也逐渐上升，当邻居数目大于 35 时其准确率趋于平稳，并且邻居数目为 30 时，改进算法的准确率达到最高（0.2177），尽管当近邻数目为[40,50]时，准确率有所下降，



中国知网　https://www.cnki.net

并且在近邻数目为 45 时，文献 44 算法的准确率稍高于 HRAW 算法，但是纵观整个折线图，HRAW 算法的准确率都优于其他三种算法。

## 4.4 本章小结

本章节首先指出传统的相似度计算公式过分考虑热门项目这一问题，提出了基于热门度修正因子的协同过滤推荐算法，然后验证了此算法改进后性能的优势，接着将第三章所提出改进的算法与本章提出的算法进行加权融合，形成了基于改进算法加权的混合推荐算法，最后进行实验分析，验证了本文提出的算法具备良好的推荐性能。



中国知网 https://www.cnki.net

# 第五章 课程资源推荐系统的设计与实现

本文将第四章所提出的基于改进算法加权的混合推荐算法应用到课程资源推荐系统，并且以为高校学生推荐相关专业课程为背景，目的是使系统为他们推荐的课程更符合个人的偏好以及自身的特征，进而提高学生用户的学习效率。

## 5.1 需求分析

为了更好地实现系统的功能，接下来主要从以下几个方面来对系统的需求进行简要地分析：

（1）用户注册：使用系统的第一步就是注册，在相应的注册页面填写用户名、密码、性别和偏好课程类型等个人信息。

（2）用户登录：要想使用此系统的推荐功能，用户必须登录进入到课程资源推荐系统这个平台。

（3）课程查询：因课程库中课程数目较多，为了让用户能够更快地定位到感兴趣的课程，需要提供课程检索的功能。

（4）课程评价：用户对自己关注的课程进行评价打分。

（5）课程推荐：课程推荐是系统中不可或缺的功能模块，后端获取到用户的行为数据，并将其存入相应的数据库中，通过操作指令对数据进行预处理并存入表格中作为算法输入的数据源，将算法模型训练的结果存入到数据库中，最终通过前端界面将推荐结果展示。其中，推荐算法模块的数据源主要包括三个部分：用户的历史评价信息、用户本身的信息特征、课程资源相关信息。

本系统的设计思路是采集系统用户行为信息，利用第二章数据预处理后的数据集作为算法模型的输入源，后台推荐算法是本文基于改进算法加权的混合推荐算法，产生推荐列表给学生用户。

## 5.2 课程资源推荐系统的设计

### 5.2.1 开发环境

一个性能良好的课程资源推荐系统对开发运行环境也会提出更高的要求，因此本文主要



中国知网 https://www.cnki.net

如下的开发运行环境：

使用 IDEA 作为后端的开发的编译器，并且后台框架搭建采用 Spring 框架，方便对相关需求进行开发。

使用 MySQL8.0 数据库。

使用 Redis 缓存数据库，为相关功能提供缓存服务。

使用 axios 可以进行 Ajax 的请求。

使用 VSCode 作为前端的开发工具，利用 Vue 框架对前端需求进行开发。

### 5.2.2 系统框架的设计

在对课程资源推荐系统开发前，首先要对此系统的框架进行设计搭建，如图 5.1 展示了此系统的架构图。

该系统所采用的是浏览器/服务器[64]（B/S）模式，此模式相较于客户端/服务端[65]（C/S）模式开发时更为简单，这是因为客户端只需要运行浏览器，当浏览器向后台服务端发出相应的请求，服务端接收并做处理，最终将数据结果返回给浏览器，从而实现信息共享。图 5.1 详细地展示了此课程资源推荐系统四层的逻辑结构，并将每层包含的主要模块和关键技术进行了简要地陈列，下面将分别对视图层、业务逻辑层、算法层、数据层的工作原理及工作内容进行介绍：

（1）视图层是相关界面的展示，使用 Vue 搭建前端相关框架，其中相关逻辑代码主要使用 JavaScript 语言，页面样式的修改使用 CSS，使用 Html 对页面框架进行搭建，学生用户与系统页面产生交互，前端通过相应的接口拿到后台传来的数据并在系统相关页面进行渲染。视图层主要有课程资源推荐、课程资源管理、课程评分管理、用户管理等模块等。

（2）业务逻辑层也就是后端研发的相关逻辑，它是接收到用户请求的相关信息，然后不同的逻辑模块会这些数据信息进行处理。

（3）算法层是该系统的核心层，主要利用前文中提出的基于改进算法加权的混合推荐算法，基于数据层处理后的数据集输入到算法层进行模型训练，进而筛选出所要推荐的课程，将推荐的课程资源存储到数据库课程资源推荐信息表中，方便业务逻辑层进行操作。

（4）数据层主要由数据库和数据处理两部分构成，其中数据库中存放了用户信息、课程信息、评价信息、推荐信息、关注信息等数据内容。数据处理是从数据库中获取到的数据集进行预处理，其中主要包括数据清洗、数据转换和数据集成等操作，最终得到用于算法层的数据集。



中国知网 https://www.cnki.net

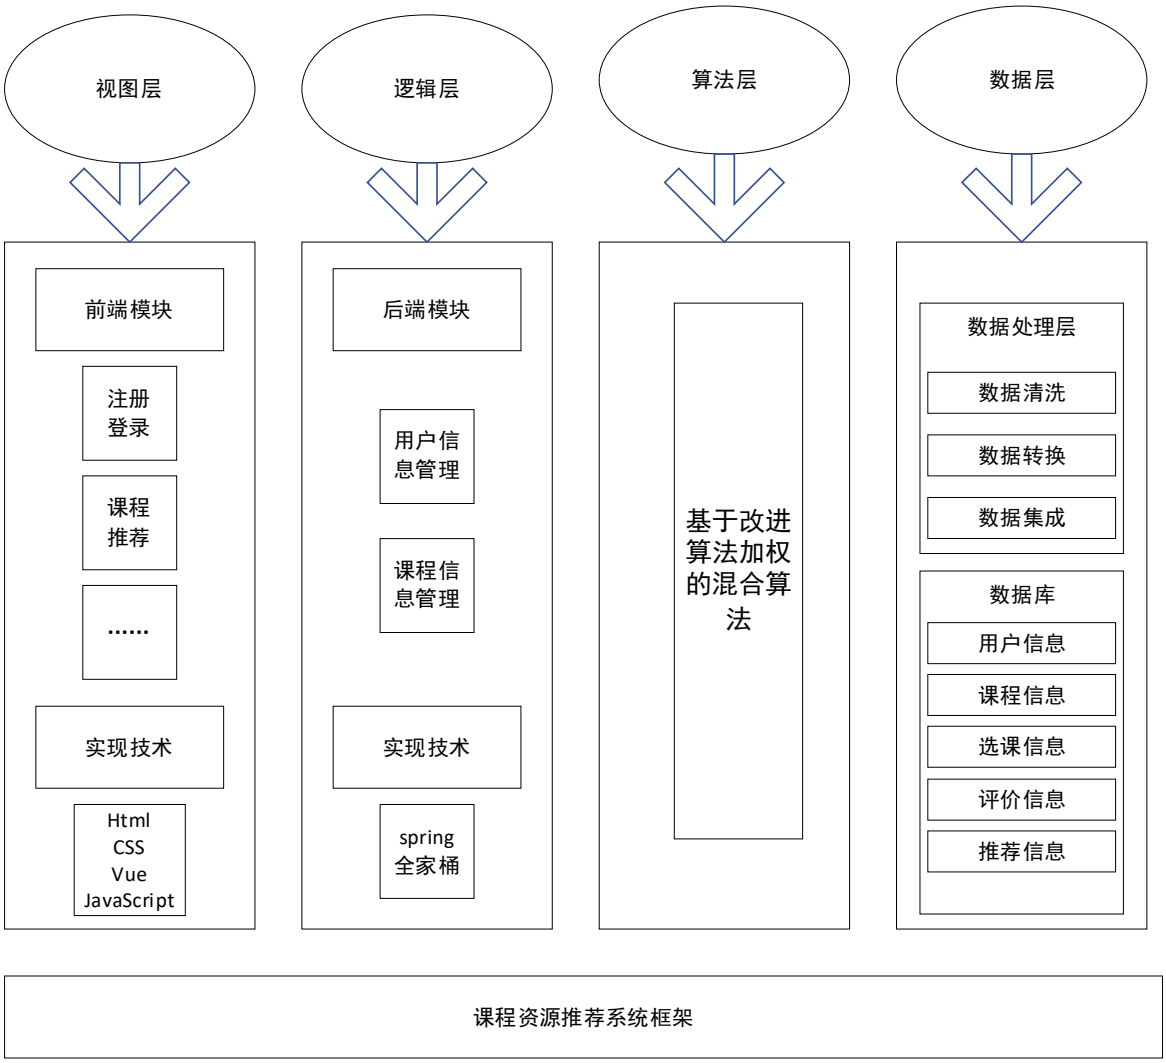


图 5.1 课程资源推荐系统架构图

## 5.3 功能模块的设计与实现

### 5.3.1 数据模块

1. 数据库设计

后端接收前端相关的数据时需要进行存储、操作等处理，因此课程资源推荐系统选用 MySQL 数据库进行设计和开发，此数据库不但可以保证数据存储的安全性，而且还可以为将来生成数据表格提供良好的保障。

本系统在数据库创建了用户个人信息表、课程资源信息表、用户选课信息表、用户课程评价信息表、课程资源推荐信息表 5 张表，以下是 5 张表的设计。

（1）用户个人信息表

用户个人信息表包括用户 id、用户名称、用户密码、性别、学校、学院、专业、用户偏



中国知网 https://www.cnki.net

爱课程类型、关注课程的个数、用户登陆时间、用户注册时间这些内容。如表 5.1 所示：

表 5.1 用户个人信息表

| 序号 | 字段类型 | 字段标识 | 备注 | 允许为空 |
|---|---|---|---|---|
| 1 | char | user_id | 用户 id | no |
| 2 | char | user_name | 用户名称 | no |
| 3 | char | user_passwd | 用户密码 | no |
| 4 | char | user_gender | 性别 | no |
| 5 | char | user_school | 学校 | no |
| 6 | char | user_college | 学院 | no |
| 7 | char | user_major | 专业 | no |
| 8 | char | user_like_type | 用户偏爱课程类型 | no |
| 9 | int | user_concer | 关注课程个数 | yes |
| 10 | datetime | user_login_time | 用户登陆时间 | yes |
| 11 | datetime | user_register_time | 用户注册时间 | no |

（2）课程资源信息表

课程资源信息表包括课程 id、课程名称、课程类型、课程时间、讲师名、被评价次数、课程录入时间这些内容，如表 5.2 所示：

表 5.2 课程资源信息表

| 序号 | 字段类型 | 字段标识 | 备注 | 允许为空 |
|---|---|---|---|---|
| 1 | char | course_id | 课程 id | no |
| 2 | char | course_name | 课程名称 | no |
| 3 | char | course_type | 课程类型 | no |
| 4 | char | course_time | 课程时间 | no |
| 5 | char | teacher_name | 讲师名 | no |
| 6 | int | course_eva_fre | 被评价次数 | yes |
| 7 | datetime | course_enter_time | 课程录入时间 | no |

（3）用户选课信息表

用户选课信息表包括用户 id、关注课程 id、关注课程名称、是否对课程进行评价、学习



中国知网 https://www.cnki.net

课程的时间这些内容，如表 5.3 所示：

表 5.3 用户选课信息表

| 序号 | 字段类型 | 字段标识 | 备注 | 允许为空 |
|---|---|---|---|---|
| 1 | char | choose_user_id | 用户 id | no |
| 2 | char | choose_course_id | 关注课程 id | no |
| 3 | char | choose_name | 关注课程名称 | no |
| 4 | Boolean | choose_eva | 是否对课程进行评价 | no |
| 5 | char | learn_time | 学习课程的时间 | yes |

（4）用户课程评价信息表

用户课程评价信息表包括用户 id、评价课程 id、评价课程名称、评价课程的分数这些内容，如表 5.4 所示：

表 5.4 用户课程评价信息表

| 序号 | 字段类型 | 字段标识 | 备注 | 允许为空 |
|---|---|---|---|---|
| 1 | char | eva_user_id | 用户 id | no |
| 2 | char | eva_course_id | 评价课程 id | no |
| 3 | char | eva_name | 评价课程名称 | no |
| 4 | int | eva_score | 评价课程的分数 | no |

（5）课程资源推荐信息表

课程资源推荐信息表包括用户 id、推荐课程 id、评价课程名称、预测评分这些内容，如表 5.5 所示：

表 5.5 课程资源推荐信息表

| 序号 | 字段类型 | 字段标识 | 备注 | 允许为空 |
|---|---|---|---|---|
| 1 | char | rec_user_id | 用户 id | no |
| 2 | char | rec_course_id | 推荐课程 id | no |
| 3 | char | rec_name | 评价课程名称 | no |
| 4 | double | pre_score | 预测评分 | no |

2. 数据获取

数据获取是指将用户注册信息、选课信息、评价信息等记录数据同步获取到本系统的数



中国知网 https://www.cnki.net

据库中。数据库中存放着四张库表，分别为用户个人信息字段列表、课程资源信息字段列表、用户选课信息字段列表以及用户课程评价信息字段列表，其中 USER_INFO 表是用户个人信息表；COURSE_ITEM 表是课程资源信息表；COURSE_CHOICE 表是用户选课信息表；EVALUATE _COURSE_SCORE 表是用户课程评价信息表，四张表对应的结构关系如图 5.2 所示。

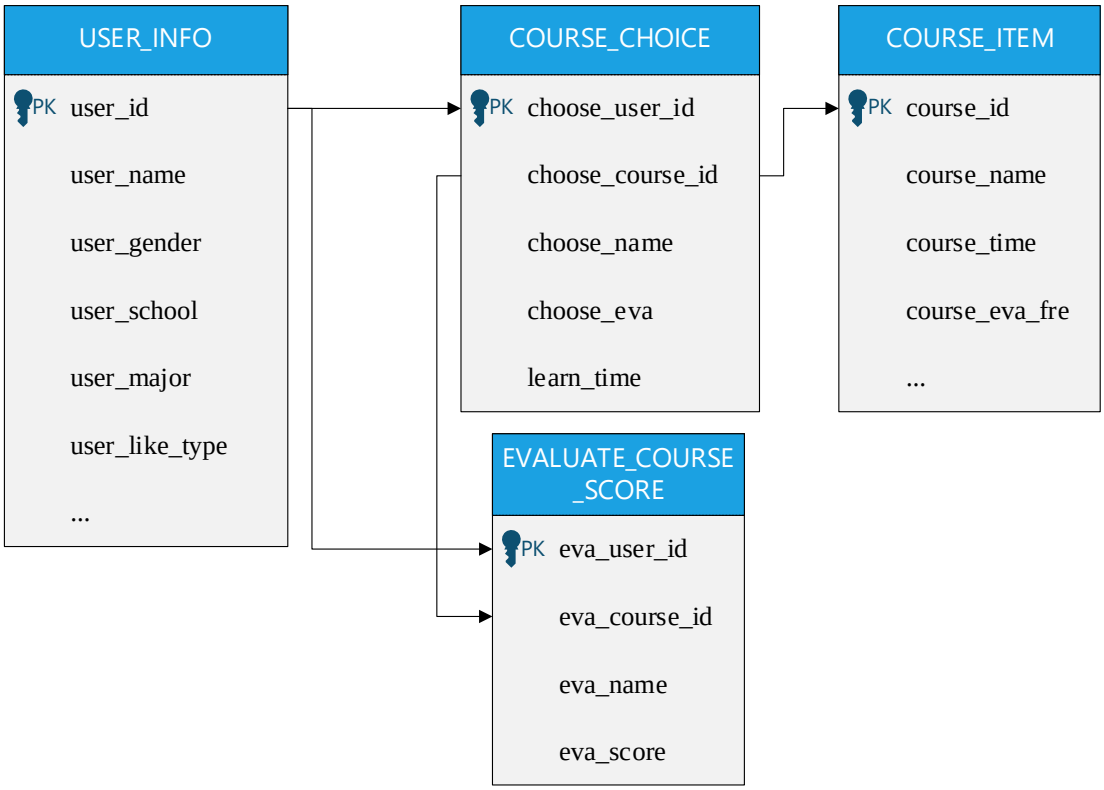


图 5.2 数据库表结构关系

3. 数据预处理

数据预处理是基于改进算法加权的混合推荐算法前必不可少的一个步骤，利用 SQL 语句，对数据表中的数据进行清洗、转换、集成等操作，将处理好的数据存入 EXCEL 表格中，具体操作如 2.3 节所示。

### 5.3.2 算法分析模块

算法分析模块主要集成了基于用户特征权重置信度的协同过滤推荐算法（CFUR）以及基于热门度修正因子的协同过滤推荐算法（P-PES），通过对上述算法加权融合得到基于改进算法加权的混合推荐算法（HRAW），利用经过预处理的用户个人信息、课程资源信息、用户—课程评分信息数据集，采用 HRAW 算法模型进行训练，具体处理流程如图 5.3 所示。



中国知网 https://www.cnki.net

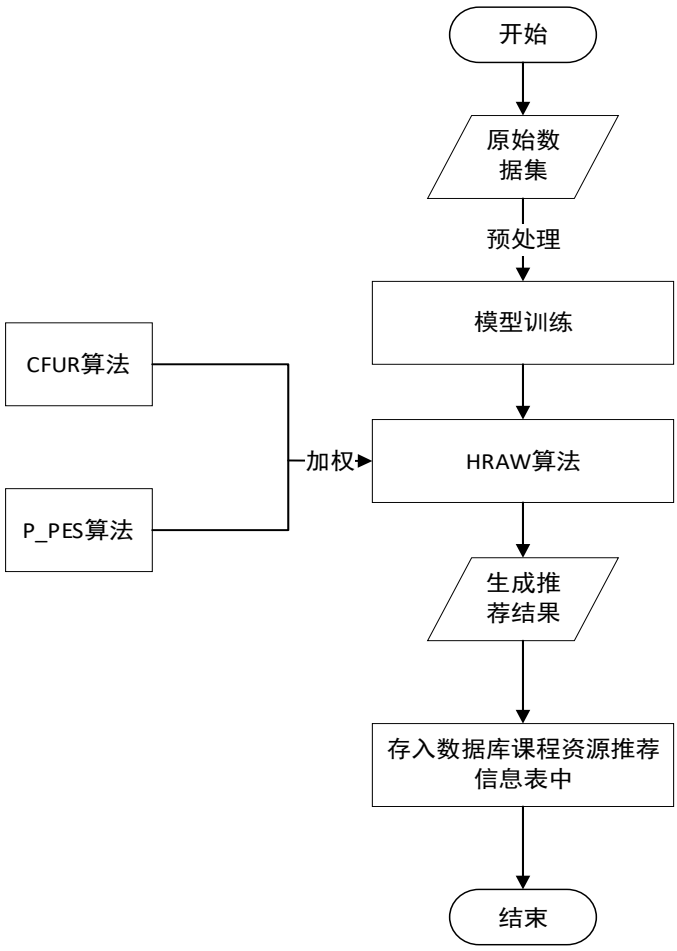


图 5.3 算法分析模块流程图

### 5.3.3 功能模块设计

课程资源推荐系统包括用户注册/登录模块、用户关注模块、用户评价模块、以及课程推荐模块 4 个功能模块。前三个模块主要是为了采集用户的行为信息数据，为推荐算法模块提供数据源。最后一个模块是本系统的核心模块，主要目的是为用户推荐感兴趣的课程列表。具体功能模块如下所示：

1. 用户注册/登录模块

该模块是系统产生推荐的前提，推荐系统只能对网站中已注册用户的行为进行记录和分析，用户与此模块交互的具体流程如下：如果用户首次访问系统，则需要切换到注册页面，填写用户名、密码、学校、专业等个人相关的信息，页面中还有确认密码这一输入框，前端会判断两次输入的密码是否一致，并检查相关信息的格式是否正确，如果正确，点击注册按钮，后台数据库会对用户信息进行存储，方便下次用户登陆时对相关信息进行比对，注册成功后进入系统平台首页，反之则需对信息重新填写。如果已经注册过的用户进行登录时，在登陆界面输入用户名和密码，点击登录按钮后，后台数据库会进行比对，比对成功后，用户



中国知网 https://www.cnki.net

则登陆成功并跳转至系统平台首页，反之则需重新输入用户名和密码，模块流程示意图如图 5.4 所示。

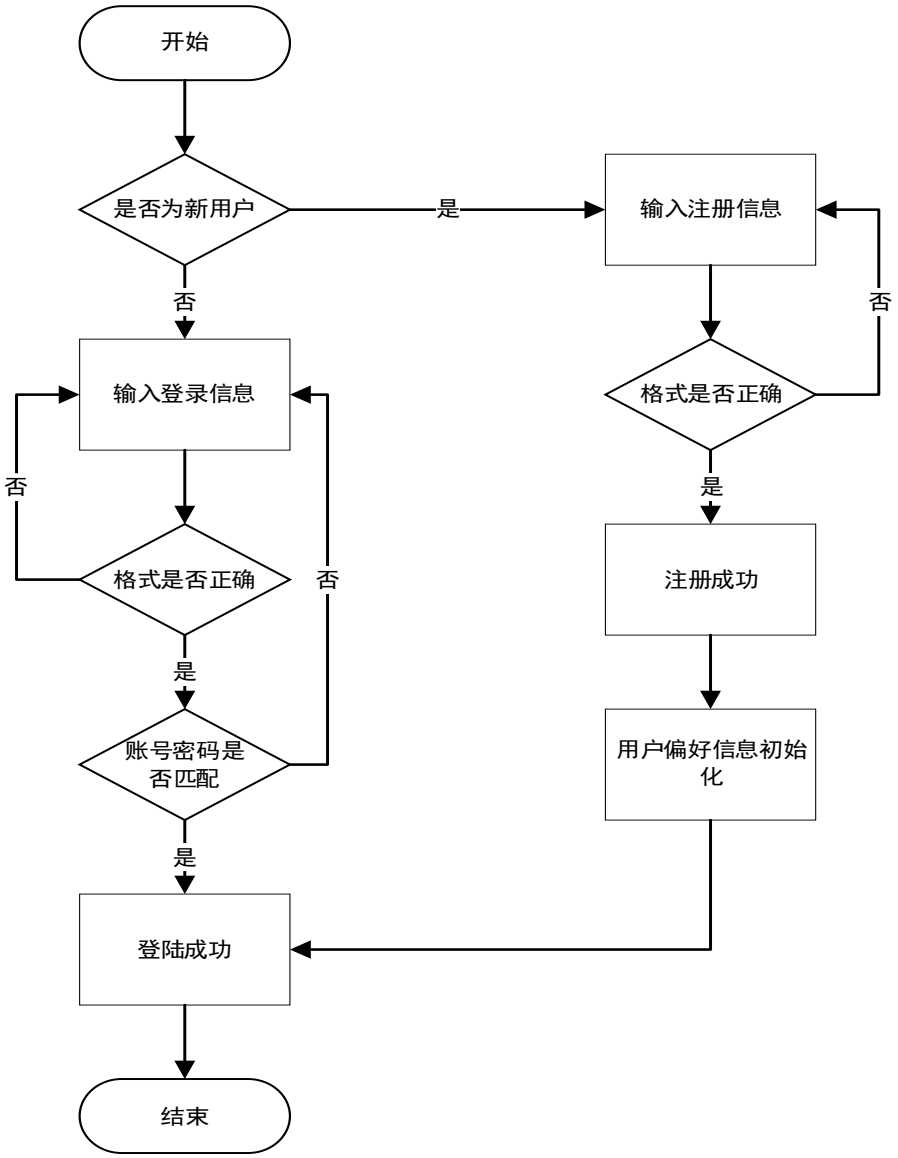


图 5.4　注册/登录模块流程示意图

2.　用户关注模块

此模块的主要作用是收集用户关注课程列表信息，后台将用户关注列表数据信息存入到数据库，为 HRAW 算法模型训练做好数据准备。流程如图 5.5 所示，用户通过浏览推荐模块的课程或者课程资源管理的课程，找到自己感兴趣的课程，对其进行关注操作，并将关注课程的列表和个数反馈到用户管理模块。



中国知网　https://www.cnki.net

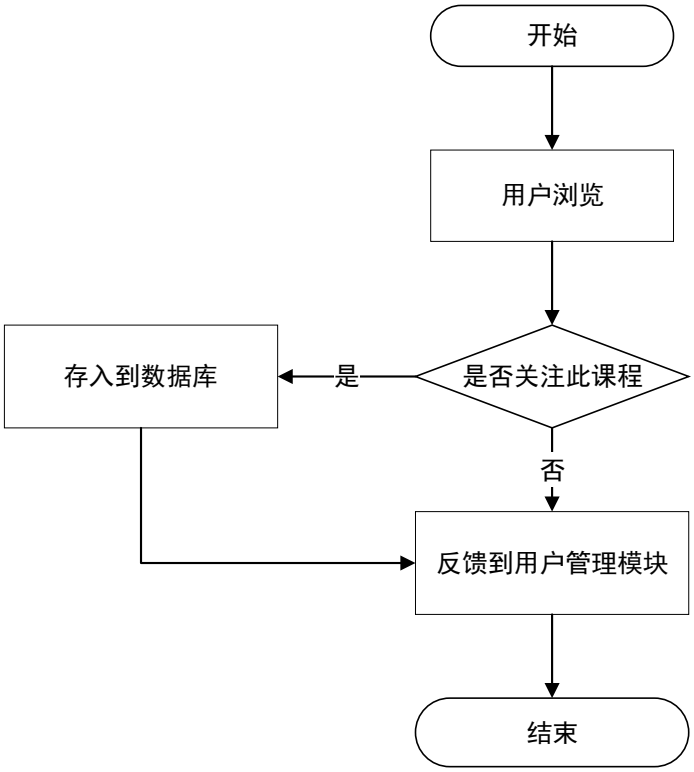


图 5.5 用户关注模块流程图

3. 用户评价模块

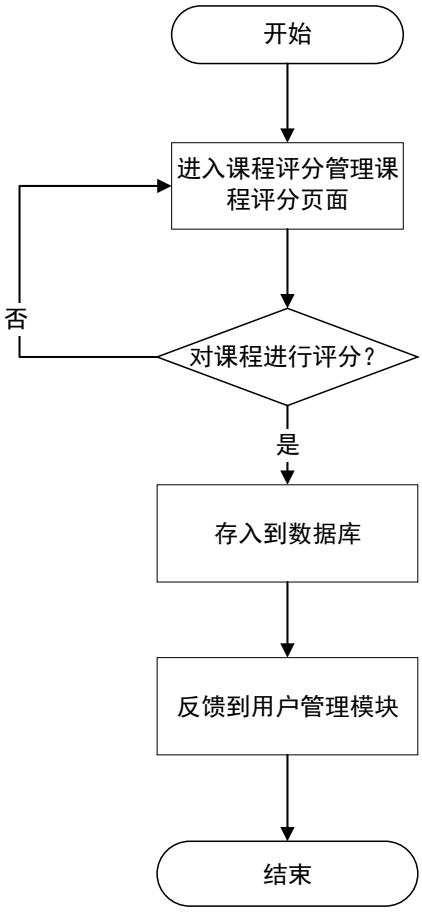


图 5.6 用户评价模块流程图



中国知网 https://www.cnki.net

课程评价模块的主要作用是收集本文改进算法的输入源数据（学生用户对课程的评价分数）。如果用户对已关注的课程有过评分记录，则将评分信息反馈到用户关注课程界面，反之，用户需要对关注的课程进行评分，新的评分记录将存入到数据库中。

4. 课程推荐模块

当后台获取到用户 ID 信息后，会根据此信息去数据库表查找用户关注的信息以及对相关课程评分的数据信息，如果上述两个信息都可以被查询并获取到，则可以使用 HRAW 算法为用户生成相应的课程资源推荐列表；如果两者都没有被查询到，则利用用户注册时填写的偏爱课程类型信息为用户进行推荐，如果仅有关注列表而没有评分信息，则通过关注课程类型信息为用户进行推荐。推荐列表主要通过算法模块得到，并将其存入到数据库课程资源推荐信息表中，前端通过调用相应的接口将课程资源列表展示给用户。推荐模块的功能流程图如图 5.7 所示。

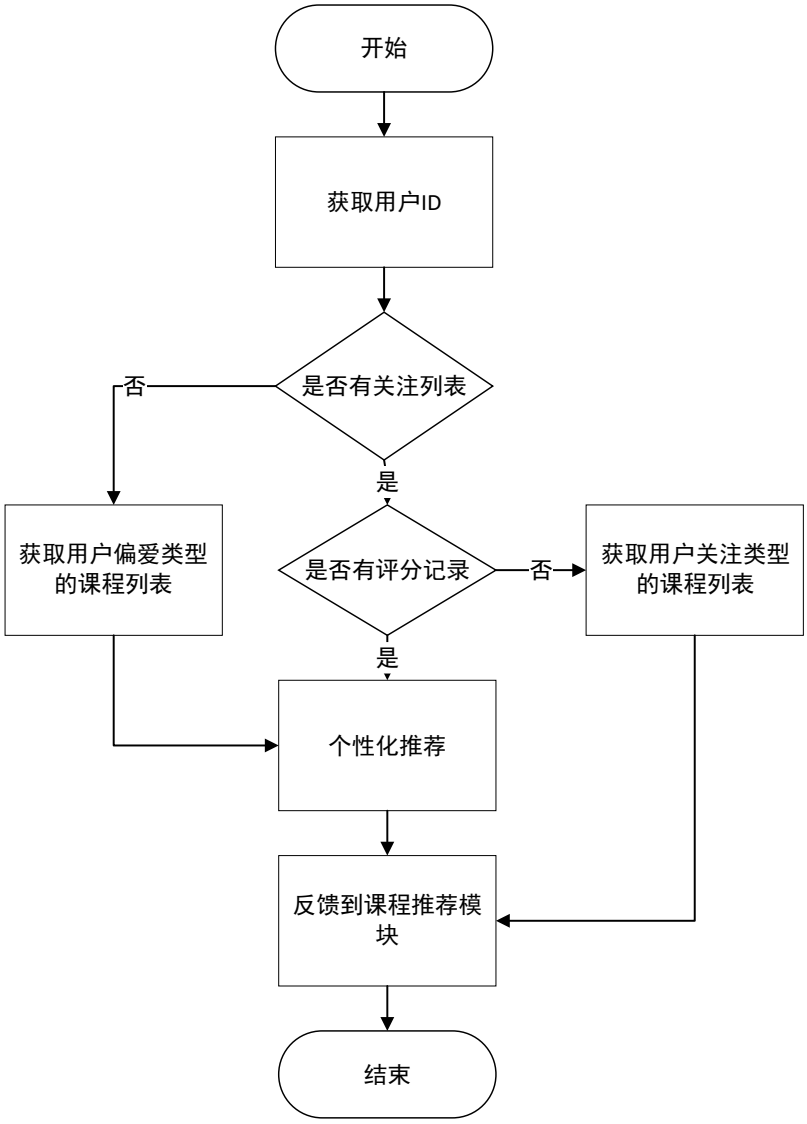


图 5.7　课程推荐模块流程图



中国知网　https://www.cnki.net

### 5.3.4 课程资源推荐系统展示

1. 用户注册登陆

登录注册界面如图 5.8 所示，用户分别输入正确的用户名和密码方可登录和访问系统主页。如果是新用户，需要进行注册填写相关信息才能访问系统主页。

图 5.8　用户注册登录界面

2. 课程推荐

图 5.9　课程推荐界面



中国知网　https://www.cnki.net

如图 5.9 所示，此界面展示了系统利用用户特征信息、课程资源信息以及用户行为信息通过本文的 HRAW 算法模型训练所得到推荐列表，其中包括了课程的名称、课程类型、课程时长、讲师名、以及用户对此课程是否关注这些内容。

3. 课程资源管理

如图 5.10 所示，此模块向用户展示了课程的相关信息，如课程的时长、课程名称、课程类型、讲师名以及用户可对课程进行选择关注，并且用户可以根据个人偏好对相关的课程进行搜索。

图 5.10　课程资源列表界面

4. 课程评分管理

如图 5.11 所示，如果用户对某门课程已经进行评价，则此课程的相关信息不会在课程评分界面出现，评价的详情信息在用户管理模块中的用户关注课程界面展示给用户，如果用户未曾评价过该课程，则需在 1-5 分进行选择评价，评价的详情信息也会展示给用户。



中国知网　https://www.cnki.net

图 5.11　用户课程评分信息界面

5.　用户管理

（1）用户信息

如图 5.12 所示，此界面主要介绍了用户相关的特征信息以及关注课程的个数。

图 5.12　用户信息界面

（2）用户关注课程

如图 5.13 所示，此界面介绍了用户关注的课程信息、评分信息以及用户对所关注的课程是否进行评价。



中国知网　https://www.cnki.net

图 5.13　用户关注课程信息界面

## 5.4 本章小结

本章完成了课程资源推荐系统的设计与实现。首先对系统进行需求分析，其次从需求分析、课程资源推荐系统的设计以及功能模块三个方面出发，对系统进行设计，最后实现了个性化课程资源推荐系统的开发，由此也说明了论文提出算法的实用性。



中国知网　https://www.cnki.net

# 第六章 总结与展望

## 6.1 总结

本文深入地研究了协同过滤算法的步骤，尤其是在计算用户之间相似度时，发现其存在一些值得改进的地方，因此提出了基于改进算法加权的混合推荐算法，并在第六章将其应用在课程资源推荐系统上，从而将算法与实际应用紧密结合起来。本文的研究内容主要包括如下几个内容：

（1）研究传统的协同过滤推荐算法，对其相关的背景、研究现状以及具体流程作了详细地介绍，并且处理了相关数据集，为后续算法实验验证作铺垫。

（2）当用户进入系统时，后台会收集用户的特征信息和行为信息，将这些信息进行量化处理，形成用户特征权重，针对用户评分数据极端稀疏的情况，本文引入 Jaccard 函数作为衡量用户间的置信度，并且对用户间评分差设定相应的阈值来过滤用户共同评分的某些课程。基于上述内容，提出了基于用户特征权重置信度的协同过滤推荐算法，最终通过实验选取合适的阈值，并且证明此改进算法具有显著提升，此算法在一定程度上缓解了由于评分数据稀疏造成推荐结果不准确的问题的同时也降低了冷启动问题对推荐性能的影响。

（3）传统的协同过滤算法会过分考虑热门课程，从而忽略用户的个性化特征，因此本文提出了热门度修正因子这个概念，并且将此因子融入到皮尔逊相似度计算公式中得到基于热门度修正因子的协同过滤推荐算法，最终通过权重因子将两个模型进行融合形成最终的基于改进算法加权的混合推荐算法，并设计实验，选取合适的热门阈值，并得出上述两个改进算法最优的权重配比，以及将本文改进算法与传统的协同过滤算法和其他论文改进算法的性能进行了对比分析，实验结果显示本文改进算法能够提高推荐系统推荐功能的准确性，进而反应了新算法模型性能的优势。

（4）基于 HRAW 算法模型设计并实现课程资源推荐系统。利用 Web 相关开发框架搭建课程推荐系统，并从需求分析、系统设计以及功能模块的设计与实现对系统进行详细地介绍。

## 6.2 展望

本文提出了融合用户特征权重的置信度和热门度修正因子的课程推荐模型，从而为用户生成满意的推荐资源。尽管此模型减少了传统算法的一些弊端，但本文算法可改进的空间依旧还很大，今后仍需在改进方向深入钻研，其中具体有以下几个方向：



中国知网 https://www.cnki.net

（1）时间因素对推荐性能的影响，在实际的生活场景中可以观察到，一个用户的兴趣爱好不可能是一成不变的，为了探究其变化规律与时间因素之间的关系，须在以后的算法模型改进中考虑到用户的兴趣爱好随时间转移这个问题。

（2）本文提出的算法只用到了一类数据集进行了实验验证，在之后的算法研究中可以考虑加入其他数据集来验证该算法的有效性，例如 MovieLens，epinions，豆瓣数据集等。

（3）推荐系统中的数据库通常存有上万条数据集，在生成推荐列表时会浪费大量的时间，为了提高推荐系统的实时性，可以考虑 Hadoop 和 Spark 大数据框架对数据集进行训练，而且这个问题也为未来研究的方向提供参考。



中国知网 https://www.cnki.net

# 参考文献


[1] 张婷. 医学教育在"互联网+"时代的发展[J]. 中国继续医学教育, 2019, 11(17): 56-58.

[2] Su Y S, Ding T J, Lue J H, et al. Applying big data analysis technique to students' learning behavior and learning resource recommendation in a MOOCs course[C]// International Conference on Applied System Innovation. IEEE, 2017.

[3] 杨晓贤, 张世明，朱彬. IPv6 环境下移动服务流程的不确定性评估推荐技术研究[J]. 通信学报, 2018, 39(S1):151-161.

[4] Lazarinis F, Karatrantou A, Panagiotakopoulos C, et al. Strengthening the coding skills of teachers in a low dropout Python MOOC[J]. Advances in Mobile Learning Educational Research, 2022, 2(01): 187-200.

[5] Mondal S, Gugnani A, Sindhgatta R, et al. Khan Academy:A Social Networking and Community Question Answering Perspective[C]// 2018 IEEE International Conference on Data Mining Workshops (ICDMW). IEEE, 2018.

[6] 陈峰, 李玲. 基于泛雅网络学习平台的高职《单片机应用技术》网络课程建设[J]. 电脑知识与技术, 2017, 13(11): 96-97.

[7] 邱立军. 基于综合评价法的在线教育企业价值评估——以 51Talk 为例[D]. 暨南大学, 2019.

[8] Iwendi C, Ibeke E, Eggoni H, et al. Pointer-Based Item-to-Item Collaborative Filtering Recommendation System Using a Machine Learning Model[J]. International Journal of Information Technology & Decision Making, 2022, 21(01): 463-484.

[9] 周琴英，杨文正. 推荐系统用户模型的研究热点及启示——基于近十年核心文献的知识图谱分析[J]. 情报科学, 2020, 38(09):166-173.

[10] 孙远帅. 基于大数据的推荐算法研究[D]. 厦门大学, 2014.

[11] Eirinaki M, Gao J, Varlamis I, et al. Recommender Systems for Large-Scale Social Networks: A review of challenges and solutions[J]. Future Generation Computer Systems, 2018, 78(78): 413-418.

[12] 何旭. 融合信任模型的协同过滤推荐算法研究[D]. 南京邮电大学, 2018.

[13] 邹凌君, 陈崚, 李娟. 时间加权的混合推荐算法[J]. 计算机科学, 2016, 43(S2): 451-454.

[14] Guo G, Jie Z, Thalmann D. Merging trust in collaborative filtering to alleviate data sparsity and cold start[J]. Knowledge-Based Systems, 2014, 57(feb.): 57-68.

[15] Tsang G, Zhou S M, Xie X. Modeling Large Sparse Data for Feature Selection: Hospital Admission Predictions of the Dementia Patients Using Primary Care Electronic Health Records[J]. IEEE Journal of Translational Engineering in Health and Medicine, 2020, 9(99): 1-1.

[16] 钟亚妹. 线上学习系统个性化课程推荐模型算法设计[J]. 电脑知识与技术:学术版, 2021, 17(25): 130-143.

[17] 左琳, 刘念伯, 杨腾杰. 一种带有数据增强的线上教学推荐系统, CN112784154A[P]. 2021.

[18] 彭云, 万红新. 基于学习推荐策略的众智型线上、线下混合式教学研究[J]. 信息与电脑(理论版), 2022, 34(09): 242-244.

[19] 郭俭, 徐亚军. K-12 区域级学习平台个性化推荐系统资源画像模型建设研究[J]. 中国教育信息化, 2019 (12): 77-80.

[20] Hou Y, Pan Z, Wang T, et al. Context-Aware Online Learning for Course Recommendation of MOOC Big Data[J]. CoRR, 2016.

[21] Vedavathi N, Kumar K M A. SentiWordNet Ontology and Deep Neural Network Based Collaborative Filtering Technique for Course Recommendation in an E-Learning Platform[J]. International Journal of Uncertainty, Fuzziness and Knowledge-Based Systems, 2022, 30(04): 709-732.

[22] Ng Y K, Linn J. CrsRecs: A personalized course recommendation system for college students[C]//




中国知网 https://www.cnki.net

International Conference on Information. IEEE, 2018.
[23] Rani L, Wise D, Ajayram K, et al. Course Recommendation for students using Machine Learning[C]// 2020 International Conference on Electronics and Sustainable Communication Systems (ICESC), 2020.
[24] 谢霖铨, 梁博群. 结合用户特征分类和动态时间的协同过滤推荐[J]. 计算机工程与应用, 2017, 53(06): 80-84.
[25] 陈婷, 朱青, 周梦溪. 社交网络环境下基于信任的推荐算法[J]. 软件学报, 2017, 28(03): 721-731.
[26] 庞海龙, 赵辉, 李万龙. 融合协同过滤的线性回归推荐算法[J]. 计算机应用研究, 2019, 36(05): 1302-1310.
[27] Mazoure B, Mineiro P, Srinath P, et al. Improving Long-Term Metrics in Recommendation Systems using Short-Horizon Offline RL[D]. Cornell University, 2021.
[28] Boughareb D, Seridi H, Khobizi A, et al. Tag Recommendation for limited access papers annotation[J]. 2019.
[29] Anakolu E, Muter B, Aytekin T. Integrating Individual and Aggregate Diversity in Top- N Recommendation[J]. INFORMS Journal on Computing, 2021, 33(01): 300-318.
[30] 曹景振, 贾新磊, 李松丹. 基于物品的协同过滤算法在 ACM 在线评测推荐系统中的改进及应用[J]. 无线互联科技, 2018, 15(05): 135-139.
[31] 邱爽, 葛万成, 汪亮友. 个性化推荐中基于用户协同过滤算法的优化[J]. 信息技术, 2016, 40(03): 62-72.
[32] 殷佳莉, 江智威, 杨毅. 融合时间衰减函数的改进协同过滤算法[J]. 计算机技术与发展, 2022, 32(04): 170-174.
[33] 赵超, 韩立新, 杨忆. 基于隐含信任关系的概率张量分解推荐算法[J]. 微型电脑应用, 2018, 34(02): 15-18.
[34] 赵文涛, 田欢欢, 冯婷婷. 融合相似度和预筛选模式的协同过滤算法[J]. 计算机科学与探索, 2023, 17(01): 217-227.
[35] Alsaadi F E, Wang Z, Alharbi N S, et al. A new framework for collaborative filtering with p-moment-based similarity measure:Algorithm,optimization and application[J].Knowledge-based systems, 2022, 248(19): 1-10.
[36] Ren J X, Wu Z F. Collaborative Filtering Algorithm Based on Dynamic Trust Attenuation[C]// ICBDT 2020: 2020 3rd International Conference on Big Data Technologies. 2020.
[37] Sachdeva N, Wu C J, Mcauley J. SVP-CF: Selection via Proxy for Collaborative Filtering Data[D]. Cornell University,2021.
[38] 郭均鹏, 王启鹏, 宁静. 基于符号数据与非负矩阵分解法的混合推荐算法[J]. 系统管理学报, 2015, 24(03): 372-378.
[39] 郭亮, 杨兴耀, 于炯. 基于注意力机制和门控网络相结合的混合推荐系统[J]. 计算机科学, 2022, 49(06): 158-164.
[40] Godoy-Lorite A, Guimera R, Moore C, et al. Accurate and scalable social recommendation using mixed-membership stochastic block models[J]. Proceedings of the National Academy of Sciences of the United States of America, 2016, 113(50): 14207-14212.
[41] 于旭, 何亚东, 杜军威. 一种结合显式特征和隐式特征的开发者混合推荐算法[J]. 软件学报, 2022,33(05): 1635-1651.
[42] 单晓红, 王春稳, 刘晓燕. 基于在线评论的混合推荐算法[J]. 系统工程, 2019, 37(06): 130-138.
[43] 钟乾, 王仲君. 基于分布式符号数据的混合推荐算法研究[J]. 计算机仿真, 2021,38(03): 470-475.
[44] Roy A, Banerjee S, Bhatt C, et al. Hybrid Group Recommendation Using Modified Termite Colony Algorithm: A Context Towards Big Data[J]. Journal of Information & Knowledge Management, 2018,17(02): 1850019-1850019.
[45] Kobyshev Kirill, Voinov Nikita, Nikiforov Igor. Hybrid image recommendation algorithm combining content and collaborative filtering approaches[J]. Procedia Computer Science, 2021, 193: 200-209.

中国知网 https://www.cnki.net

[46] Gao Y, Liang H, Sun B. Dynamic network intelligent hybrid recommendation algorithm and its application in online shopping platform[J]. Journal of Intelligent and Fuzzy Systems, 2021,40(5): 9173-9185.

[47] 崔炜荣，杜承烈. 分布式隐私保护单类协同过滤算法研究[J]. 计算机应用与软件，2020，37(08): 307-313.

[48] 黄文明，程广兵，邓珍荣. 基于用户特征的分步协同推荐算法[J]. 计算机应用研究，2017，34(04): 1047-1049.

[49] 冯勇，刘洋，徐红艳，王嵘冰，张永刚. 融合近邻评论的 GRU 商品推荐模型[J]. 现代图书情报技术，2021, 5(03): 78-87.

[50] Xiao Y, Jianyue H, Xin G. An Asynchronous Track-to-track Association Algorithm without Time Alignment[J]. Procedia Engineering, 2015, 99(35): 1120-1125.

[51] 姚佳奇，徐正国，燕继坤. GCN-PU:基于图卷积网络的 PU 文本分类算法[J]. 计算机工程与应用，2021, 57(11): 162-167.

[52] 陶莹，杨锋，刘洋. K 均值聚类算法的研究与优化[J]. 计算机技术与发展, 2018,28(06): 90-92.

[53] Fratrovic T, Li L, Ran B, et al. Traffic speed prediction for highway operations based on a symbolic regression algorithm[J]. Promet - Traffic & Transportation, 2017, 29(04): 433-441.

[54] 廖延娜，李婉. 基于卷积神经网络的桥梁裂缝检测方法[J]. 计算机工程与设计,2021，42008): 2366-2372.

[55] Yousef Kilani, Ahmed Fawzi Otoom, Ayoub Alsarhan, Manal Almaayah. A Genetic Algorithms-Based Hybrid Recommender System of Matrix Factorization and Neighborhood-Based Techniques[J]. Journal of Computational Science,2018,28: 78-93.

[56] 王永，邓江洲，邓永恒，张璞. 基于项目概率分布的协同过滤推荐算法[J]. 现代图书情报技术,2016(06): 73-79.

[57] Shan L, Yao D, Chai J. Research of personalized news recommendation system based on hybrid collaborative filtering algorithm[C]// IEEE International Conference on Computer & Communications. IEEE, 2016.

[58] 李灿，李书琴，蔡骋. 基于 IALM 和填充可信度的协同过滤算法及其并行化研究[J]. 计算机应用研究，2016,33(10): 2954-2976.

[59] 梁佳男. 融合协同过滤算法及其攻击检测模型的研究和设计[D]. 北京邮电大学, 2015.

[60] Lim H, Xie L.A New Weighted Imputed Neighborhood-Regularized Tri-Factorization One-Class Collaborative Filtering Algorithm: Application to Target Gene Prediction of Transcription Factors[J]. IEEE/ACM transactions on computational biology and bioinformatics, 2021,18: 126-137.

[61] 高山，张宏坡，周兵,等. 基于多关系隐式反馈置信度的协同过滤推荐方法, CN110059251A[P]. 2019.

[62] Davis, Benjamin J. K.Curriero, Frank C. Development and Evaluation of Geostatistical Methods for Non-Euclidean-Based Spatial Covariance Matrices[J]. Mathematical geosciences, 2019, 51(6): 767-791.

[63] 宋平，邵清. 使用正态分布函数修正推荐系统相关相似性[J]. 电子科技, 2016, 29(10): 58-61.

[64] 王继克. B/S 模式下高校实验室管理信息系统的研究[J]. 电子技术与软件工程, 2021(01): 159-160.

[65] Miao Liu, Qing Zhang,Qing Jie Zhou. Research on Smart Grid Dispatching Operation System Based on C/S and B/S Mode[J]. Applied Mechanics and Materials, 2013, 2617: 1903-1906.



中国知网 https://www.cnki.net