计算机科学
Computer Science
ISSN 1002-137X,CN 50-1075/TP

《计算机科学》网络首发论文

题目：　基于知识图谱的个性化在线课程推荐方法
作者：　赵蕾，杨雨露，袁波
网络首发日期：　2025-09-28
引用格式：　赵蕾，杨雨露，袁波．基于知识图谱的个性化在线课程推荐方法[J/OL]．计算机科学. https://link.cnki.net/urlid/50.1075.tp.20250928.1239.018

网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

网络首发时间：2025-09-28 19:27:48　网络首发地址：https://link.cnki.net/urlid/50.1075.tp.20250928.1239.018

基于知识图谱的个性化在线课程推荐方法

赵蕾 [1,2]　杨雨露 [1]　袁波 [1]

1 西安财经大学信息学院 西安市 710100
2 智财协同可信计算陕西省高等学校重点实验室 西安市 710100
（leizhao@xaufe.edu.cn）

摘 要 伴随在线学习平台数量激增与课程内容的指数级增长，用户在海量信息中面临着严重的选择困境。由于未能充分挖掘用户与课程之间的交互信息，现有推荐模型推荐结果与用户真实需求存在偏差，严重影响学习体验与资源匹配效率。针对上述问题，提出一种基于增强信息表示的图神经网络推荐模型——IKGCN（Interactive Knowledge Graph Convolutional Network）。该模型通过构建课程知识图谱和用户-课程交互图，借助融合门聚合机制识别并整合两类图结构的互补信息，实现双重信息维度的深度融合，从而有效捕捉用户行为模式的动态特征，显著提升课程语义表征的准确性与推荐系统的智能化水平。实验结果表明，相较于传统基线方法，IKGCN 在多个关键指标上实现了显著突破：在召回率和归一化折扣累积增益（NDCG）等核心评估维度上，分别提升了 4.84%和 9.22%，充分验证了该模型在优化在线教育推荐服务中的有效性与实用性。

关键词：在线教育；用户交互信息；图神经网络；课程推荐；知识图谱

中图分类号 TP391

Personalized Course Recommendation System Based on Knowledge Graph

Zhao Lei[1,2]，Yang Yulu [1]　and　Yuan Bo [1]

1 College of Information, Xi'an University of Finance and Economics, Xi'an, 710100, China

2 Key Laboratory of Intelligent Finance Collaborative and Trusted Computing Higher Education Institutions in Shaanxi Province, Xi'an, 710100, China

Abstract As online learning platforms and course content multiply, users struggle to choose from a sea of information. Existing recommendation models, failing to fully exploit user - course interaction info, deviate from users' real needs, harming learning experience and resource - matching efficiency. To address this, IKGCN (Interactive Knowledge Graph Convolutional Network), a graph neural network recommendation model based on enhanced info representation, is proposed. It builds a course knowledge graph and a user - course interaction graph. Using a gating mechanism, it identifies and integrates complementary info from these two graph structures, fusing dual info dimensions deeply. This enables effective capture of user behavior dynamics, boosting course semantic representation accuracy and recommendation system intelligence. Experiments show IKGCN outperforms traditional baselines: recall rate and NDCG rise by 4.84% and 9.22% respectively, validating its effectiveness in optimizing online education recommendations.

Keywords Online education,User interaction information,Graph neural network,Course recommendation,Knowledge graph

1 引言

在知识经济时代与数字化浪潮的双重驱动下，互联网技术凭借其强大的穿透力，突破了传统教育在时间与空间维度上的桎梏，与在线教育深度融合，推动教育资源实现跨区域、跨平台的开放共享。中共中央、国务院印发《教育强国建设规划纲要（2024—2035年）》，该纲要明确要求以教育数字化开辟发展新赛道、塑造发展新优势，要创造出更加适合每一个学生特点的教育模式，即需具备个性化特征。国内外各类在线教育平台如雨后春笋般涌现，为用户提供了海量学习资源和便捷学习途径，满足了人们日益增长的自我提升需求。

然而，伴随在线学习平台的蓬勃发展，网络课程数量急剧膨胀，用户在面对庞大的知识选择时陷入“信息过载”困境[1]，无法快速选择出适合自己的学习资源。而且当前多数在线学习平台仅按类别热度排序，无法关联学习历史或挖掘用户潜在兴趣，致使推荐存在偏差，因此提供精准的个性化推荐迫在眉睫[2]。研究者把推荐系统应用于在线课程平台，有效解决了课程推荐的问题。童家玮[3]及其团队提出了一种基于协

同过滤算法的个性化学习平台设计方案。该方案旨在通过分析学生的学习行为、兴趣偏好和课程评价数据，为每位学生提供了个性化的课程推荐服务。毛雷[4]及其团队通过构建课程结构模型，改进已有的协同过滤推荐算法，为在线学习平台设计和实现了一个推荐系统。然而传统在线课程推荐模型忽视用户与课程之间的交互信息，导致推荐的课程与用户实际需求脱节，推荐准确度大打折扣，例如，Zhang[5]及其团队提出一种基于知识分组与聚合网络的课程推荐系统（KGAN），通过整合多学科课程资源并结合学习者的个性化特征数据，实现了精准化的课程智能推荐，但忽略了用户个性化需求。类似地，歹杰[6]设计的基于图学习的智慧课程推荐系统，聚焦在线教育平台推荐系统面临的关键问题，通过构建课程知识信息融合模型，采用分层流水线处理机制，显著改善了系统冷启动现象。这些方法侧重系统性地分析用户行为数据与课程内容信息，构建多维度的特征指标体系，进而实现个性化的智能推荐。

什么是"系统冷启动现象"
推荐系统要想给用户推荐合适的课程，通常需要两类信息：

用户信息：兴趣、行为记录、浏览/学习历史

课程信息：内容特征、标签、关联关系

用户与课程之间的交互数据：点击、收藏、学习时长等

冷启动就是这些信息不足导致系统无法判断"推荐什么"的情况。

还有学者基于学习行为序列的建模方式有效捕捉用户的知识偏好和认知特征，为个性化推荐提供数据支撑。例如，Tang[7]及其团队采用长短期记忆神经网络（LSTM）构建学习者行为分析模型，基于学习者课程交互序列数据，实现对其潜在学习兴趣课程的预测。Zhang[8]提出了一种融合递归神经网络与内容分析技术的课程推荐方法，对用户已选修课程序列进行深度特征提取，以捕捉学习者的兴趣偏好，结合基于内容的技术挖掘课程之间的关系，从而实现课程个性化推荐。然而，当前主流在线课程推荐模型多聚焦于单一辅助信息的应用，尚未形成对多源异构辅助信息的系统性整合机制。为进一步提升在线课程推荐的精准度，实现用户需求与课程资源的深度个性化匹配，需构建多维度辅助信息融合的学习表示增强框架，通过跨模态信息互补与特征协同优化，突破单一信息源的表征局限，从而在动态交互场景中实现更具语义理解能力的推荐决策。

本文提出增强信息表示的图神经网络推荐模型（IKGCN）。通过构建用户课程交互图和知识图谱，深度挖掘其中的潜在关联信息，利用门控机制融合双重信息，精准捕捉用户行为模式，强化课程信息表征，进而实现更贴合用户个性化需求的课程推荐。本研究不仅在理论上丰富了图神经网络在推荐系统中的应用，也为在线教育平台优化推荐服务提供了实践指导。

本文的主要工作如下：

（1）构建课程知识图谱和用户-课程交互图，并进行图嵌入与实体聚合。

（2）设计并实现一个门控聚合单元，用于接收两种课程表示向量，并利用双重物品表示向量将它们融合在一起；使用最终的物品表示向量预测用户的偏好，并据此做出内容推荐。

（3）实验结果表明，本文提出的 IKGCN 模型相较于已有的基线模型在 Recall 和 NDCG 上有明显提升，有效提高了推荐的准确性。

2 相关工作

2.1 推荐算法

现有的课程推荐系统主要有以下几种：1）基于内容的推荐算法：这类算法通过分析课程文本描述、关键词体系及教师背景等内容特征，构建与用户历史偏好相似的语义匹配模型。郝海洪[9]等学者将内容推荐算法应用于大学生网络思想政治教育领域，从个性化需求理解、内容供给质量提升、社交互动促进及跨平台合作拓展四个维度，构建了教育内容供给的优化路径，相关成果为高校网络思政教育提供了理论与实践支撑。王光[10]等人提出的加权粒度序列推荐算法具有代表性，该方法以内容特征为核心，通过对不同粒度的内容信息赋予差异化权重，构建序列推荐模型，为基于内容的推荐在序列场景下的应用提供了有效思路，显著提升了推荐结果与用户内容偏好的匹配度。李忠俊[11]等人提出了一种通过同构化整合思路构建

的推荐系统模型，该模型以内容特征为核心，有效发挥了基于内容推荐的可解释性优势，为提升推荐效果提供了切实可行的方案。基于内容的推荐算法核心优势在于对冷启动场景的适应性较强，但存在双重局限：一是难以挖掘用户潜在兴趣偏好，二是推荐效果高度依赖课程内容描述的准确性。2）协同过滤推荐算法：基于用户的协同过滤推荐算法依据“人以群分”原理，通过三步实现：首先提取用户偏好信息，其次基于相似度度量构建用户关联矩阵并定位邻居用户，最终依据相似用户评分生成推荐列表并过滤已交互项目。张健安[12]等人提出基于用户伪强概念外延集合的近邻划分方法，针对不同类型的用户设计差异化相似度计算模型，通过融合均方差影响因子优化评分预测。基于用户的协同过滤推荐算法依赖群体行为预测，不依赖项目特征，但在新用户冷启动或数据稀疏场景下，因缺乏偏好信息难以准确计算用户相似度，导致推荐效果不佳。因此研究者又秉持“物以类聚”的思想，提出基于项目的协同过滤推荐算法。该算法先构建项目相似度矩阵，再通过目标用户历史交互项目与候选项目的关联度评分，最终筛选高评分项目形成推荐，剔除目标用户已选项目，把剩余项目推荐给目标用户。张萱[13]等人引入项目流行度惩罚系数优化相似度计算，利用优化后的相似度寻找目标项目的最近邻；构建基于时间衰减因子的兴趣模型，根据用户评分时间与周期赋予时序权重，实现兴趣衰减效应的量化表征。类似研究还有文献将该算法应用于企业工程场景问题求解[14]，还有文献提出耦合对象相似度模型，通过捕获项目特征频率分布与依赖关系提升推荐精度。然而，两类协同过滤算法均面临冷启动与数据稀疏性的共性挑战[15]。

随着推荐系统研究的不断深化，融合多元技术思路的方法持续涌现，共同推动着推荐精度与可解释性的双重提升。矩阵分解（MF）作为协同过滤推荐的经典方法，核心在于通过分解用户-课程交互矩阵学习低维隐向量，借助向量内积预测用户偏好，仅依赖交互数据即可实现个性化推荐，在领域发展中奠定了重要基础[16]。在此基础上，协同知识库嵌入（CKE）开创性地将知识图谱嵌入与矩阵分解框架结合，通过 TransR 模型显式编码物品语义关联，有效利用结构化知识提升推荐准确性，为跨域信息融合提供了可扩展的解决方案[17]。

知识图谱卷积网络（KGCN）借助图卷积网络（GCN）有效聚合知识图谱邻域特征，显著增强物品语义表征能力，为推荐系统引入结构感知的信息传递机制，在整合多源知识提升推荐精度方面具有重要方法学价值[18]。而知识图谱注意力网络（KGAT）则在其基础上引入注意力机制，通过加权聚合邻居特征同步建模用户-物品交互与知识图谱关系。该机制依据邻居节点与中心节点的关联紧密程度、语义贡献度等动态分配权重，以精准强化关键信息捕捉，既提升了语义关联的精准性，又增强了推荐结果的可解释性。这种对重要信息的差异化关注，为后续模型处理复杂关联、提升特征利用效率提供了重要思路，成为该研究方向的关键突破点[19]。

在异构信息融合领域，协作知识感知注意网络（CKAN）虽构建异构传播框架融合用户-物品二部图与知识图谱信息，提升了用户-物品关联建模能力，但对跨图结构信息的整合缺乏自适应机制[20]；相比之下，知识图谱意图网络（KGIN）借助关系感知聚合机制提取知识图谱中的远距离关联特征，同时结合用户意图建模行为序列，能够有效捕捉用户兴趣与知识结构的深层关联，增强了推荐的语义可解释性，尤其在复杂场景下的推荐表现更为突出[21]。

聚焦于基于交互图的建模方向，神经图协同过滤（NGCF）通过多层图卷积操作深度融合用户-物品间的高阶交互信息，强化了对复杂关联模式的捕捉能力，成为该领域的经典方法[22]；而轻量级图卷积网络（LightGCN）则通过简化传统 GCN 结构，仅保留邻

居聚合操作，在降低计算复杂度的同时仍能高效学习用户和物品嵌入，在推荐任务中表现优异，其轻量化设计为大规模推荐系统的落地提供了有力支撑[23]。

此外，PCGNN 作为针对图数据类别不平衡问题的图神经网络算法，虽主要应用于欺诈检测等领域，但其通过“Pick（采样平衡子图）-Choose（筛选有效邻居）-Aggregate（聚合信息）”三部分结构提升少数类节点识别能力的设计思路，也为推荐系统处理稀疏交互等不平衡场景提供了有益借鉴，为解决推荐领域长期存在的冷启动等难题开辟了新的思路[24]。

受上述推荐模型创新思路的启发，在推荐系统研究与实践领域，神经协同过滤、多层感知机等算法不断涌现，结合时间序列分析和多模态特征融合，构建具备动态学习能力与个性化推荐精度的智能推荐系统。胡金涛[25]等人提出了一种新颖的基于自注意力的图对比学习推荐算法（AttGCL）。一方面，集成的自注意力机制能够增强用户与项目之间的联系，从而更精确地捕捉用户偏好和个体差异性。另一方面，采用的 ICL 损失函数有效控制正样本和负样本的重要性，从而更好地对齐全局和局部的表示。该方法保留了关键的用户-项目交互语义，使得模型不仅更准确地反映用户偏好，还提升了推荐效果。类似地，研究者以“个性化学习资源推荐实现”与“推荐效果评估”为双核心，对现有研究进行了多维度系统性综述，为算法优化提供了理论框架[26]。

2.2 图神经网络

图神经网络（Graph Neural Network,GNN）的核心聚合机制：先从图结构选目标节点，按预设邻近距离准则，筛选固定数量邻近节点构成邻域集合；再整合中心节点邻域特征信息，基于第 l 层中心节点的邻域信息迭代更新第 $l+1$ 层中心节点的信息表示。聚合过程如图 1 所示，中心节点以黑色标注，浅灰色节点是与中心节点直接关联的第一层邻居节点，是根据度量计算筛选得来的，第二层邻居节点用深灰表示。用于推荐系统时，GNN 主要经邻居聚合、节点更新、预测三个步骤完成任务。本文主要使用该模块处理用户-课程交互图，提取其初始特征表示，并通过多层图卷积操作学习节点的高阶表示。

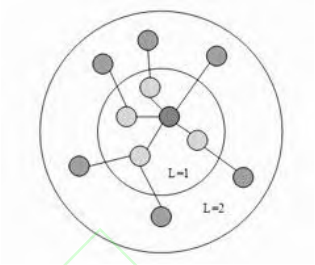

图 1 聚合过程
Fig.1 Aggregation process

（1） 邻居聚合

邻居聚合这一过程通过逐轮迭代的方式，将相邻节点的特征数据进行融合处理，从而实现对图结构信息的有效传播。

以用户节点 u 聚合多个邻居节点 i 为例，具体表达如式 1：

$$n_u^{(l)} = Aggregator_l(\{e_i^l, \forall i \in N_u\}) \quad (1)$$

式中，e_i^l 表示第 l 层节点 i 的表示，$n_u^{(l)}$ 表示第 l 层节点 u 邻居的聚合表示，N_u 表示节点的邻居的集合，$Aggregtor_l$ 表示第 l 层的聚合函数。

模型对用户-课程交互图的每个节点的邻居特征进行加权求和，聚合的过程中对图加自环并进行对称归一化，允许节点保留自身特征并确保节点的特征尺度一致。

（2） 节点更新

节点更新是指经过聚合处理的邻域特征向量与中心节点的初始表征进行整合，随后通过多轮迭代计算，使得每个实体节点能够逐步吸收并整合其拓扑邻域的结构化信息。以用户节点为例，节点更新可以总结为以下的公式 2：

$$e_u^{(l+1)} = Updater_l(e_u^{(l)}, n_u^{(l)}) \quad (2)$$

式中，$e_u^{(l)}$ 表示第 l 层节点 u 的表示，$n_u^{(l)}$ 表示第 l 层节点 u 邻居的聚合表示，$Updater_l$ 表示第 l 层更新操作的函数。

该部分将聚合后的邻居用户-课程交互特征与当前节点特征相融合，通过非线性变换生成新的节点表示，使聚合后的节点特征适配模型需求，增强模型表达力。

（3） 预测

构建推荐系统时，节点表征获取至关重要。通常以 GNN 最终层节点嵌入作为最终表征，因为 GNN 不同层级可捕获不同粒度结构信息：浅层保留节点局部特征，深层融合邻域特征。其中，物品节点高层表征反映属性特征，用户节点高层表征体现兴趣偏好。为利用各层信息，部分研究探索多种整合方法。为了充分利用不同层次的信息，一些研究采用了不同的方法来整合来自各 GNN 层的信息，以用户节点为例：

均值池化通过对各 GNN 层用户节点表征取平均值来得到最终表征，详见公式 3：

$$e_u^* = \frac{1}{L+1}\sum_{l=0}^{L} e_u^{(l)} \qquad (3)$$

式中，e_u^* 是用户节点的最终选择，$e_u^{(l)}$ 表示第 l 层节点 u 的表示，该方式平等对待各层信息。

求和池化则是将各层用户节点表征直接相加，详见公式 4：

$$e_u^* = \sum_{l=0}^{L} e_u^{(l)} \qquad (4)$$

该方式通过累加操作获取最终结果。

加权池化在整合时引入了可学习的参数，根据各层信息的重要程度赋予不同权重，详见公式 5：

$$e_u^* = \frac{1}{L+1}\sum_{l=0}^{L} \alpha^{(l)} e_u^{(l)} \qquad (5)$$

可学习参数使得模型能够自适应地调整各层信息的贡献度。

连接方法将各层用户节点表征按顺序拼接起来，得到维度更高的向量作为最终选择，详见公式 6：

$$e_u^* = e_u^{(0)} \| e_u^{(1)} \| \ldots \| e_u^{(L)} \qquad (6)$$

其核心价值在于完整保留了各网络层的原始特征信息，从而实现了信息的无损传递。

使用用户和课程的最终表示进行内积操作，以预测用户与特定课程进行交互的概率，如公式 7 所示：

$$\hat{y}_{ui} = (e_u^*)^T e_i^* \qquad (7)$$

式中，e_u^* 是用户节点的最终选择，e_i^* 是课程节点的最终表示，$\hat{y}_{ui}$ 表示最后得到的概率在 0-1 内取值。

该模型以用户节点的最终表征为基础，整合各层特征生成用户/课程的语义向量，再通过内积计算某用户与某课程的交互概率。

然后，将最终的特征表示作为模型输入，并以图结构数据作为监督标签，进而构建相应的损失函数进行优化。

3 增强信息表示的图神经网络推荐模型

核心思想是：
在聚合邻居信息时，引入“门”（gate）来控制不同邻居信息的重要程度，从而让模型更聪明地选择要吸收哪些信息、忽略哪些噪声。

3.1 模型框架

门控（Gate）来自 RNN（如 LSTM、GRU）的思想，本质上是一个 0~1 之间的权重，用来控制信息流动。
你可以把它理解为：
模型给每个邻居分配一个“通过多少信息”的开关。
数学上通常是一个 sigmoid：
$g=\sigma(Wx+b)g$
值。

针对知识图谱推荐系统忽略用户交互信息的问题，本文提出增强信息表示的图神经网络推荐模型（Interaction-Knowledge Graph Convolutional Network，IKGCN）。IKGCN 与以往物品表示仅基于知识图谱聚合的方法不同，IKGCN 引入了门控聚合机制，通过自适应权重分配实现对课程知识图谱和用户-课程交互图的有效区分与整合，从而更有效地捕捉用户的偏好。首先分别构建课程知识图谱和用户-课程交互图，接着使用 TransE 模型对知识图谱实现图嵌入并对知识图谱中的实体进行聚合，然后采用图卷积神经网络模型 GCN 对用户-课程交互图实现聚合，最后该模型设计并使用一个融合门聚合模块来区分 GCN 模型聚合后的课程信息表示和知识图谱聚合后的课程信息表示，随后采用自适应加权方法对两类表征进行融合。这种双重表征机制不仅充当了跨模态信息的交互桥梁，而且通过特征互补显著提升了物品表征的准确性和信息丰富度，为下游任务提供了更优质的输入特征。本文提出的 IKGCN 模型整体框架图如图 2 所示。该模型由课程知识图谱、用户-课程交互图、融合门聚合和

预测四部分组成：（1）知识图谱表示。构建知识图谱并对其进行图嵌入，然后对实体进行聚合更新向量，得到新的实体表示；（2）用户-课程交互图表示。构建用户-课程交互图并通过图神经网络模型 GCN 对用户-课程交互图进行特征聚合，更新向量表示，得到新的用户-课程交互表示。（3）融合门聚合。利用门控聚合机制来区分知识图谱和用户-课程交互图上的信息表示，并将二者融合为双重信息表示，以提高对用户偏好建模的准确度。（4）预测。在经历多次卷积之后，生成用户 u 和物品 i 的最新表示，将他们相加作为最终的用户表示和物品表示。对用户和物品的最终表示进行内积操作，可得到用户对各课程的偏好得分，按得分高低对课程进行排序，选取高分课程作为推荐结果，因为得分越高，表明课程与用户需求和兴趣的匹配度越高，以此实现精准推荐。模型框架图如图 2 所示。

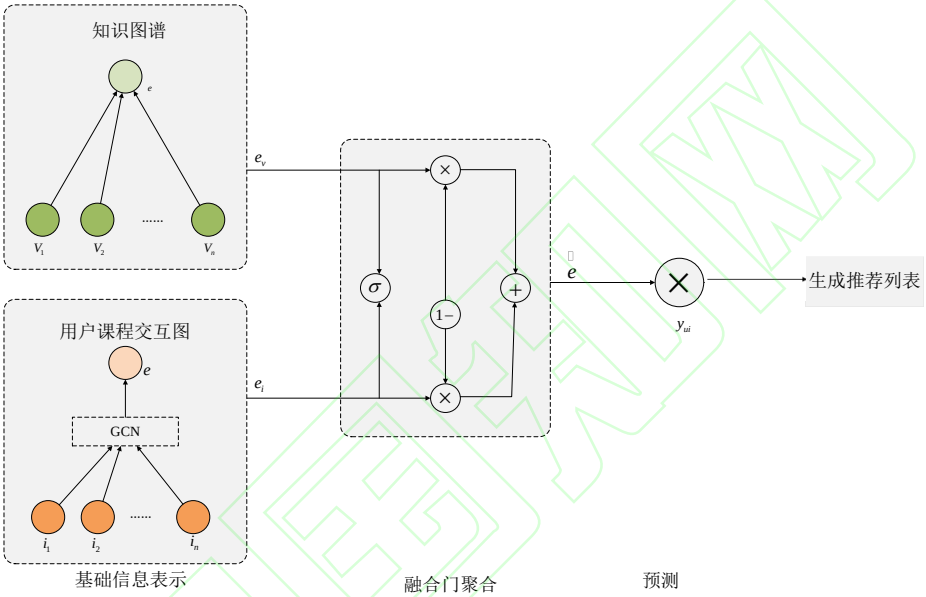

图 2IKGCN 模型框架图
Fig.2 IKGCN Model framework diagram

3.2 课程知识图谱

3.2.1 课程知识图谱构建

（1）知识获取

本文使用 MOOCCube 数据集构建知识图谱，该数据集是由清华大学团队从学堂在线中获取的结构化数据，包含了 706 门真实的在线课程，3 万个教学视频，19 万余名学生客户以及 800 万余条交互信息等。为了构建实体间的关联网络，将该数据集处理成结构化的知识体系。本文在实体识别方面，对课程信息、专业名称、教师信息、高校名称等关键要素进行实体识别，提取出课程信息及其相关属性四个，专业名称的属性两个，教师信息的属性三个，高校名称的属性三个。在关系提取环节，首先对 MOOCCube 数据集进行预处理，随后运用基于规则的关系提取方法对文本进行遍历分析，识别符合条件的实体对，进而抽取出实体间的关联关系。例“计算机网络属于计算机”，实体为计算机网络、计算机，关系为“属于”，最终将关系分为授课老师、开设大学、所属专业，对于关系不设置属性。详细的知识图谱属性见下表 1。

表 1 知识图谱属性

Table 1 Attributes of knowledge graph

实体类	属性名称	属性类别	实体类描述	值域
课程	课程 ID	数据类	课程 ID	Int
	课程名称	对象类	课程名称	课程名称
	章节数	数据类	课程章节数量	Int
	视频数	数据类	课程视频数量	Int
	关键词	对象类	课程的关键词	关键词
学校	学校 ID	数据类	学校 ID	Int
	学校名称	对象类	学校名称	学校名称
	学校简介	对象类	学校简介内容	学校简介
老师	老师 ID	数据类	老师 ID	Int
	老师姓名	对象类	老师姓名	老师姓名
	老师简介	对象类	老师简介内容	老师简介
专业	专业 ID	数据类	专业 ID	Int
	专业名称	对象类	专业名称	专业名称

（2）三元组构建

知识图谱由实体-关系-实体三元组 (h,r,t) 组成，例如，“北京大学”开设“计算机科学与技术”，构成三元组的头实体为北京大学，尾实体为计算机课程与技术，关系为开设[24]，如表 2 所示三元组标签列表。

表 2 三元组标签示例

Table 2 Examples of triple labels

头实体	关系	尾实体
课程	属于	专业
大学	开设	课程
老师	教授	课程

（3）知识图谱构建

Yu 等提出面向在线教育领域的大规模数据仓库 MOOCCube 数据集[28]。其数据来源于学堂在线平台，涵盖多种丰富的教学资源，广泛应用于课程推荐领域，为在线教育领域的算法验证和应用研究提供了丰富的数据支撑。本文通过对该数据集进行知识抽取和三元组构建，采用 Neo4j 图数据库来存储图谱数据，构建出课程知识图谱。课程知识图谱详情请见图 3 所示。

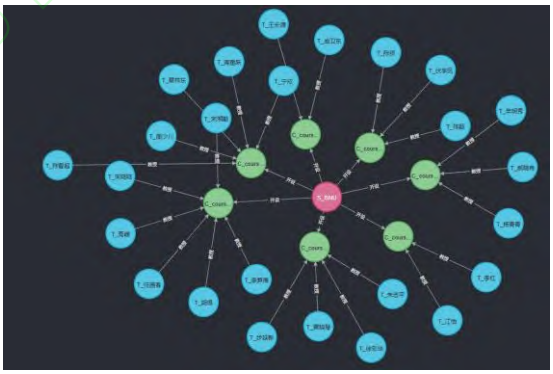

图 3 知识图谱可视化

Fig.3 Visualization of knowledge graph

3.2.2 课程知识图谱嵌入

本模型采用基于距离的嵌入模型 TransE。TransE 模型将知识图谱中的实体和关系向量化且表示在同一向量空间中，如图 4 所示。给定一个事实三元组 (h,r,t)，关系 r 表示一个平移向量，通过不断调整 h，r，t，使得从头实体 h 加到关系向量 r 上等于尾实体 t，即 $h+r\approx t$ 成立[28]。

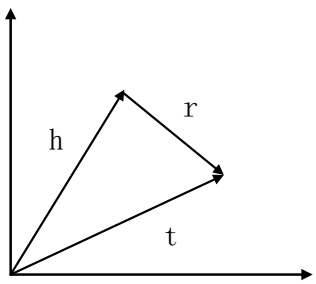

图 4 TransE 模型
Fig.4 TransE model

TransE 模型为每个三元组定义了一个评分函数，用来衡量一个三元组是否合理。评分函数如式 8 所示：

$$f(h,r,t)=\|h+r-t\|_p \qquad (8)$$

式中，p 取 1 或 2，分别对应 $L1$ 或 $L2$ 距离。

同时对于每个嵌入三元组的关系设置权重向量，使用 $L1$ 距离如公式 9 所示：

$$w_i=\exp(-|d_i|) \qquad i=1,2...n \qquad (9)$$

式中，i 表示每个实体的嵌入维度，w_i 表示每个三元组的嵌入向量。

例如，三元组（Use1，评分，课程 1），对其进行嵌入可得到：

头实体 User1 的嵌入向量：[0.10341807 -0.63540728 -0.75618979 0.08569924 -0.07996833]

关系评分的嵌入向量：[0.54401275 0.3727374 0.31516604 -0.35146436 0.58503002]

尾实体课程 1 的嵌入向量：[0.62640338 -0.26077825 -0.45153431 -0.29323331 0.49974445]。

3.2.3 课程知识图谱实体聚合

在知识图谱完成嵌入之后，通过对知识图谱中的课程实体的邻居网络进行聚合，更新知识图谱中课程实体的表示，具体聚合函数如公式 10 所示：

$$\tilde{e}=\frac{1}{|N(i)|}\sum_{(i,j,r)\in\varepsilon}(e_j \square w_r) \qquad (10)$$

式中，i 为头实体，j 为尾实体，r 为关系，ε 为边合集，e_j 为实体 j 的嵌入向量，w_r 为关系 r 的嵌入向量，$N(i)$ 为实体 i 的邻居集合。

通过对知识图谱上的实体进行聚合得到具有知识图谱语义的关系的信息表示。

对三元组（Use1，评分，课程 1）聚合后的更新表示：

User1 新表示：[0.340773 -0.097203 -0.142217 0.103065 0.292351]

课程 1 新表示：[0.056261 -0.236844 -0.238323 -0.030118 -0.046884]

评分关系的信息表示验证：

h+r：[0.647431 -0.26267 -0.441024 -0.265765 0.505062]

t：[0.626403 -0.260778 -0.451534 -0.293233 0.499744]

3.3 用户-课程交互图

3.3.1 用户-课程交互图的构建

用户-课程交互图由节点和边组成，节点包括用户节点集合 $U=\{u_1,u_2,...,u_n\}$ 与课程节点集合 $V=\{v_1,v_2,...,v_m\}$，边上有权重，主要由该课程对该节点的交互强度决定。

(1)从交互数据到邻接矩阵

将上述用户-课程交互图处理为用户-课程交互数据，每行包含（用户 ID，课程 ID，交互权重）。首先将用户-课程交互数据转换为稀疏邻接矩阵，然后对课程 ID 偏移，使其不与用户 ID 重叠，最后对邻接矩阵添加转置边，构成对称矩阵。

(2)添加自环矩阵

需要构建包含自环的邻接矩阵 $\tilde{A}$，具体公式如公式 11 所示：

$$\tilde{A}=A+I \qquad (11)$$

式中 A 为用户－课程交互图矩阵，I 为单位矩阵。

3.3.2 用户-课程交互图的聚合

基于用户节点与课程节点之间的评分构建用户-课程交互图，并利用图神经网络模型 GCN 对用户课程交互信息进行表示学习，即基于第 l 层中心节点的邻域信息迭代更新第 $l+1$ 层中心节点的信息表示[30]。

具体公式如式 12 所示：

$$H^{(l+1)} = \sigma(\tilde{D}^{-\frac{1}{2}}\tilde{A}\tilde{D}^{-\frac{1}{2}}H^{(l)}W^{(l)}) \qquad (12)$$

式中，$H^{(l)}$ 表示第 l 层的节点信息表示，经过图卷积层后得到新的表示，$\tilde{A}$ 表示包含了自环矩阵的图邻接矩阵，$\tilde{D}$ 表示对应的度矩阵，$W^{(l)}$ 表示第 l 层的可学习的权重矩阵，σ(·)表示非线性激活函数。

通过堆叠多个图神经网络聚合层来对用户物品交互信息和用户物品的特征信息进行聚合，聚合邻居信息来更新用户课程的特征信息，最终输出得到用户课程的信息表示。

3.4 融合门聚合

通过前两部分获得两种不同类型的物品信息表示：（1）具有知识图谱信息的物品信息表示 e_v，（2）具有交互信息的物品信息表示 e_i。受到 GRU 中自适应更新模型不同部分的门控机制以及以往研究的启发[31]，本文设计了一个融合门聚合模块来自适应地从两种物品表示中提取有用信息。将物品的知识图谱表示 $e_v^{(l)}$ 和交互信息表示 $e_i^{(l)}$ 送入融合门 $g_i^{(l)}$ 中，可以获得融合了知识关联的交互信息的双重物品表示 $\tilde{e}$，并且融合门单元 $g_i^{(l)}$ 可以自适应的调整这两种信息的贡献程度，调整的方式主要为使用门控循环单元（GRU）模型，将知识图谱和交互图的特征进行聚合。在聚合过程中，门控机制会根据输入信息动态调整融合比例，使得融合后的特征既能保留知识图谱中的语义信息，又能体现交互图中的用户行为信息。具体公式如式 13 所示：

日？

加权？

$$\tilde{e}_i^{(l)} = g_i^{(l)} \square e_v^{(l)} + (1 - g^{(l)}) \square e_i^{(l)} \qquad (13)$$

式中，$g_i^{(l)}$ 表示融合门聚合单元，$e_v^{(l)}$ 表示具有知识图谱信息的物品表示，$e_i^{(l)}$ 表示具有交互信息的物品表示。通过融合门聚合得到增强信息的物品表示。

融合门聚合示例如图 5 所示。

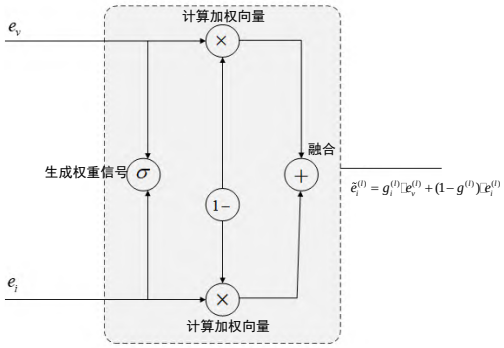

图 5 融合门聚合示例
Fig.5 Example of Fusion Gate Aggregation

3.5 预测和优化

在经历多次卷积之后，生成用户 u 和物品 i 的最新表示，然后将他们相加作为最终的用户表示和物品表示。

最终用户表示如式 14 所示：

$$e_u^* = e_u^{(0)} + \cdots + e_u^{(L)} \qquad (14)$$

式中，$e_u^{(L)}$ 表示用户 e_u 第 L 层的表示，e_u^* 为最终用户表示。

最终物品表示详见公式 15：

$$\tilde{e}_i^* = \tilde{e}_i^{(0)} + \cdots + \tilde{e}_i^{(L)} \qquad (15)$$

式中，$\tilde{e}_i^{(L)}$ 表示融合物品第 L 层的表示，$\tilde{e}_i^*$ 为最终物品表示。

为了预测用户选择该物品的可能性，对用户和物品的最终表示进行内积操作，具体公式如公式 16 所示：

$$y_{ui} = e_u^{*T} \tilde{e}_i^* \qquad (16)$$

式中，y_{ui} 表示用户与该预测物品的相关性得分。

Adam 优化器是深度学习里最常用、也最"聪明"的优化算法之一。它的名字来自 Adaptive Moment Estimation（自适应矩估计），核心思想是：

结合动量（Momentum）和 RMSProp 的优点，让每个参数都拥有自己的自适应学习率，从而更快、更稳定地收敛。

IKGCN 采用 Adam 优化器来学习模型参数，在每一步迭代中都会利用梯度的一阶矩和二阶矩的估计来调整参数的更新幅度，具体如公式 17 所示：

$$g_t = \nabla_\theta f(\theta_t) + \lambda \theta_t \qquad (17)$$

式中，θ_t 表示为模型参数，$f(\theta_t)$ 表示为损失函数，λ 表示为设置的梯度变化率。

4 实验设置与结果分析

4.1 实验设置

4.1.1 实验环境

本文实验环境为 Windows10 操作环境，处理器 Nvidia GeForce 1050 Ti GPU，基于深度学习框架 Pytorch 1.10.1，编程语言为 Pyhton 3.11。

4.1.2 实验数据

实验使用 MOOCCube 数据集进行实验评估，数据的具体内容见表 3。本实验将数据随机划分为 80%的训练集、10%的验证集和 10%的测试集。

表 3 MOOCCube 数据集
Table 3 MOOCCube Dataset

数据信息属性	数量
用户数量	199199
课程数量	706
视频数量	38181
交互信息数量	>8000000

本实验将数据集中所有样本及模型的嵌入向量维度统一配置为 64 维。在网络参数初始化阶段，采用 Xavier 方法对各层权重进行赋值，该方法能够有效平衡各层梯度分布，从而提升模型训练的收敛效率。在优化策略方面，选用 Adam 优化算法对目标函数进行迭代更新，并将批量训练样本数（batch size）设定为 1024。学习率的初始值配置为 0.01，其动态调整区间控制在 0.0001 至 0.01 之间，以实现训练过程的稳定优化。

4.1.3 评价指标

本文选用推荐方法中常用的召回率(Re*call@k*)、和归一化折损累计收益（*NDCG@k*）（k为推荐列表的长，即系统给出的推荐结果的数量）作为评估指标来衡量所提方法的推荐性能，如式（18）-（19）所示：

$$\mathrm{Re}call = \frac{\sum_u |R(u) \cap T(u)|}{\sum_u |T(u)|} \tag{18}$$

式中，$R(u)$ 表示用户 u 推荐的项目，$T(u)$ 表示用户 u 在测试集上喜欢的项目集合。

$$ndcg = \frac{1}{|U|} \sum_{u \in U} \frac{\sum_{i=1}^{K} \frac{2^{rel_i} - 1}{\log_2(i+1)}}{\sum_{i=1}^{K} \frac{2^{rel_i^*} - 1}{\log_2(i+1)}} \tag{19}$$

式中，rel_i 表示排名第 i 个物品的相关性评分，rel_i^* 表示理想排序中第 i 个物品的相关性评分，$|U|$ 表示用户的集合。

4.2 实验结果与分析

4.2.1 基线方法

本文选取的基线方法主要包括三大类：不依赖知识图谱的传统方法、基于嵌入技术的表征学习方法，以及基于图神经网络（GNN）的结构化建模方法。具体包括 MF、CKE、KGCN、KGAT、CKAN、KGIN、NGCF、LightGCN、PCGNN 模型，这一分类体系从数据依赖、模型架构和核心技术等维度，涵盖了当前推荐领域的主流研究范式，可为后续的对比实验和性能分析提供较为全面的基准参考。

4.2.2 性能实验及结果分析

本文 IKGCN 模型与基线模型方法比较结果见表 4，其中默认 K=5，即需要从邻居课程节点处获取五个课程来进行推荐。

表 4 模型总体性能比较
Table 4 Comparison of overall model performance

	MOOCCUBE	
模型	Recall	NDCG
MF	0.1233	0.0876
CKE	0.1278	0.0923
KGCN	0.1193	0.0789
KGAT	0.1089	0.0845
CKAN	0.1136	0.0965
KGIN	0.1385	0.1041
NGCF	0.1205	0.0935
LightGCN	0.0835	0.0602
PCGNN	0.1380	0.0785
IKGCN	0.1452	0.1137

由表 4 实验结果可以看出，由于未引入知识图谱，基线模型仅通过用户与课程嵌入特征向量的内积表示特征难以有效捕获高阶复杂关系，所以整体性能欠佳。在知识图谱增强的基线模型中，KGCN 在

MOOCCube 数据集上的表现也不尽如人意，这主要归因于两个方面：一方面该模型虽然能够捕捉课程间的关联，却忽视了用户与课程间的交互关系；另一方面模型参数量过大易导致过拟合现象，影响模型的泛化性能。而且，与神经协同过滤（NGCF）相比，KGCN 在课程数据集上的性能差距显著，这一结果证实了 KGCN 在课程知识图谱语义信息提取方面存在局限性，其根本原因在于未能有效建立用户与课程之间的关联路径。

通过对比可知，IKGCN 模型的推荐性能要好于主流的基线模型，在 MOOCCube 数据集上的 Recall 和 NDCG 指标上对比性能最好的基线模型提升了 4.84% 和 9.22%，其主要原因归功于创新的融合门控聚合模块，能够自适应地从知识图谱和用户－课程交互图中筛选出关键特征，实现了对双重信息源的有效整合，进而构建出更具表达力的双重信息表示，更精确地刻画用户的潜在行为特征，克服了传统图神经网络模型在处理稀疏数据方面的局限性。

4.3 消融实验和结果分析

为了研究 IKGCN 融合门聚合模块对于模块的性能影响，在 MOOCCube 数据集上进行消融实验，本次实验共构建了两种不同的 IKGCN 变体：（1）传统图神经卷积网络模型 GCN；（2）采用矩阵加法替换融合门聚合模块的推荐模型，称为 IKGCN+，实验结果如图 6 所示。

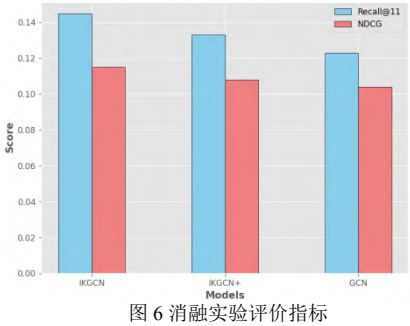

图 6 消融实验评价指标
Fig.6 Evaluation indicators for ablation experiments

从图 6 实验结果中可以看出，当移除融合门聚合模块后，由于无法平衡知识图谱与交互图之间的比例关系，传统图神经网络模型 GCN 的性能出现显著下滑；进一步对比 IKGCN+模型发现，该模型虽然通过简单相加的方式融合了知识图谱与交互图中的课程表示，在一定程度上增强了特征表达能力，但由于缺乏对两种课程表示向量的有效区分机制，导致用户节点表示质量欠佳，难以充分发挥异构信息融合的优势。而本文所提模型，在召回率和归一化折损累计收益上均取得不错的得分，主要原因在于融合门聚合机制能够平衡知识图谱与用户-课程交互图之间的权重，使得模型可以合理利用来自知识图谱和交互图的信息，发挥两者的优势。

4.4 有效性分析

为进一步验证融合用户课程交互信息与课程知识图谱信息的双重表示方法的有效性，设计了对比实验：实验组采用双重信息表示方法，对照组则使用传统单一信息表示方法。其中，对照组仅采用课程知识图谱信息，通过公式 10 获得的物品表示进行用户表示学习，而未整合用户课程交互信息。通过对比两组实验结果的差异，可以验证双重信息融合策略的有效性。实验结果如表 5 所示。

表 5 双重信息表示的研究成果
Table 5 Research achievements of dual information representation

	Recall	NDCG
单一信息表示	0.1251	0.1094
双重信息表示	0.1452	0.1137

表 5 的实验结果显示，当模型仅采用知识图谱这单一信息表示时，其召回率为 0.1251，NDCG 为 0.1094；而添加上用户与课程的交互信息后，各项性能指标均有所提高，其召回率提升 16.1%，NDCG 提高 4%。主要原因在于课程实体具有双重语义特征，若仅采用知识图谱单一表征手段，难以完整地描述其语义内涵。相比之下，知识图谱和用户课程交互双重信息表示机制不仅能够系统整合课程的多维属性特征，同时还能准确刻画课程间的相似关系，通过这种双向互补的信

息融合策略，大幅提升了模型对复杂语义的表征能力与学习效率，从而提升模型的表征能力。

5 结语

针对在个性化课程推荐中知识图谱辅助信息嵌入推荐系统时未考虑到用户交互信息的问题，本文提出了一种融合知识图谱和用户课程交互图的信息增强表示的图神经网络推荐模型 IKGCN。该模型通过对知识图谱和用户课程交互图进行聚合，强化学习课程的特征表示，引入融合门聚合模块融合知识图谱和用户课程交互图信息，更好地获得用户行为模式，从而增强课程的信息表示。实验结果表明，该模型在 MOOCCube 数据集上的推荐性能均有所提高。而随着人工智能技术在各领域的深度渗透，在线课程推荐可从以下维度展开探索。一方面，可通过优化模型架构与训练策略，显著提升模型的跨数据集迁移性能与鲁棒性。通过研究迁移学习与领域自适应技术，使其能够快速适配不同类型的课程数据集，像职业教育课程库、兴趣技能课程平台等都能被高效覆盖，以此拓宽模型在教育领域的应用边界，且这种适配能力同样可延伸至其他领域，为更广泛的场景提供支持；另一方面，结合新兴的大语言模型技术，增强模型对课程文本内容的理解与语义分析能力，有望实现更智能、更精准的个性化课程推荐，为在线教育的智能化发展注入新动能。

6 参考文献

[1] Otero-Cano P A, Pedraza-Alarcón E C. Recommendation systems in education: A review of recommendation mechanisms in e-learning environments[J]. Revista Ingenierías Universidad De Medellín, 2021, 20(38): 147-158.

[2] Du Menghan, Cui Xianji, Jiang Yumeng, et al. Research on MOOC Recommendation Method Based on LDA Topic Model[J]. Computer and Digital Engineering, 2024, 52(12): 3616-3622+3760.(in Chinese)
杜梦晗,崔仙姬,姜雨蒙,等.基于LDA主题模型的MOOC推荐方法研究[J].计算机与数字工程,2024,52(12):3616-3622+3760.

[3] Tong Jiawei, Liu Zelin. Design of a Personalized Learning Platform for Aesthetic Education Courses Based on the Collaborative Filtering Algorithm[J]. Computer Programming Skills & Maintenance, 2025, (03): 50-52. (in Chinese)
童家玮,刘泽霖.基于协同过滤算法的美育课程个性化学习平台设计[J].电脑编程技巧与维护,2025,(03):50-52.

[4] Mao Lei. Design and Implementation of an Online Course Recommendation System[J]. Fujian Computer, 2024, 40(06): 95-98. (in Chinese)
毛雷.在线课程推荐系统设计与实现[J].福建电脑,2024,40(06):95-98.

[5] Zhang H, Shen X, Yi B, et al. KGAN: Knowledge grouping aggregation network for course recommendation in MOOCs[J]. Expert Systems with Applications, 2023, 211: 118344.

[6] Dai Jie, Li Qingshan, Chu Hua, Zhou Yangtao, Yang Wenyong, Wei Biaobiao. Breaking through Smart Education: A Course Recommendation System Based on Graph Learning[J]. Journal of Software, 2022, 33(10): 3656-3672. (in Ch-inese)
歹杰,李青山,褚华,周洋涛,杨文勇,卫彪彪.突破智慧教育:基于图学习的课程推荐系统[J]. 软件学报,2022,33(10): 3656-3672.

[7] Tang S, Peterson J, Pardos Z. Predictive modelling of student behaviour using granular large-scale action data[J]. The Handbook of Learning Analytics, 2017: 223-233.

[8] Zhang H, Huang T, Lv Z, et al. MOOCRC: A highly accurate resource recommendation model for use in MOOC environments[J]. Mobile Networks and Applications, 2019, 24: 34-46.

[9] Hao Haihong, Yu Xinyu. Exploration on the Path of Content Supply for College Students' Network Ideological and Political Education—From the Perspective of Content Recommendation Algorithm[J]. Journal of Guangxi College of Education, 2025, 40(03): 104-111(in Chinese)
郝海洪,余欣宇.大学生网络思想政治教育内容供给路径探赜——基于内容推荐算法视角[J].广西教育学院学报,2025,40(03):104-111.

[10] Wang Guang, Zhang Jiemin, Dong Shuaihan, et al. Content-based Weighted Granularity Sequence Recommendation Algorithm[J]. Computer Engineering and Science, 2018, 40(03): 564-570. (in Chinese)
王光,张杰民,董帅含,等.基于内容的加权粒度序列推荐算法[J].计算机工程与科学,2018,40(03):564-570.

[11] Li Zhongjun, Zhou Qihai, Shuai Qinghong. A Recommendation System Model Based on Isomorphic Integration of Content-based and Collaborative Filtering[J]. Computer Science, 2009, 36(12): 142-145. (in Chinese)
李忠俊,周启海,帅青红.一种基于内容和协同过滤同构化整合的推荐系统模型[J].计算机科学,2009,36(12):142-145.

[12] Zhang Jian'an, Yang Kai. Collaborative Filtering Recommendation Algorithm Based on User Pseudo-Strong Concepts[J]. Control Engineering, 2025, 32(05): 882-890. (in Chinese)
张健安,杨凯. 基于用户伪强概念的协同过滤推荐算法 [J]. 控制工程, 2025, 32 (05): 882-890.

[13] Zhang Xuan, Su Kai, Qian Feng. Collaborative Filtering Algorithm Based on Item Popularity and Dynamic Interest Changes[J]. Fire Control & Command Control, 2022, 47(12): 136-144. (in Chinese)
张萱,苏凯,钱锋.基于项目流行度及兴趣动态变化的协同过滤算法[J].火力与指挥控制,2022,47(12):136-144.

[14] Ma Jianhong, Zhang Tong. Expert Recommendation Algorithm for Enterprise Engineering Problems[J]. Computer Science, 2022, 49(01): 159-165. (in Chinese)
马建红,张炯.面向企业工程问题的专家推荐算法[J].计算机科学,2022,49(01):159-165.

[15] Yu Yonghong, Chen Xingguo, Gao Yang. An Item Recommendation Algorithm Based on Coupled Object Similarity[J]. Computer Science, 2014, 41(02): 33-35+54. (in Chinese)
余永红,陈兴国,高阳.一种基于耦合对象相似度的项目推荐算法[J].计算机科学,2014,41(02):33-35+54.

[16] Zhang F, Yuan N J, Lian D, et al. Collaborative knowledge base embedding for recommender systems[C]//Proceedings of the 22nd ACM SIGKDD international conference on knowledge discovery and data mining. 2016: 353-362.

[17] Koren Y, Bell R, Volinsky C. Matrix factorization techniques for recommender systems[J]. Computer, 2009, 42(8): 30-37.

[18] Wang H, Zhao M, Xie X, et al. Knowledge graph convolutional networks for recommender

systems[C]//The world wide web conference. 2019: 3307-3313.

[19] Wang X, He X, Cao Y, et al. Kgat: Knowledge graph attention network for recommendation[C]//Proceedings of the 25th ACM SIGKDD international conference on knowledge discovery & data mining. 2019: 950-958.

[20] Wang Z, Lin G, Tan H, et al. CKAN: Collaborative knowledge-aware attentive network for recommender systems[C]//Proceedings of the 43rd International ACM SIGIR conference on research and development in Information Retrieval. 2020: 219-228.

[21] Wang X, Huang T, Wang D, et al. Learning intents behind interactions with knowledge graph for recommendation[C]//Proceedings of the web conference 2021. 2021: 878-887.

[22] Wang X, He X, Wang M, et al. Neural graph collaborative filtering[C]//Proceedings of the 42nd international ACM SIGIR conference on Research and development in Information Retrieval. 2019:165-174.

[23] Xu Haotian, Cai Wenyu, Zhang Meiyan, et al. A Lightweight Convolutional Neural Network Model Based on the Combination of MobileNet and ShuffleNet[J]. Journal of Hangzhou Dianzi University (Natural Science Edition), 2025, 45(03): 50-62+72. (in Chinese)
许浩天,蔡文郁,张美燕,等.基于MobileNet-ShuffleNet结合的轻量级卷积神经网络模型[J].杭州电子科技大学学报(自然科学版),2025,45(03):50-62+72.

[24] Mei Suyuan. Research on Course Recommendation Methods for MOOCs[D]. Hefei University of Technology, 2023. (in Chinese)
梅苏源.面向MOOC的课程推荐方法研究[D].合肥工业大学,2023.

[25] Hu Jintao, Xian Guangming. Graph Contrastive Learning Recommendation Algorithm Based on Self-Attention Mechanism[J/OL]. Computer Science, 1-12[2025-06-15]. (in Chinese)
胡金涛,冼广铭.基于自注意力机制的图对比学习推荐算法[J/OL].计算机科学,1-12[2025-06-15].

[26] Zhou Yangtao, Chu Hua, Zhu Feifei, et al. A Survey of Deep Learning-based Personalized Learning Resource Recommendation[J]. Computer Science, 2024, 51(10): 17-32. (in Chinese)
周洋涛,褚华,朱非非,等.基于深度学习的个性化学习资源推荐综述[J].计算机科学,2024,51(10):17-32.

[27] Lu Haiyang, Liu Xianhui, Hou Wenlong. Negative Sampling Method Fusing Knowledge Graph[J]. Computer Science, 2025, 52(03): 161-168. (in Chinese)
陆海洋,柳先辉,侯文龙.融合知识图谱的负采样方法[J].计算机科学,2025,52(03):161-168.

[28] Yu H, Zhang W, Chen Z, 等. MOOCCube: A Large - scale Data Repository for NLP applications in MOOCs[C]//Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics. Online: Association for Computational Linguistics, 2020: 3135-3140.

[29] Ran Jia. Research on Knowledge Recommendation Based on User Interest Topic Model [D]. Zhengzhou University, 2020. (in Chinese)
冉佳. 基于用户兴趣主题模型的知识推荐研究[D]. 郑州大学, 2020.

[30] Cui Yan. Research on Hybrid Recommendation

Algorithm Based on Convolutional Neural Network [D]. Changchun University of Technology, 2020. (in Chinese)
崔岩. 基于卷积神经网络的混合推荐算法研究[D]. 长春工业大学, 2020.

[31] Du Y, Zhu X, Chen L, et al. Metakg: Meta-learning on knowledge graph for cold-start recommendation[J]. IEEE Transactions on knowledge and data engineering, 2022, 35(10): 9850-9863.

中文简介:

赵蕾，出生于 1981 年，博士，副教授，主要研究方向为知识图谱和推荐系统。

杨雨露，出生于 2002 年，硕士，学生，主要研究方向为知识图谱。

袁波，出生于 2000 年，硕士，学生，主要研究方向为推荐系统。

Zhao Lei,born in Shan Xi, Ph.D, associate professor, master supervisor. Her main research interests include Knowledge Graph and Recommendation System.

Yang Yulu，born in Shan Xi, postgraduate,student, Her main research interests include Knowledge Graphs.